



CNN & RNN

人工神经网络


- 连接主义观点：将大量的神经元之间，按照拓扑连接结构，构成人工神经网络。
- 网络的拓扑结构
 - 不同神经元之间的连接关系。
 - 前馈网络（feedforward）、反馈网络（feedback）和记忆网络（memory network）



(a) 前馈网络

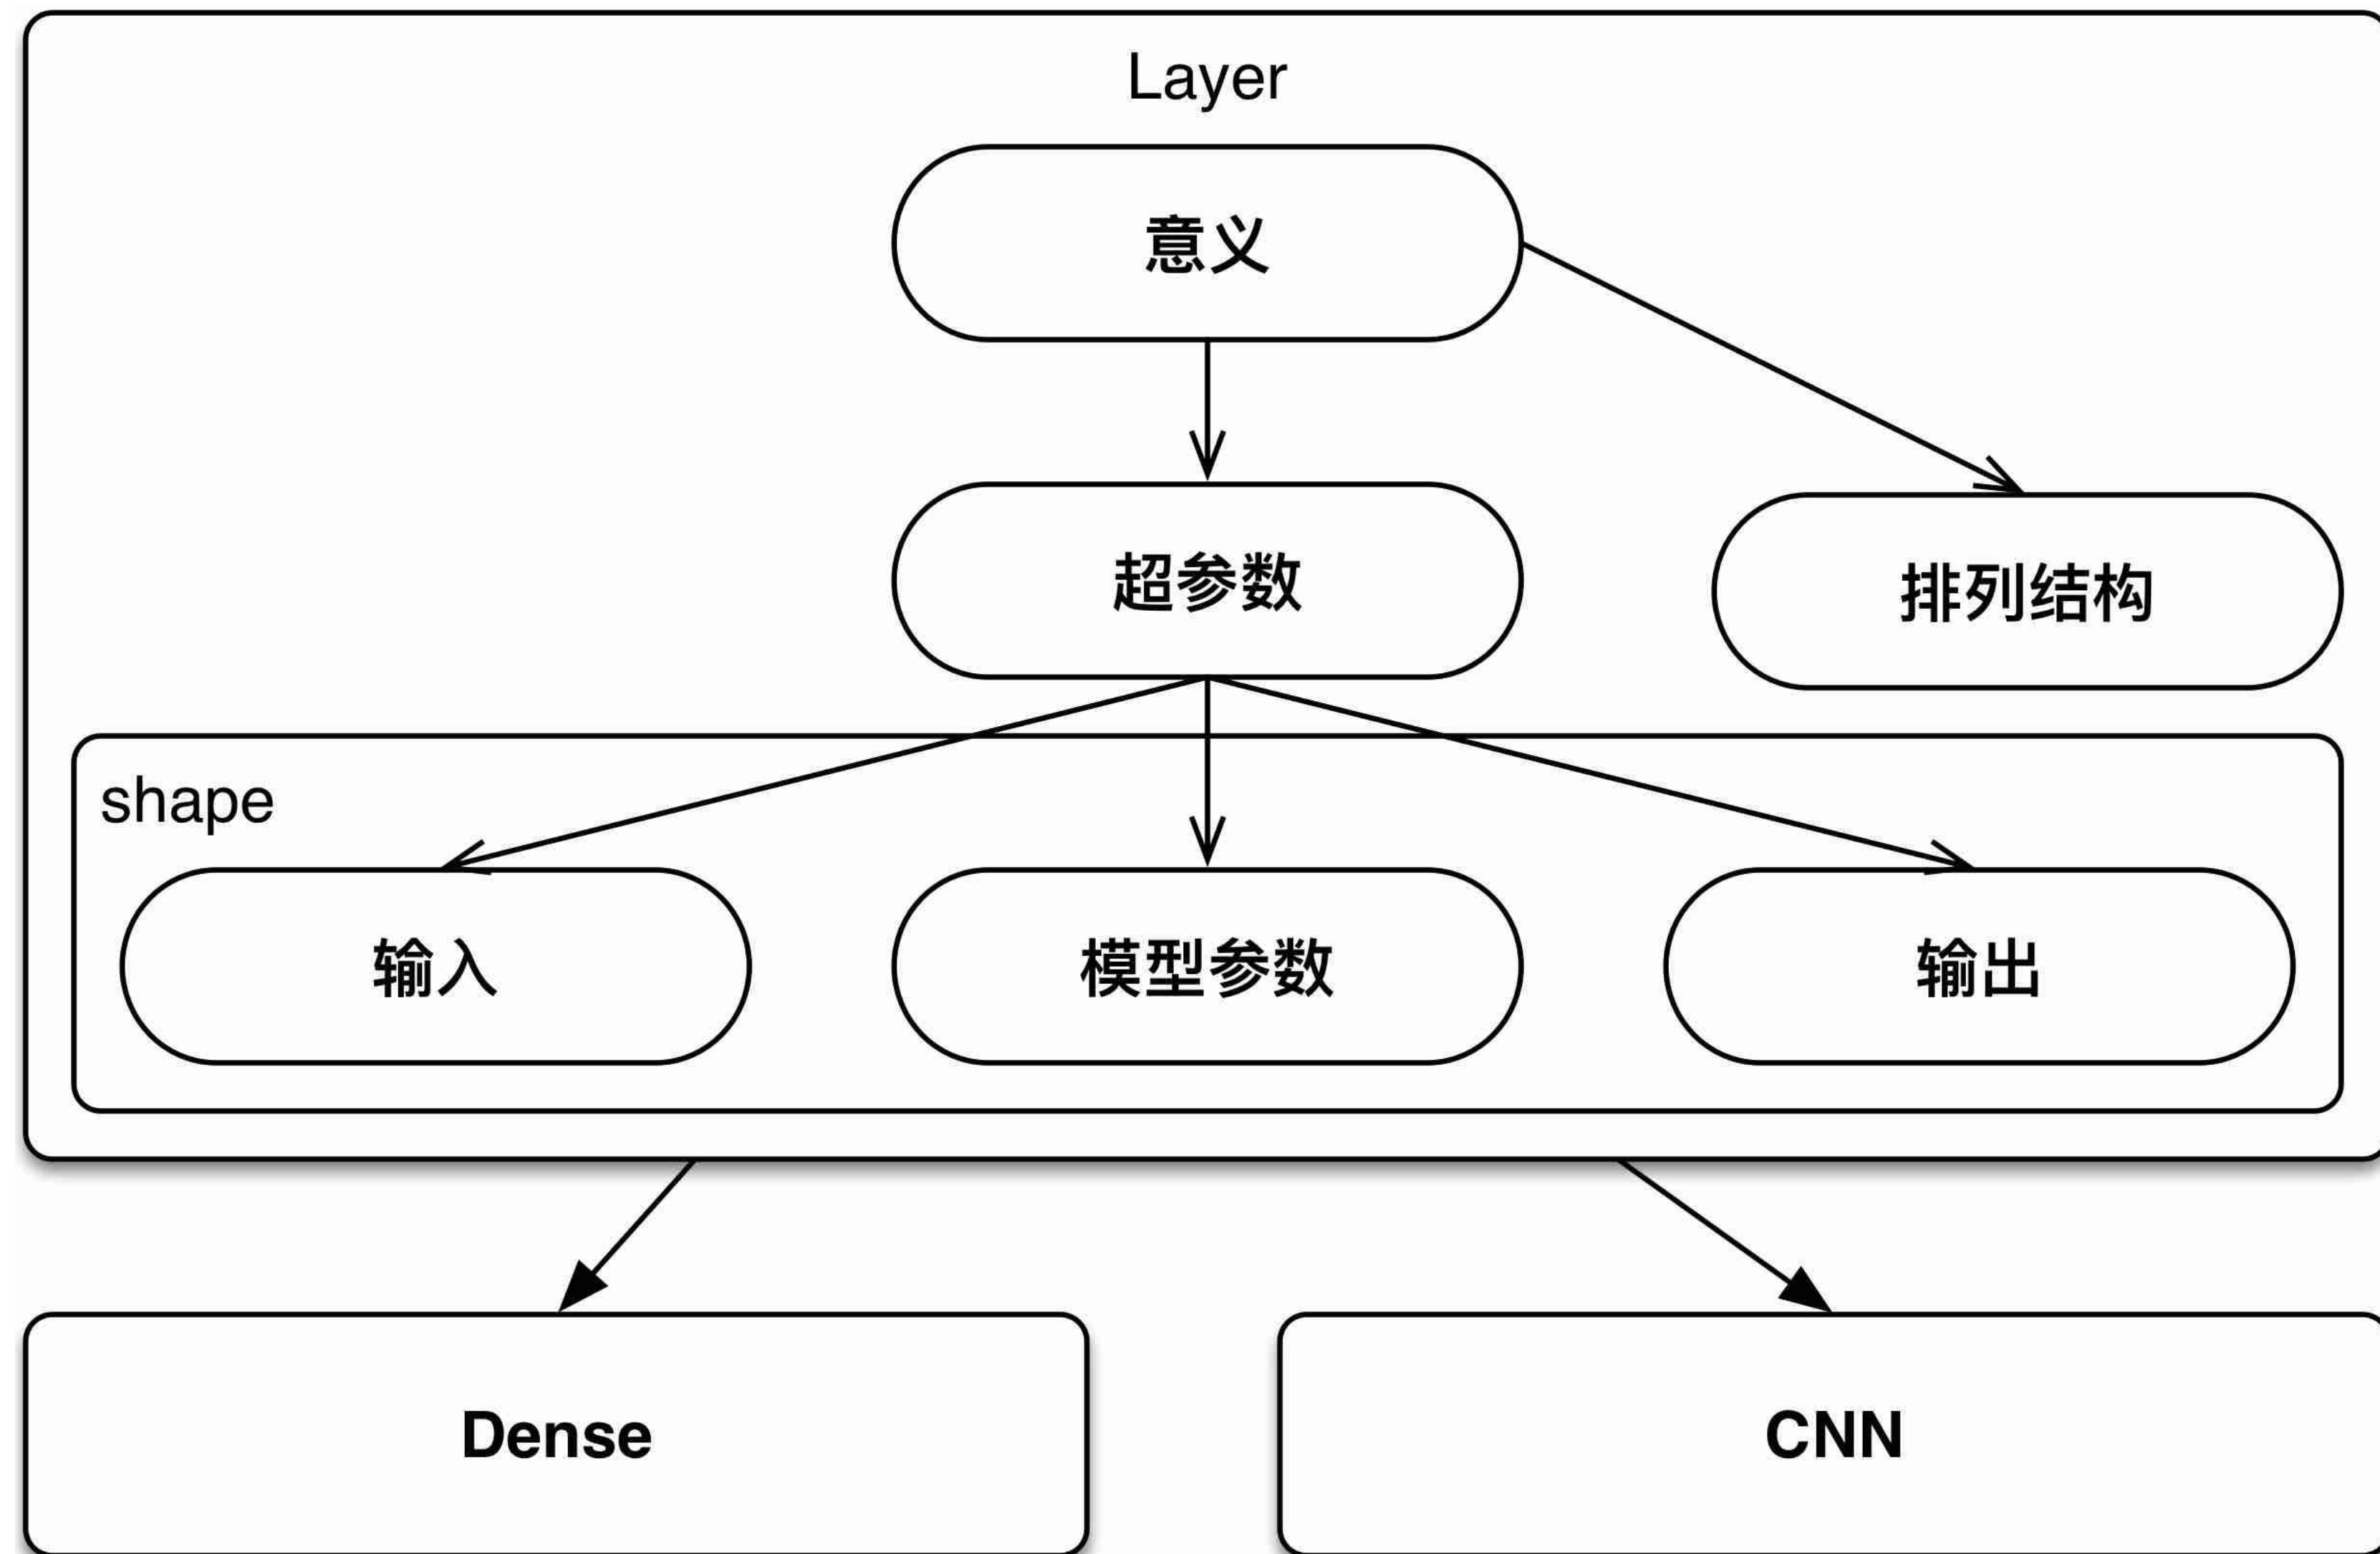


(b) 反馈网络

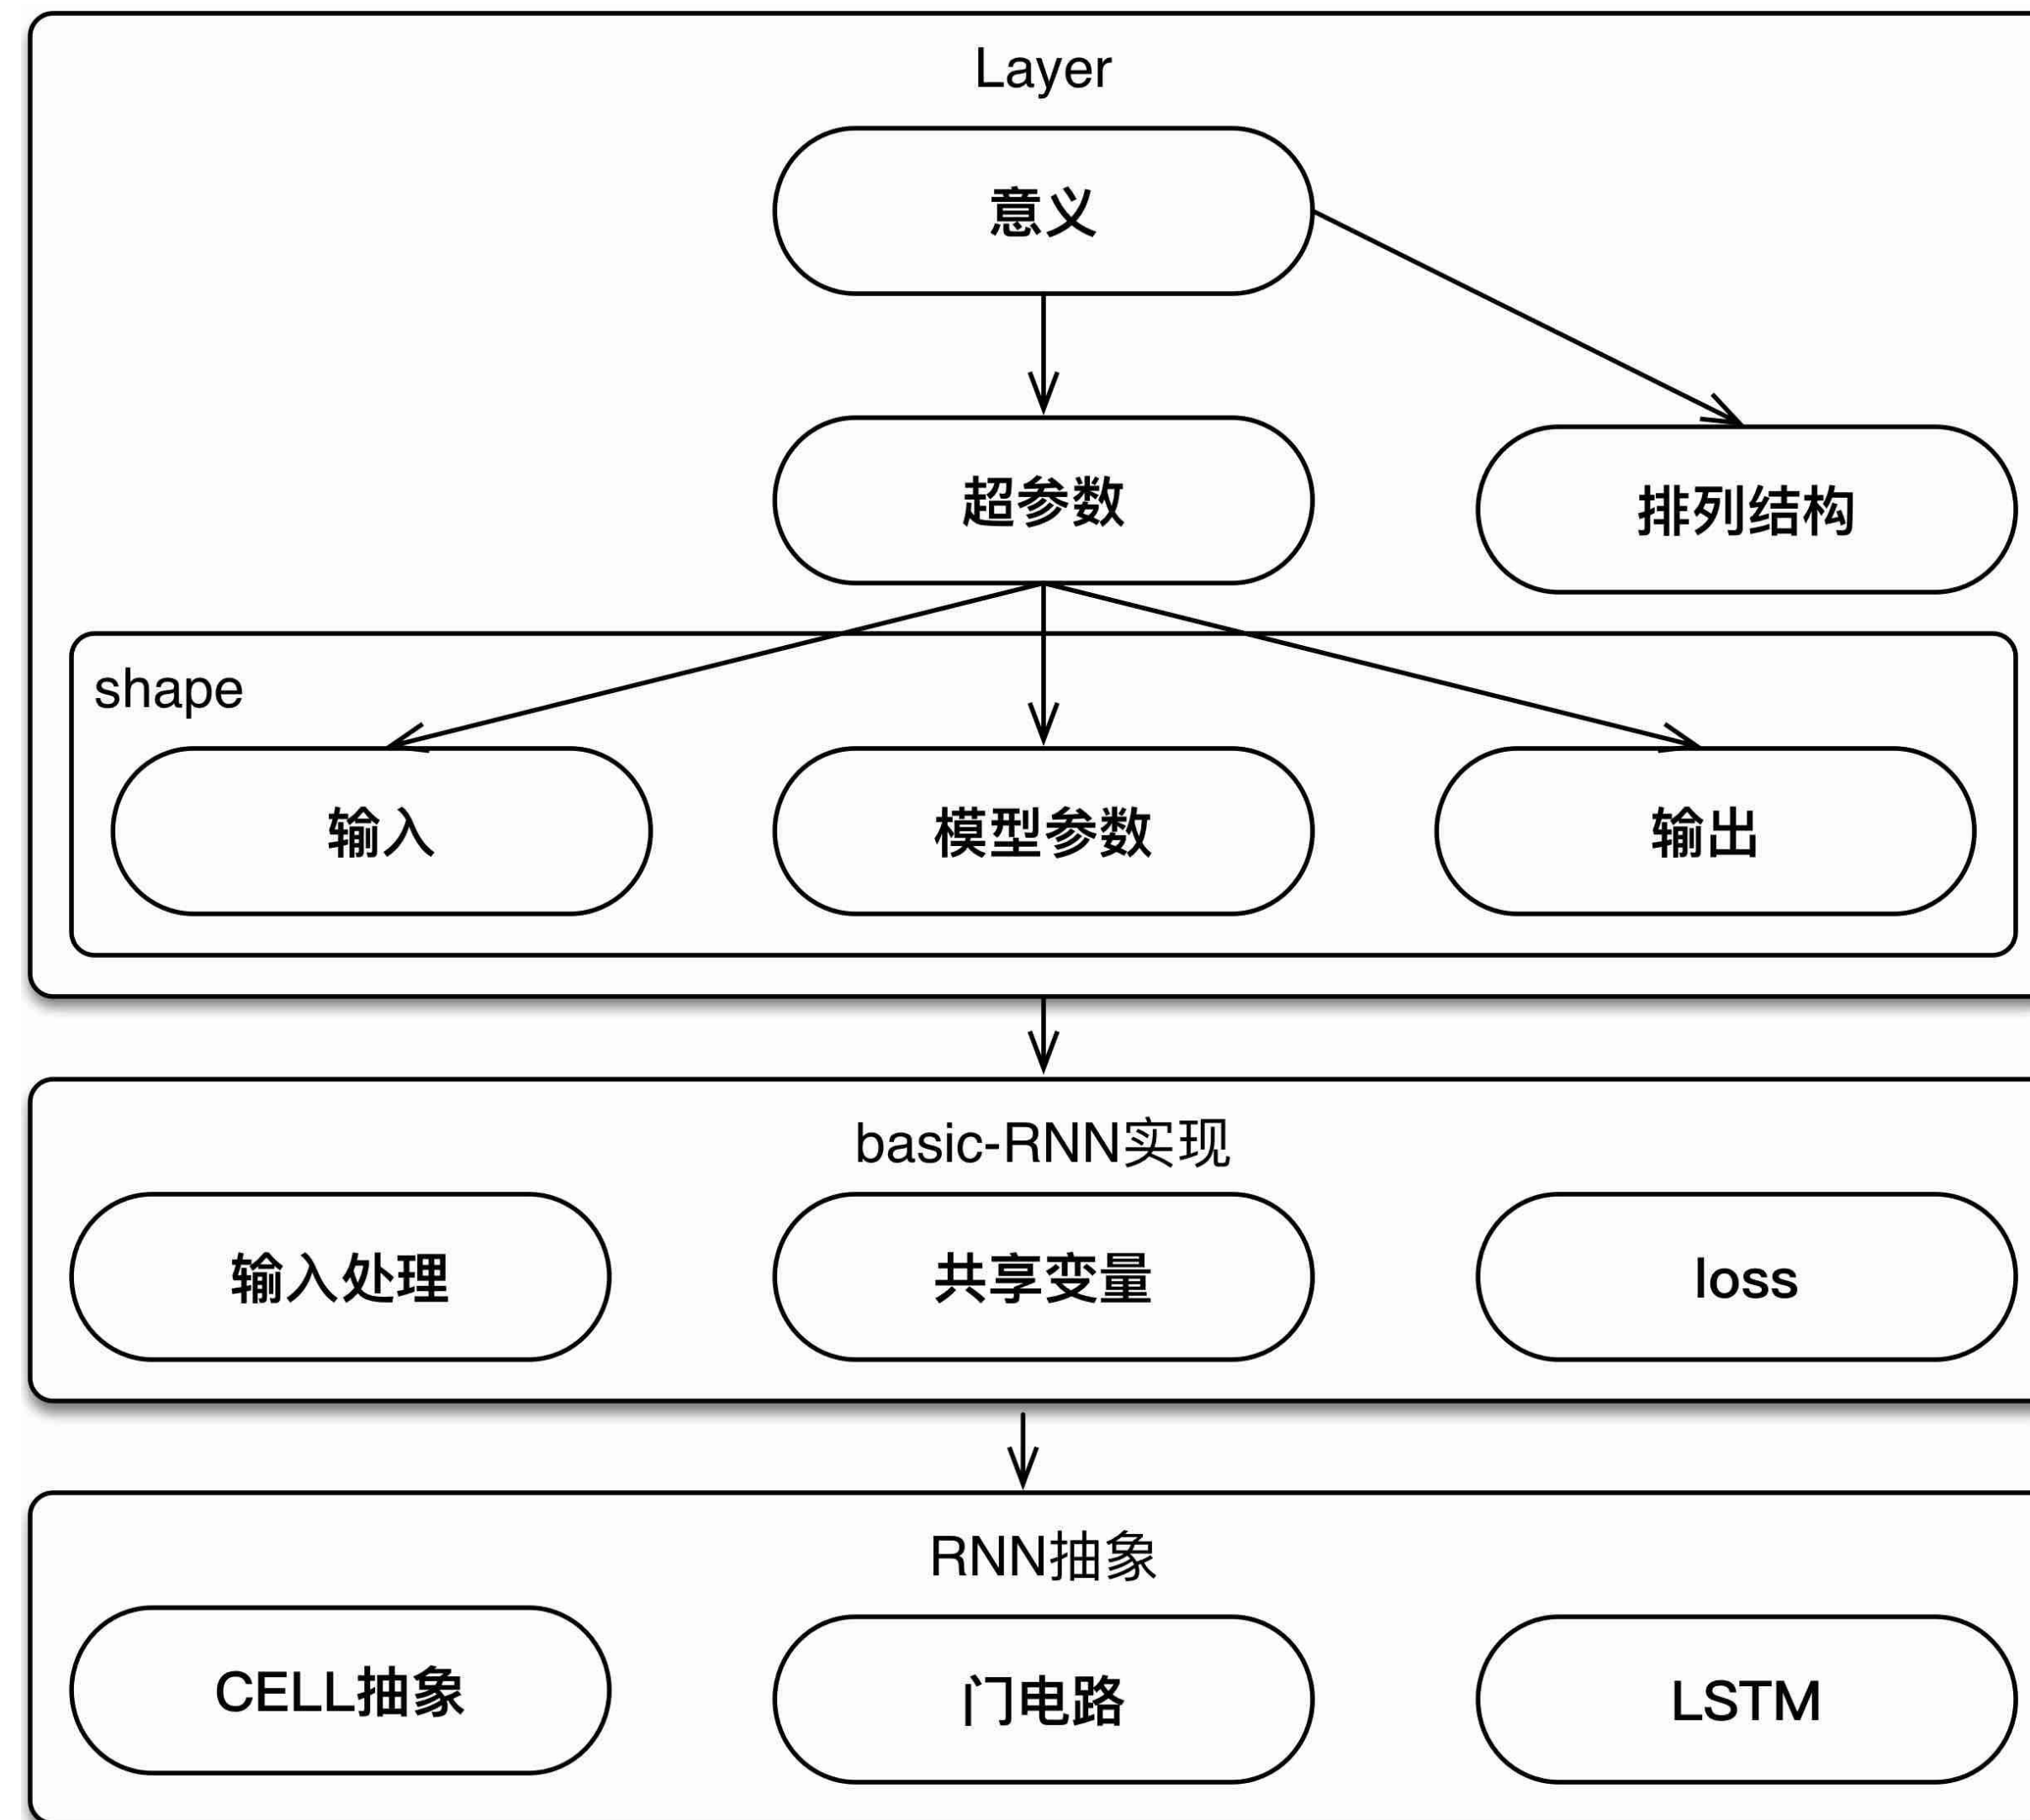


(c) 记忆网络

TensorFlow学习路线： Dense与CNN




TensorFlow学习路线： RNN与LSTM



Dense

学习路线



Tensor形象化表示


- 对于一个4*5*6的Tensor

- rank : 3d

- length: 4, 5, 6

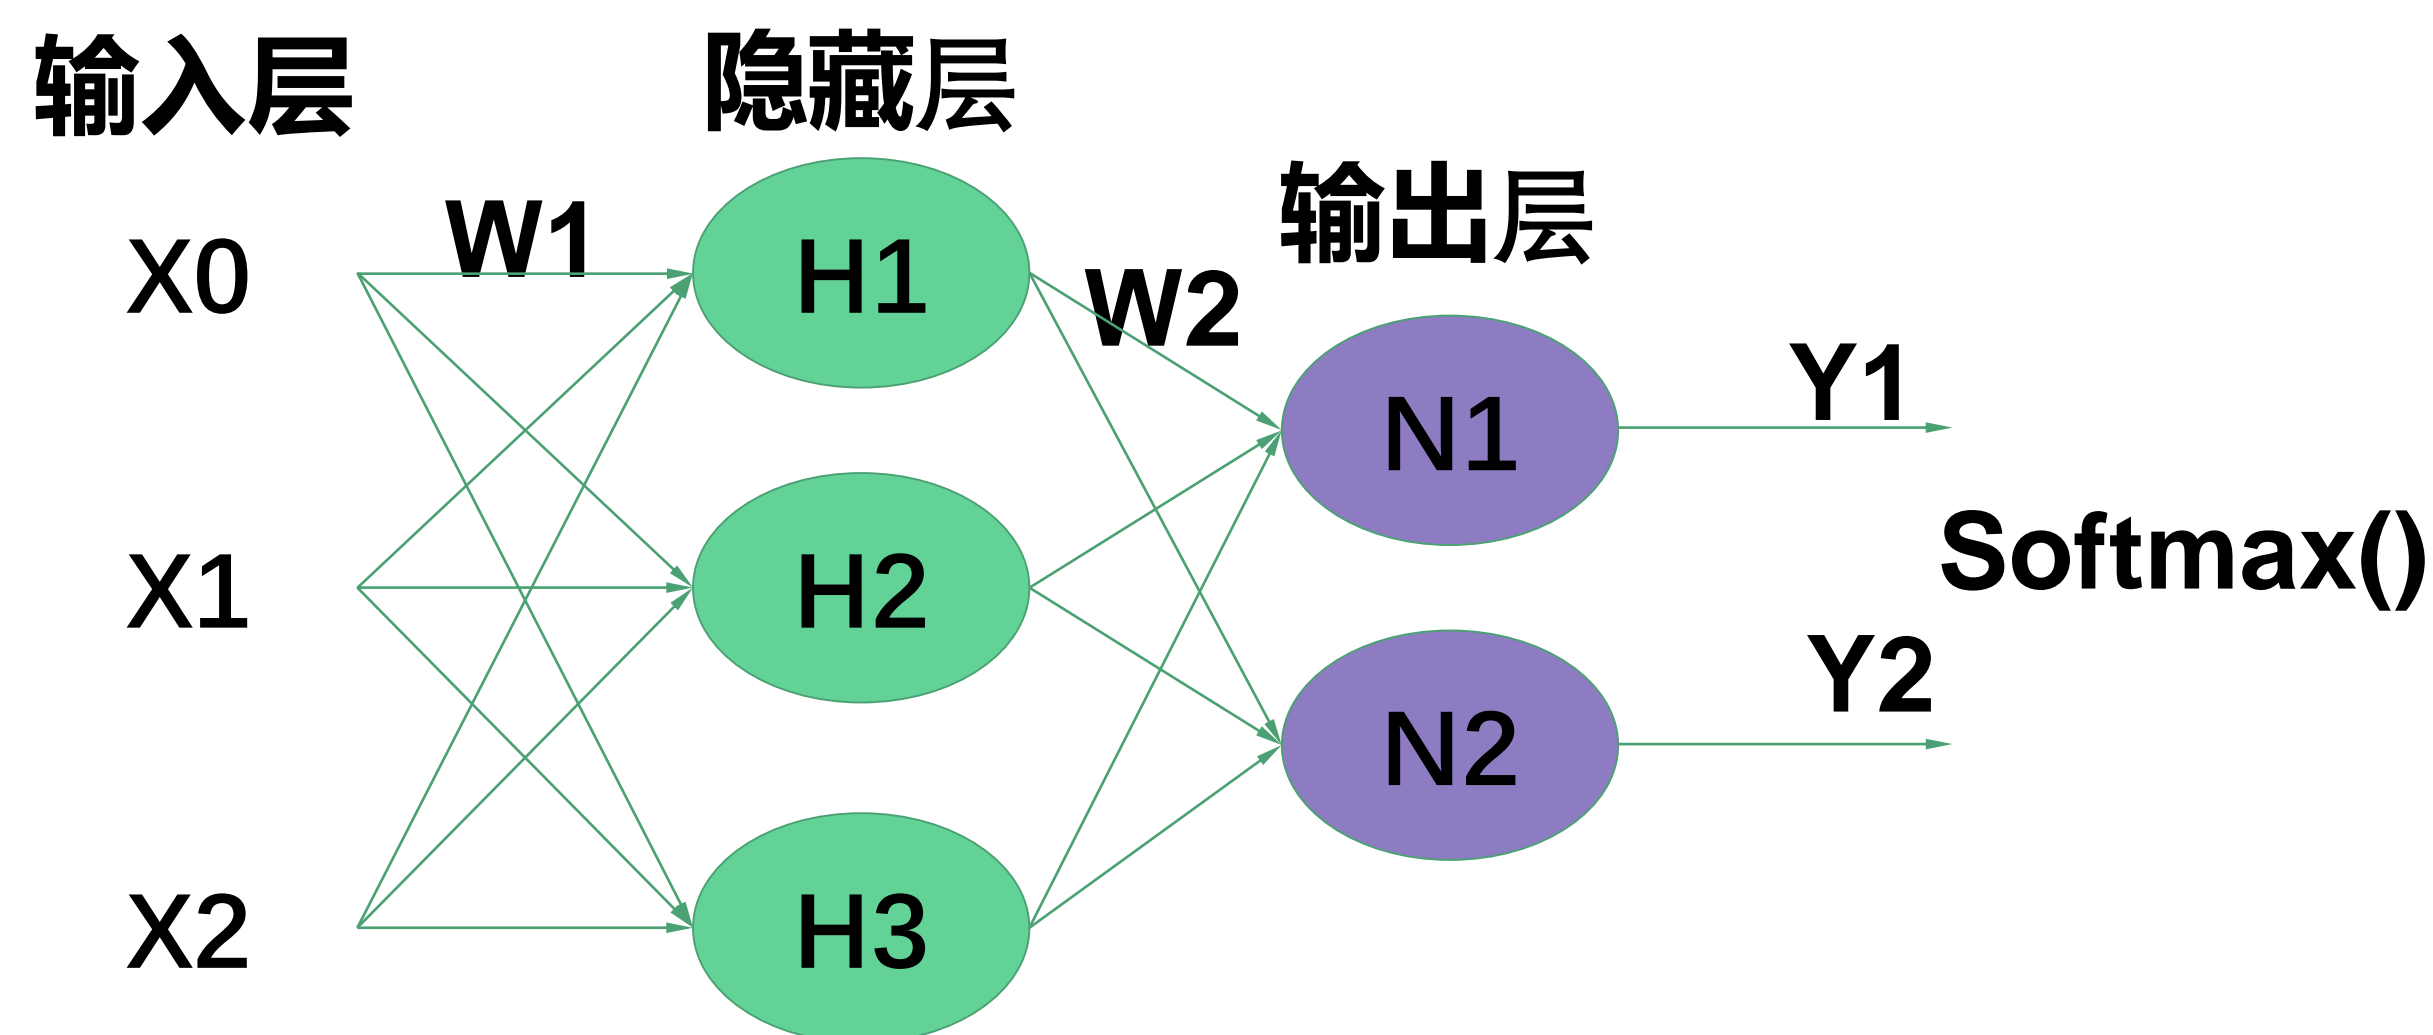
- shape: [4, 5, 6]

- volume: $4*5*6=120$



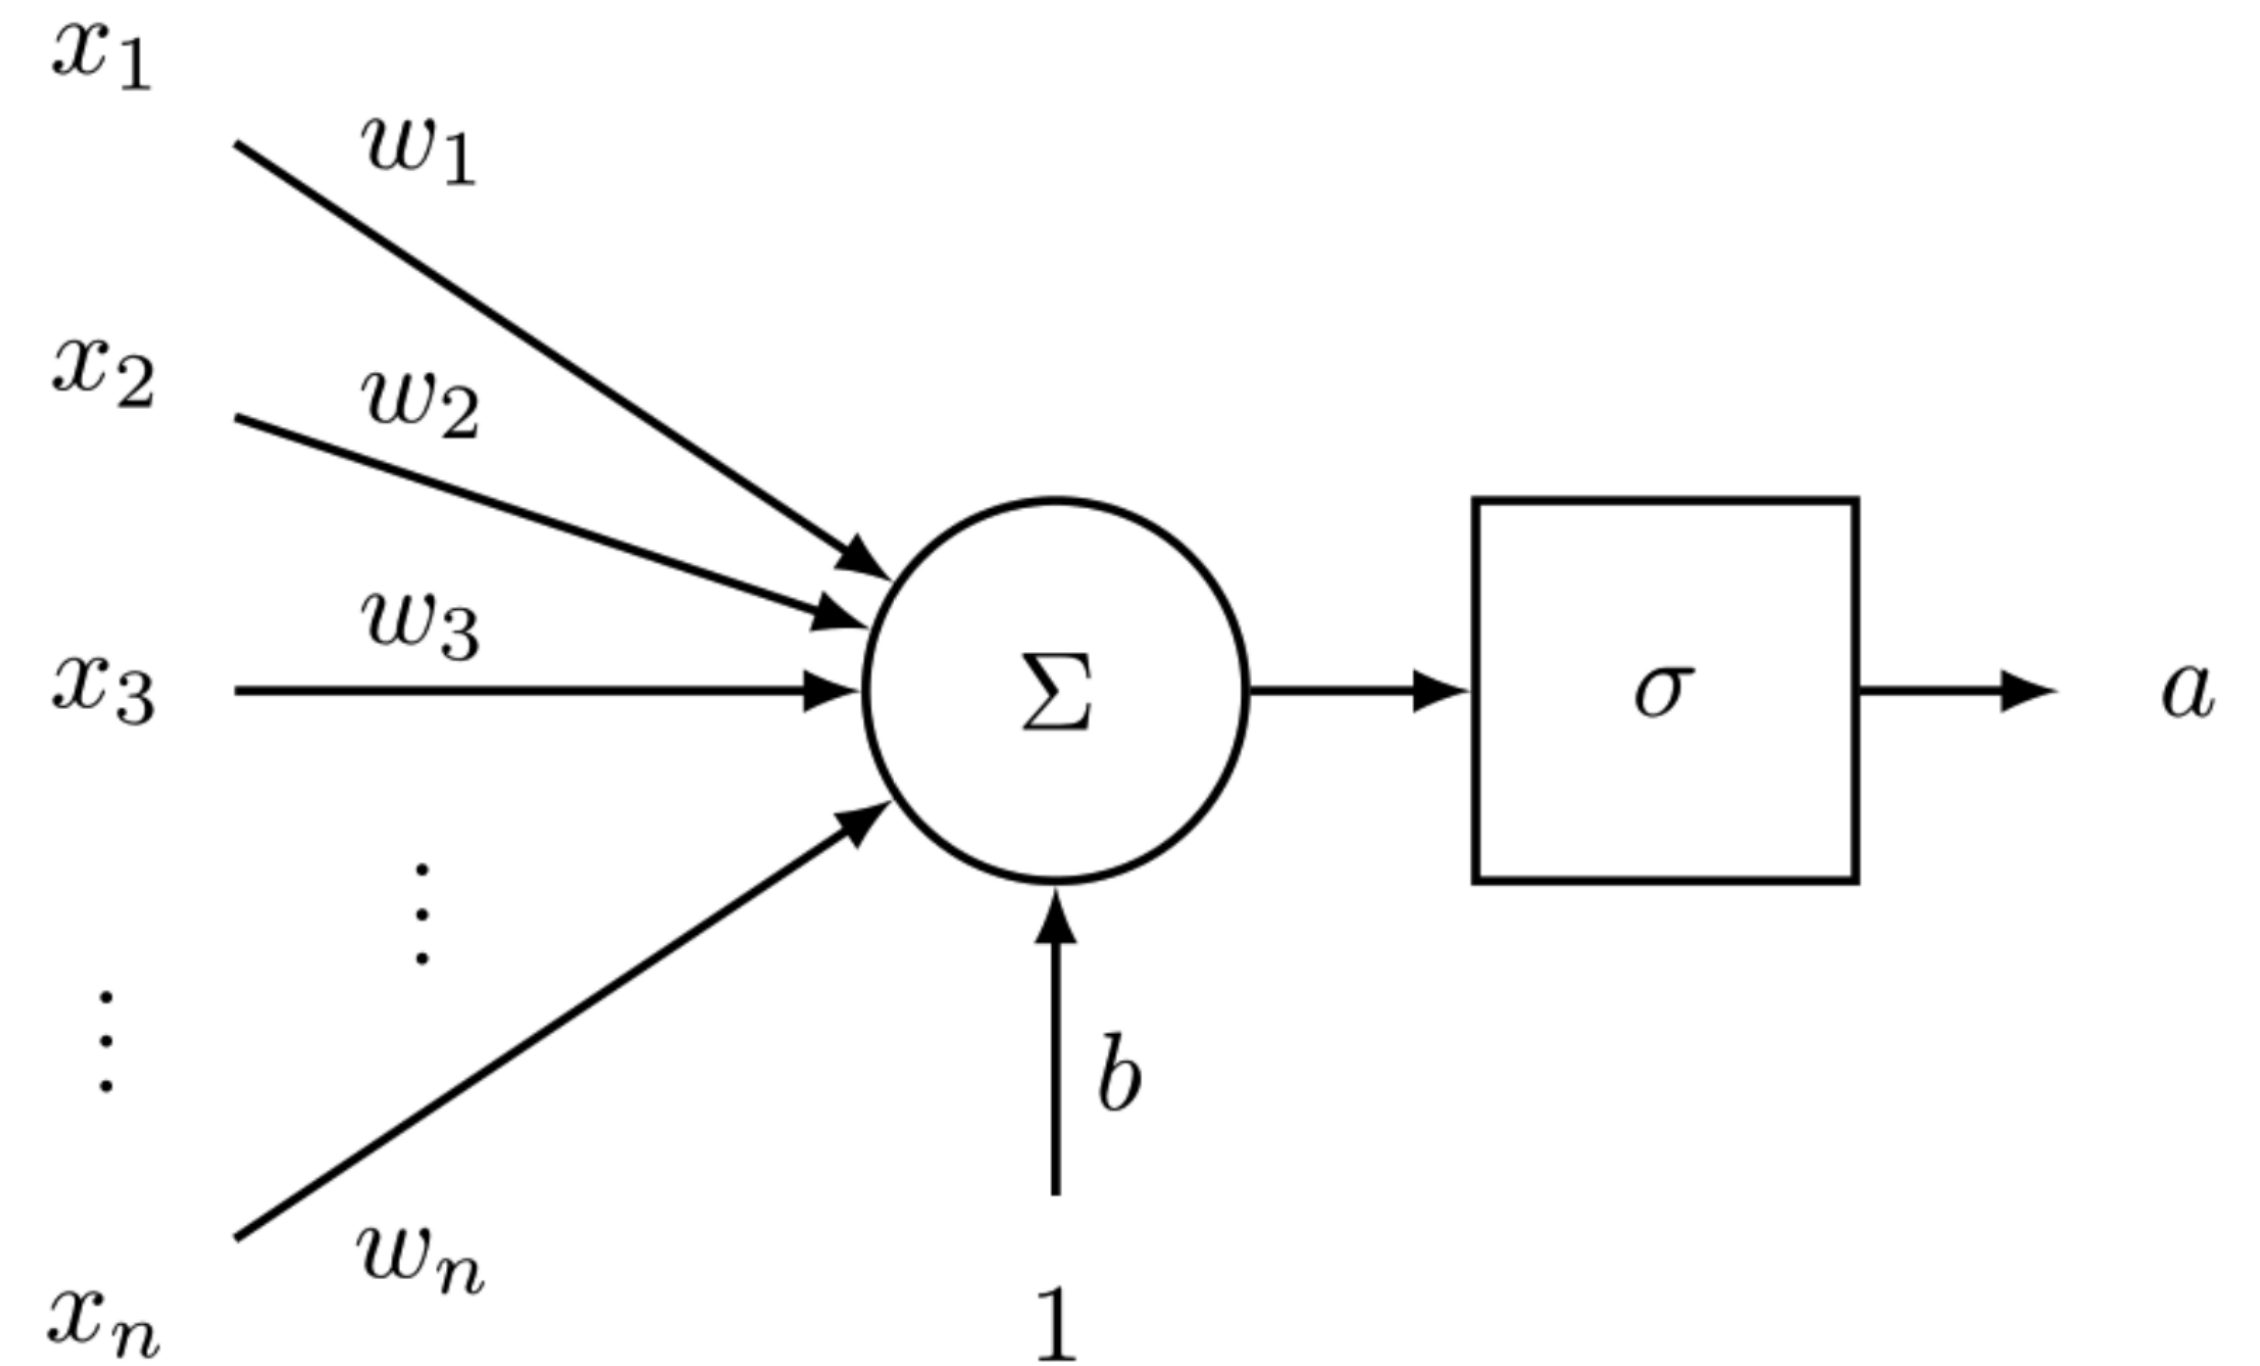
多层前馈网络 (Multilayer feedforward networks)

- 前馈网络结构 (feedforward) 是一种**计算图 (Computational Graph)**
- 别名：多层全连接网络 (FCN)、多层感知机 (MLP)、多个密集层网络 (Dense)
- 神经网络有3个输入，2个输出，中间有1个隐藏层，有1个输出层，共有5个神经元。



Neuron \rightarrow Layer

- 单个神经元：
 - 输入是1d, 参数是1d, 输出是0d
- 一层神经元构成一个Layer
 - 显然输出的shape和Layer的shape一致.
- batch_size
 - 会影响输出的shape
 - 并不会影响参数的shape



Dense

- 排列结构: Layer的结构是1d
- 超参数: 神经元的个数U
- shape:
 - $\text{input} = L$
 - $\text{weights} = L * U$
 - $\text{output} = U$
- 意义: 多个Dense层构成MLP (Multi-layer Perceptron, 多层感知机), 用于解分类问题.

```
tf.layers.dense(  
    inputs,  
    units  
    activation=None,  
    use_bias=True,  
    kernel_initializer=None,  
    bias_initializer=tf.zeros_initializer(),  
    kernel_regularizer=None,  
    bias_regularizer=None,  
    activity_regularizer=None,  
    kernel_constraint=None,  
    bias_constraint=None,  
    trainable=True,  
    name=None,  
    reuse=None  
)
```

Softmax处理

- 输出层的Softmax 处理，计算出一个概率分布：


$$g(z_m) = \frac{e^{z_m}}{\sum_k e^{z_k}}$$

- 所有分量之和为 1, 所有输出的数值是正的。

`numpy_activation_function.ipynb`

图像处理

- 图像表示-每个像素是数字
- 手写字体MNIST数据集，
 - 灰度图像，
 - 二值图像，黑白：
 - 0代表黑色， 1代表白色
- 时尚MNIST数据集（Fashion MNIST）
 - 彩色图像（RGB）：红(Red)，绿（Green）， 蓝(Blue)
 - 对应的值域从0到255，对应8位2进制数字
 - 24位二进制数字




MLP处理图像

- MLP 分类器（多层Dense）
- MLP来处理一张图像
 - 图像单个像素点的颜色RGB值表示
 - 一张200x200x3的图片
 - 单个神经元有 $200*200*3 = 120,000$ 参数！（参数量太大！怎么办？）

CNN


卷积运算 (Convolution)




- 卷积是一种张量运算
- 输入是多维数组的数据
- 卷积核是一个多维数组，参数由学习算法得到的
- 卷积核数目一般选32、64等
- 这些多维数组都是张量 (Tensor) 。

2d卷积核

- 卷积核是一个多维数组，参数由学习算法得到的
- 定义输入的长度 (W)，卷积核的大小 (F)，核移动的步长stride (S)，zero padding (P)
- 输出的长度 $L = (W - F + 2P) / S + 1$
- 并行化：做一个和输出一样大小的Layer，Layer里面所有的神经元参数都一样！





3d卷积核



- 输入是3d的
- 有多个卷积核

CNN

- 卷积网络 (Convolutional neural network, CNN)
- 特点: 局部区域的权重 W 共用 (**weight sharing**) (空间维度)
- 每一个卷积层后通常紧跟着一个下采样层 (subsample), 如最大池化 (max-pooling) 方法完成下采样。



CNN组成

- 卷积层 (convolutional layers)
- 采样层 (pooling layers)
- 正则层 (normalization layers) (如 dropout)


卷积层

- 意义：用于处理图像.
- 排列结构：Layer的结构是3d
- 超参数：卷积核个数(D)，核大小(F)，padding(P)，strides(S)
- shape：
 - Input = $W \times W \times 3$
 - $L = (W - F + 2P) / S + 1$
 - Layer = $L \times L \times D$
 - Weights = $F \times F \times D$
 - Output = $L \times L \times D$

```
tf.layers.conv2d(  
    inputs,  
    filters,  
    kernel_size,  
    strides=(1, 1),  
    padding='valid',  
    data_format='channels_last',  
    dilation_rate=(1, 1),  
    activation=None,  
    use_bias=True,  
    kernel_initializer=None,  
    bias_initializer=tf.zeros_initializer(),  
    kernel_regularizer=None,  
    bias_regularizer=None,  
    activity_regularizer=None,  
    kernel_constraint=None,  
    bias_constraint=None,  
    trainable=True,  
    name=None,  
    reuse=None  
)
```



Pooling层

- 意义：采样, 缩小模型大小
- 排列结构：Layer的结构是3d
- 超参数： `pooling_type`, `window_shape`, `padding`, `strides`
- 一个2*2核, `strides=2`的pooling层, 等于减少75%的输出
- pooling层并不会改变tensor的深度




Dropout层


- 意义：减少CNN过拟合问题
- 超参数：keep_prob 丢弃率
- 对于所有的输入，有keep_prob概率保留并乘以 $1/\text{keep_prob}$ ，以保证前后总和大致相等，否则输出0




(a) Standard network



(b) Dropout network



(a) Standard Neural Net



(b) After applying dropout.

共享Variable

```
def my_image_filter(input_images):  
    with tf.variable_scope("conv1"):  
        # Variables created here will be named "conv1/weights", "conv1/biases".  
        relu1 = conv_relu(input_images, [5, 5, 32, 32], [32])  
    with tf.variable_scope("conv2"):  
        # Variables created here will be named "conv2/weights", "conv2/biases".  
        return conv_relu(relu1, [5, 5, 32, 32], [32])
```




```
with tf.variable_scope("model") as scope:  
    output1 = my_image_filter(input1)  
scope.reuse_variables()  
    output2 = my_image_filter(input2)
```

生成两套参数

```
with tf.variable_scope("model") as scope:  
    output1 = my_image_filter(input1)  
    scope.reuse_variables()  
    output2 = my_image_filter(input2)
```

共享一套参数

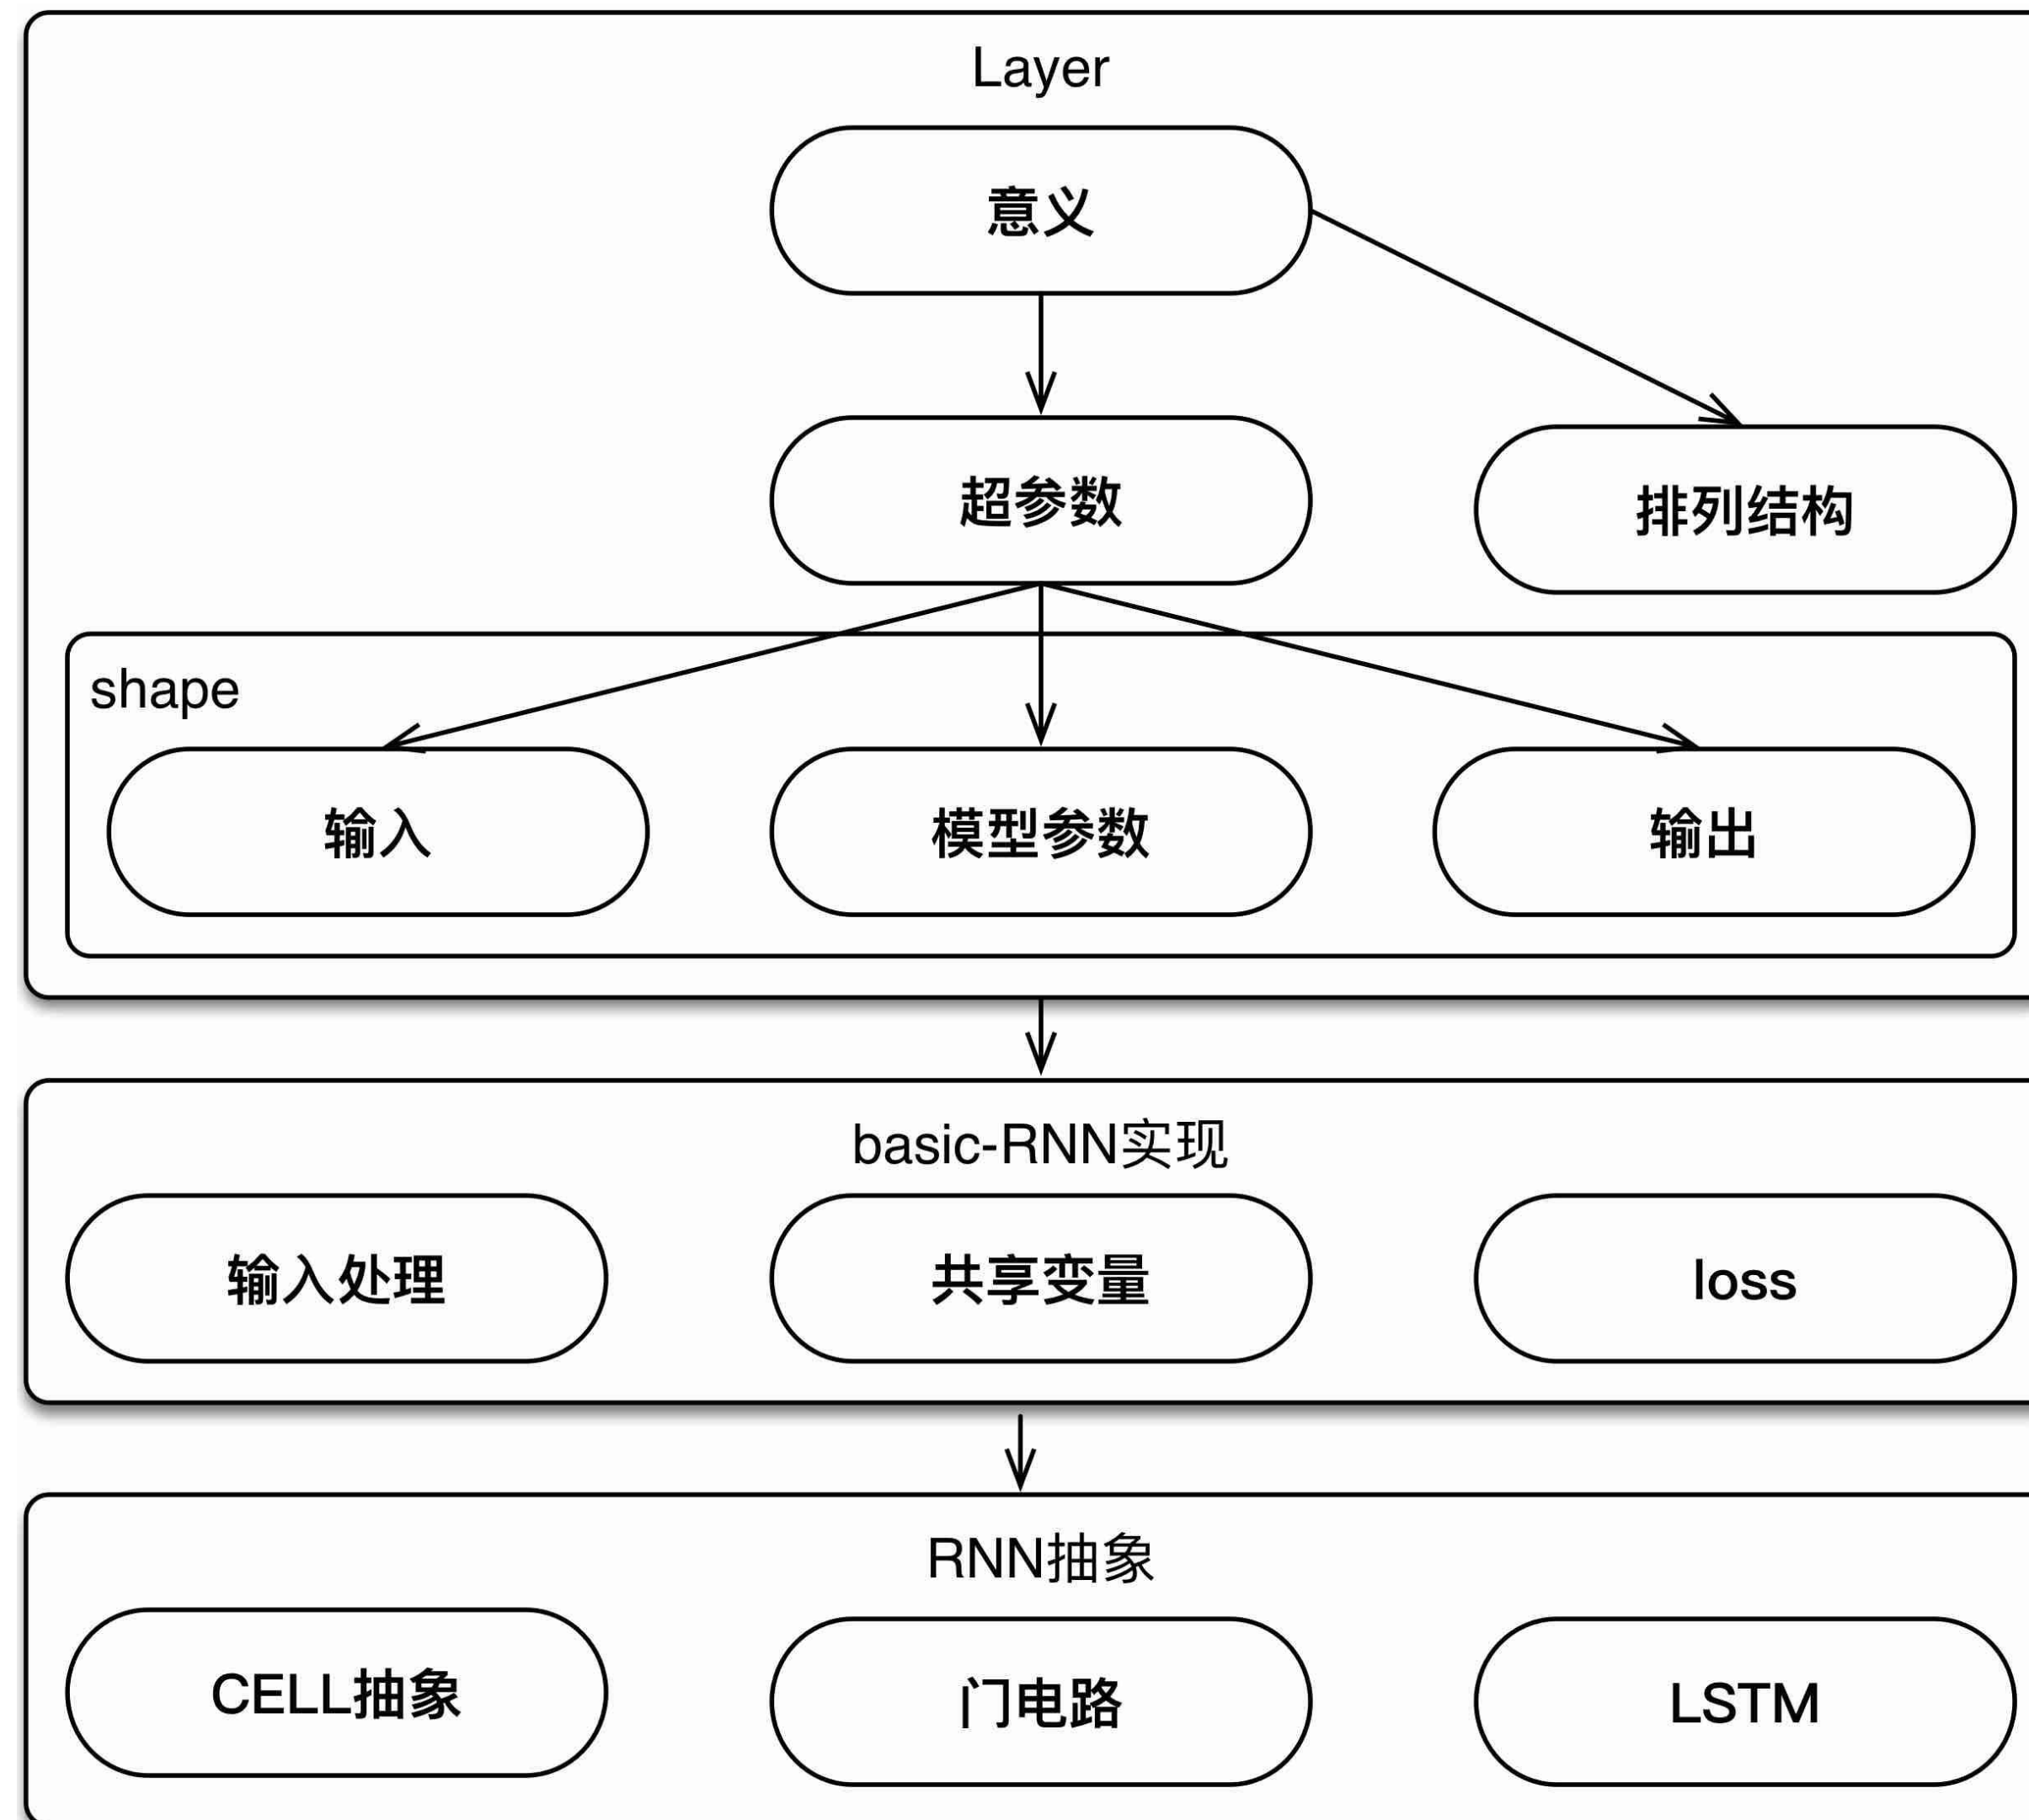
课后阅读作业



Alex Krizhevsky, Ilya Sutskever and Geoffrey E. Hinton. "ImageNet classification with deep convolutional neural networks." NIPS 2012.

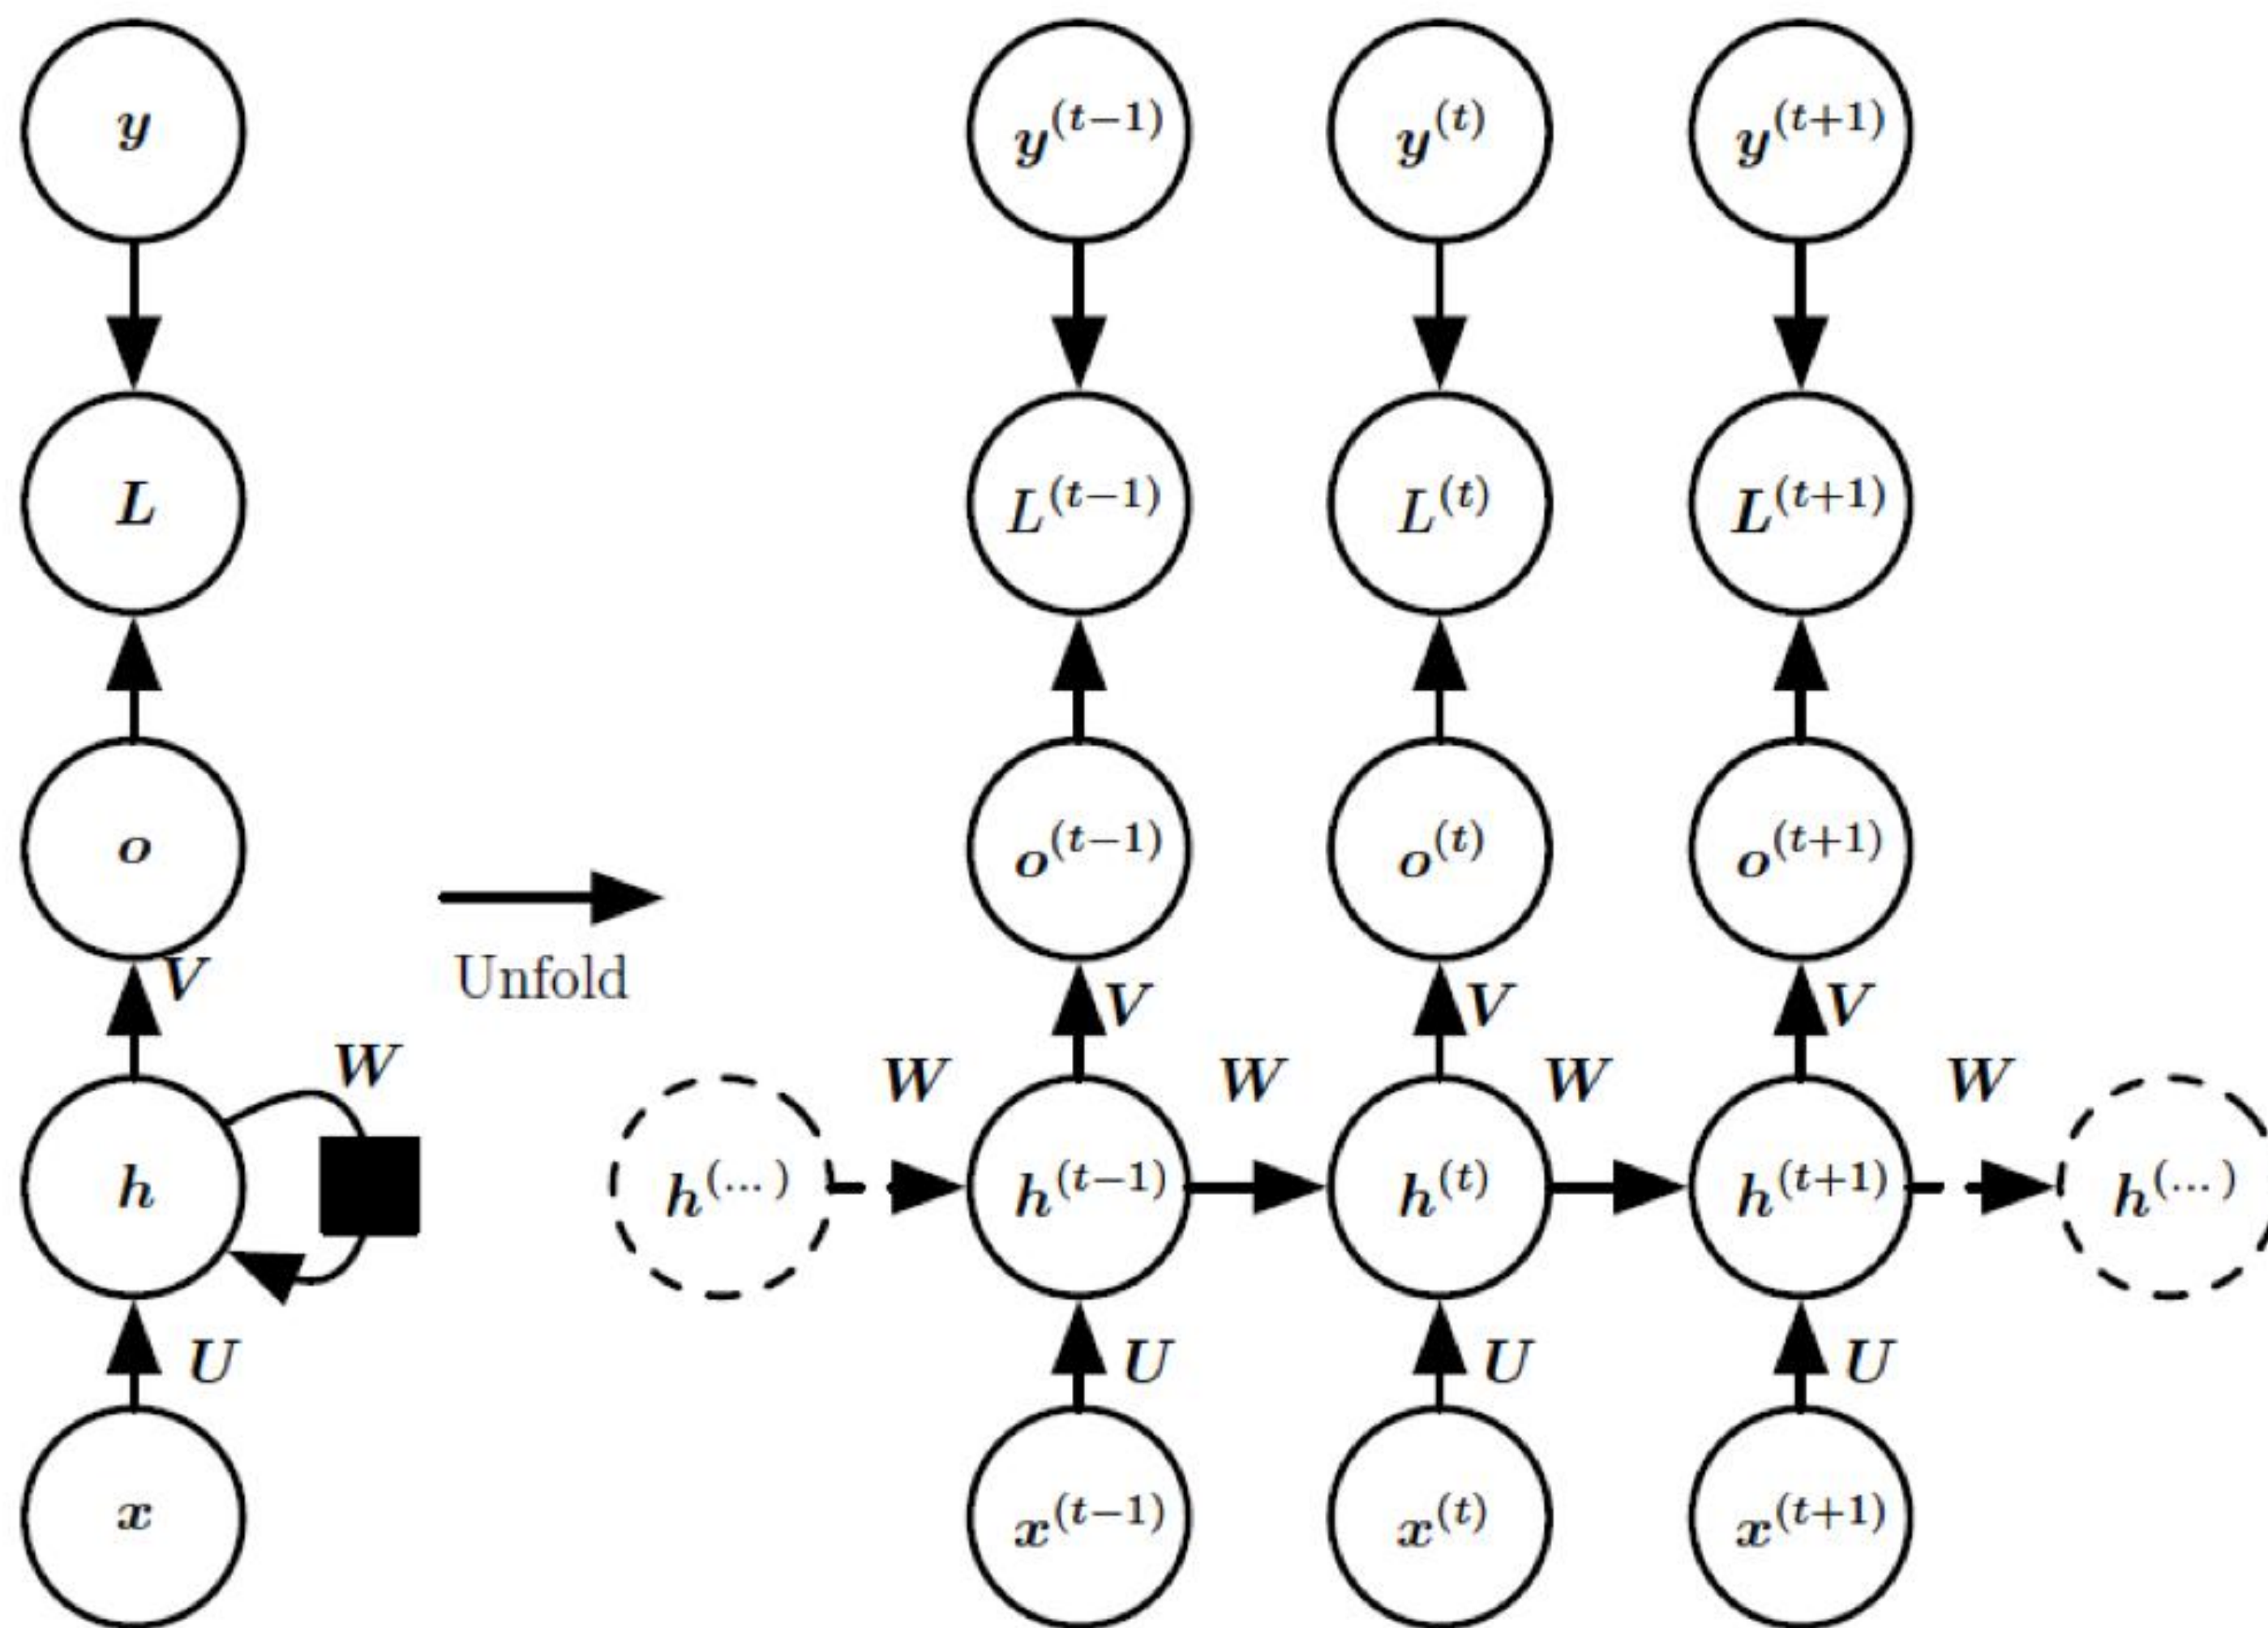
Simple RNN

学习路线




RNN

- 循环网络结构
 - y 是训练目标
 - L 是损失函数
 - o 是网络输出
 - h 是状态（隐藏单元）
 - x 是网络输入
- 计算图的时间步上展开
- 举例：天气预测



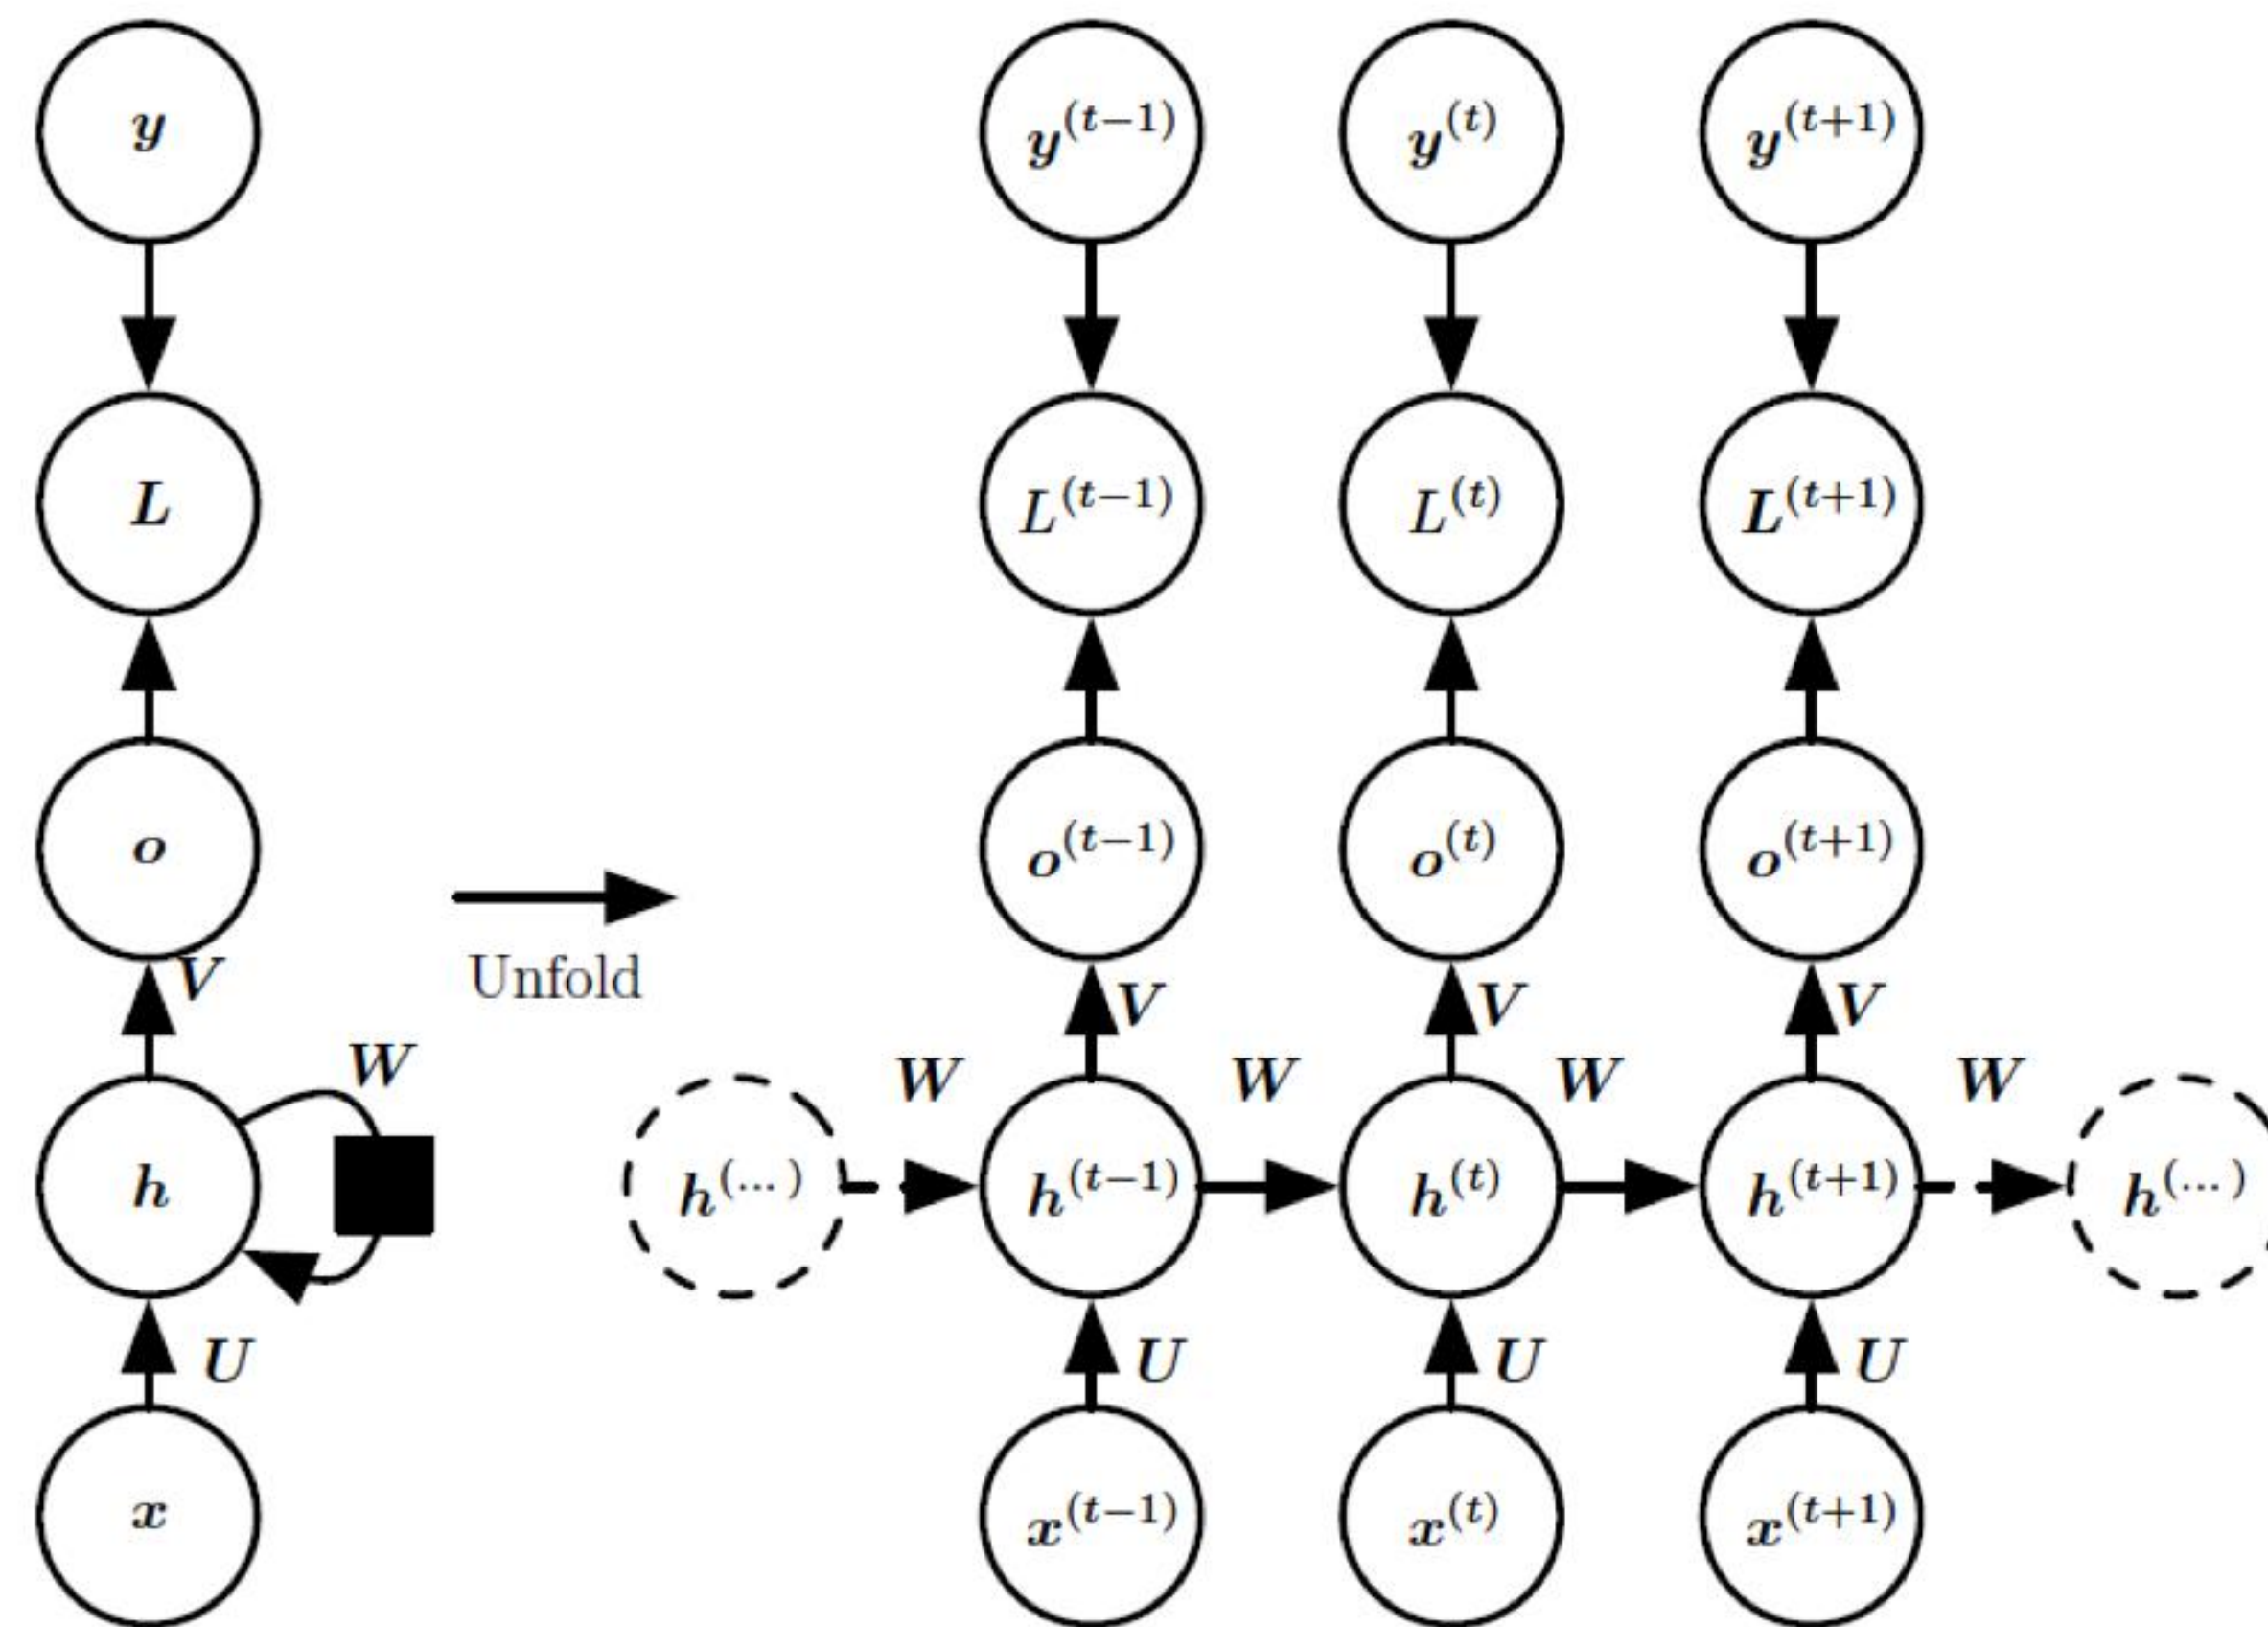
权重共享

- 循环神经网络在不同的时间步上采用相同的U、V、W参数
- 输入到隐藏的连接由权重矩阵U 参数化
- 隐藏到输出的连接由权重矩阵V 参数化
- 隐藏到隐藏的循环连接由权重矩阵W 参数化



计算图

$$\begin{aligned}a^{(t)} &= b + Wh^{(t-1)} + Ux^{(t)}, \\h^{(t)} &= \tanh(a^{(t)}), \\o^{(t)} &= c + Vh^{(t)}, \\\hat{y}^{(t)} &= \text{softmax}(o^{(t)}),\end{aligned}$$



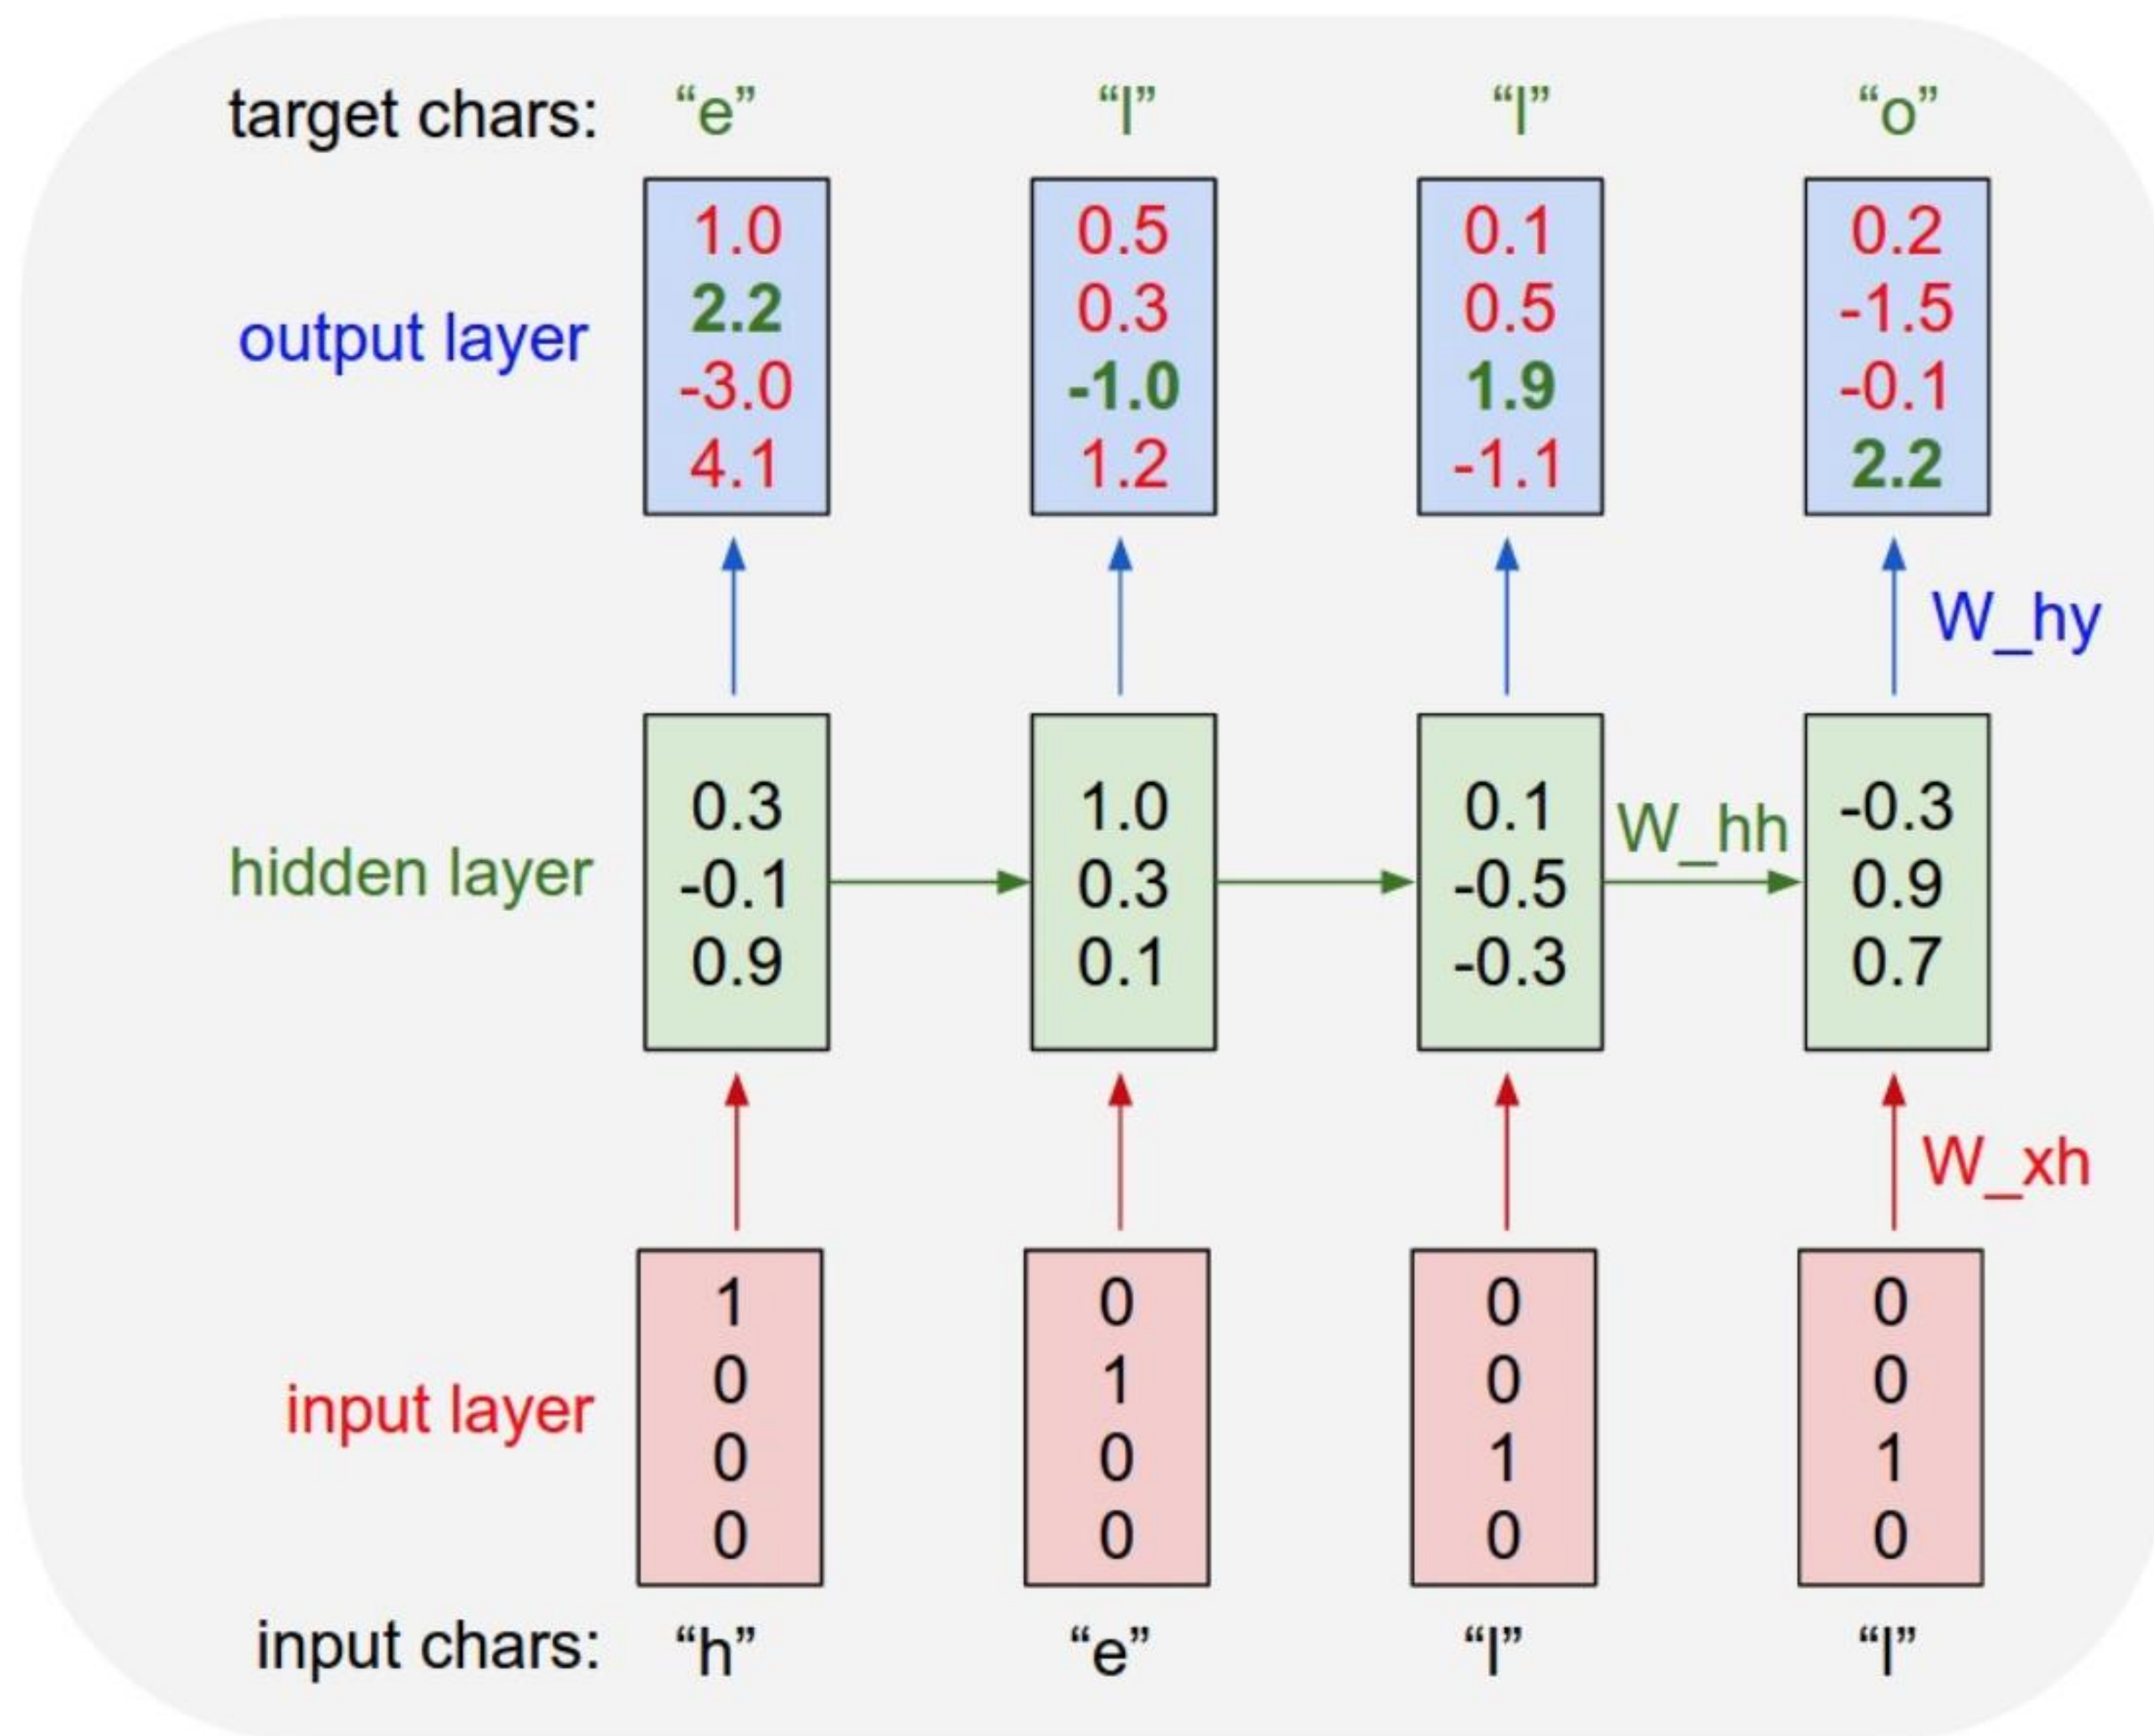
- 循环网络将一个输入序列映射到相同长度的输出序列。
- 信息流动路径：信息在时间上向前（计算输出和损失）和向后（计算梯度）的思想。
- U 、 V 和 W 分别对应于输入到隐藏、隐藏到输出和隐藏到隐藏的连接权重矩阵。
- b 和 c 是偏置向量。

basic-rnn 实现

```
iter: 646500, p: 1300, loss: 0.019042
----
y = tf.get_variable("by", [vocab_size], initializer=initializer)
    by = tf.get_variable("by", [vocab_size], dtype=tf.float32, name="state:
hprev_val = np.zeros([1, hidden_size])

while True:
```

- Andrej Karpathy的min-char-rnn tf版本实现
- 实现了一个自动写代码的程序，输入程序就是本身



输入和loss处理

- 给定序列长度(模型超参数), 把输入序列化
- one-hot 离散化处理
- U, V, W 共享权重
- 收集所有时刻的输出, 计算的loss
- 梯度截取预防梯度爆炸

$$\begin{aligned} L(\{\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(\tau)}\}, \{\mathbf{y}^{(1)}, \dots, \mathbf{y}^{(\tau)}\}) \\ &= \sum_t L^{(t)} \\ &= - \sum_t \log p_{\text{model}}(y^{(t)} \mid \{\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(t)}\}) \end{aligned}$$

rnn-cell抽象

```
__init__(  
    num_units,  
    activation=None,  
    reuse=None,  
    name=None  
)
```

Cell超参数: num_units

```
__call__(  
    inputs,  
    state,  
    scope=None,  
    *args,  
    **kwargs  
)
```

调用时刻要输入state

```
tf.nn.static_rnn(  
    cell,  
    inputs,  
    initial_state=None,  
    dtype=None,  
    sequence_length=None,  
    scope=None  
)
```

static-rnn抽象

```
state = cell.zero_state(...)  
outputs = []  
for input_ in inputs:  
    output, state = cell(input_, state)  
    outputs.append(output)  
return (outputs, state)
```

rnn-example

rnn-cell抽象

- `hidden-units` : 模型的容量大小
- $I(\text{input}) + S(\text{state}) \rightarrow O(\text{output}) + S(\text{new_state})$
- `inputs`: 输入
- `state`: 隐含了之前所有的输出信息
- 当前的输出完全取决于`state`和当前的输入

keras.layers.RNN(cell)

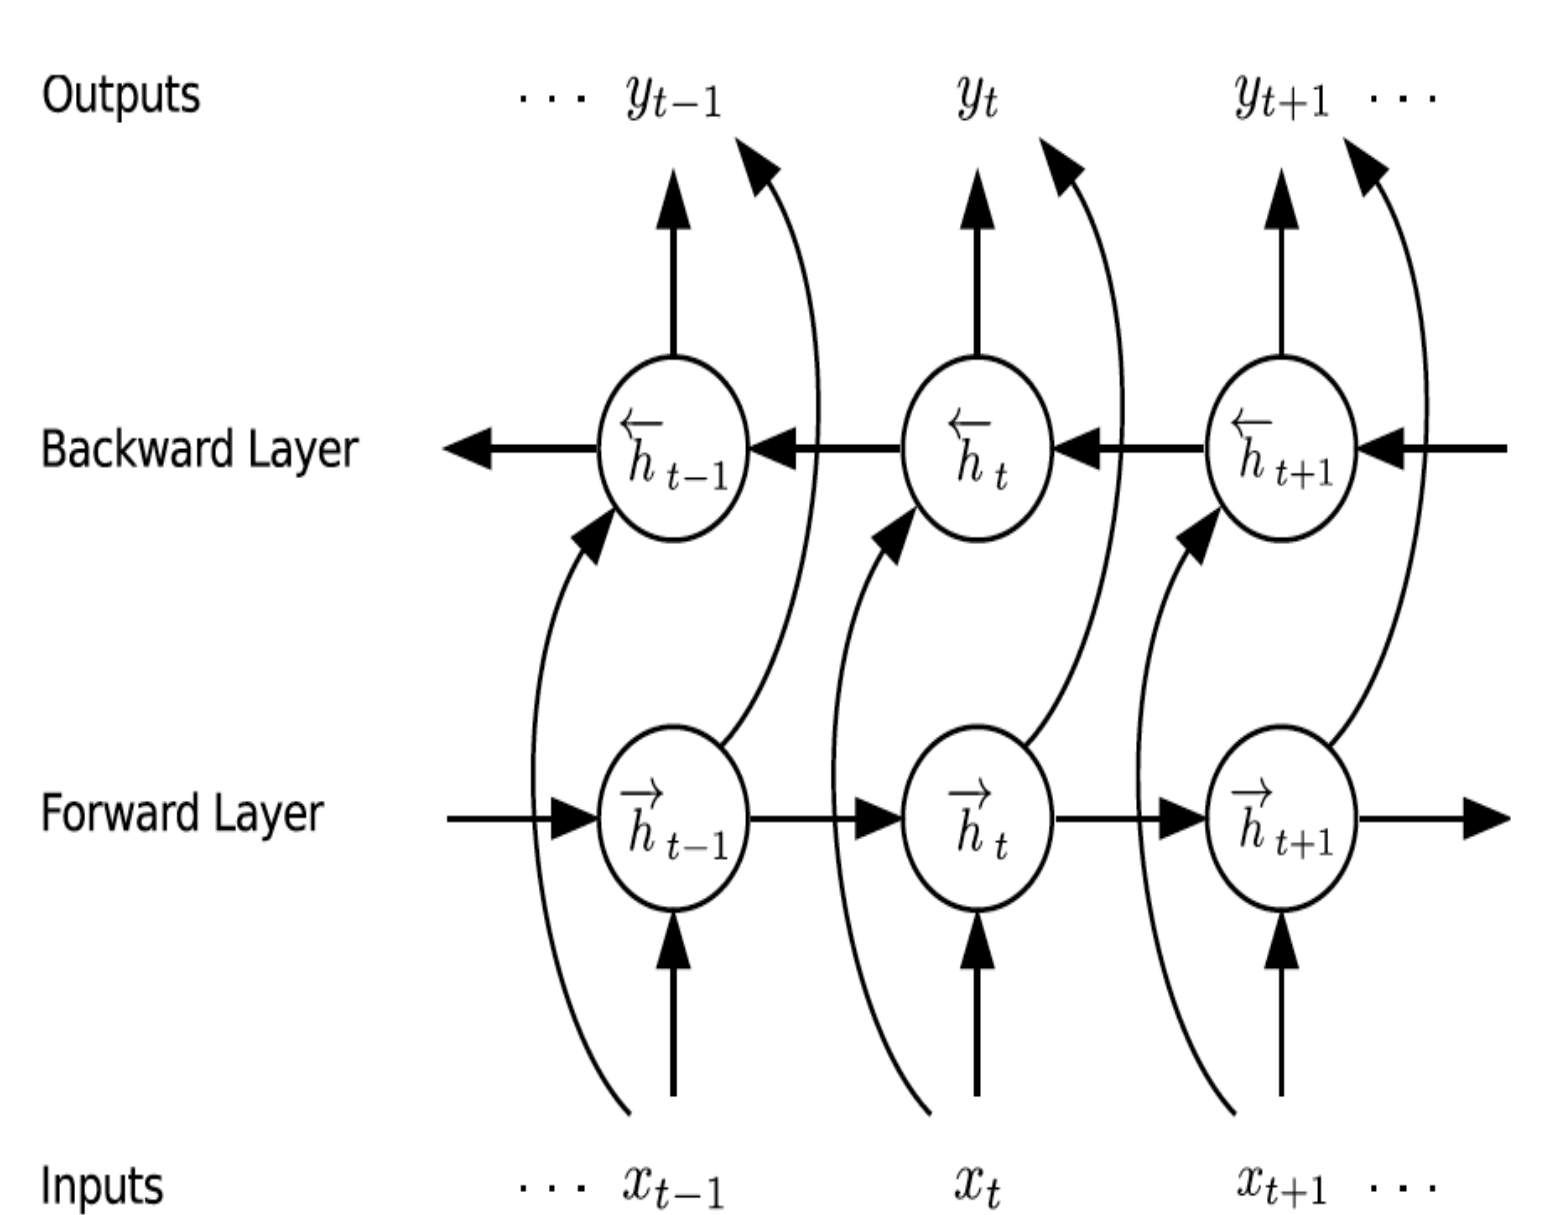
- Class SimpleRNN
- Fully-connected RNN where the output is to be fed back to input.

https://tensorflow.google.cn/api_docs/python/tf/keras/layers/SimpleRNN

https://tensorflow.google.cn/api_docs/python/tf/keras/layers/RNN?hl=en

```
__init__(  
    units,  
    activation='tanh',  
    use_bias=True,  
    kernel_initializer='glorot_uniform',  
    recurrent_initializer='orthogonal',  
    bias_initializer='zeros',  
    kernel_regularizer=None,  
    recurrent_regularizer=None,  
    bias_regularizer=None,  
    activity_regularizer=None,  
    kernel_constraint=None,  
    recurrent_constraint=None,  
    bias_constraint=None,  
    dropout=0.0,  
    recurrent_dropout=0.0,  
    return_sequences=False,  
    return_state=False,  
    go_backwards=False,  
    stateful=False,  
    unroll=False,  
    **kwargs  
)
```

课后作业



$$\vec{h}_t = \mathcal{H} \left(W_{x\vec{h}} x_t + W_{\vec{h}\vec{h}} \vec{h}_{t-1} + b_{\vec{h}} \right)$$

$$\overleftarrow{h}_t = \mathcal{H} \left(W_{x\overleftarrow{h}} x_t + W_{\overleftarrow{h}\overleftarrow{h}} \overleftarrow{h}_{t+1} + b_{\overleftarrow{h}} \right)$$


$$y_t = W_{\vec{h}y} \vec{h}_t + W_{\overleftarrow{h}y} \overleftarrow{h}_t + b_y$$

- [x] Alex Graves et al., Speech recognition with deep recurrent neural networks, ICASSP 2013.

RNN & LSTM

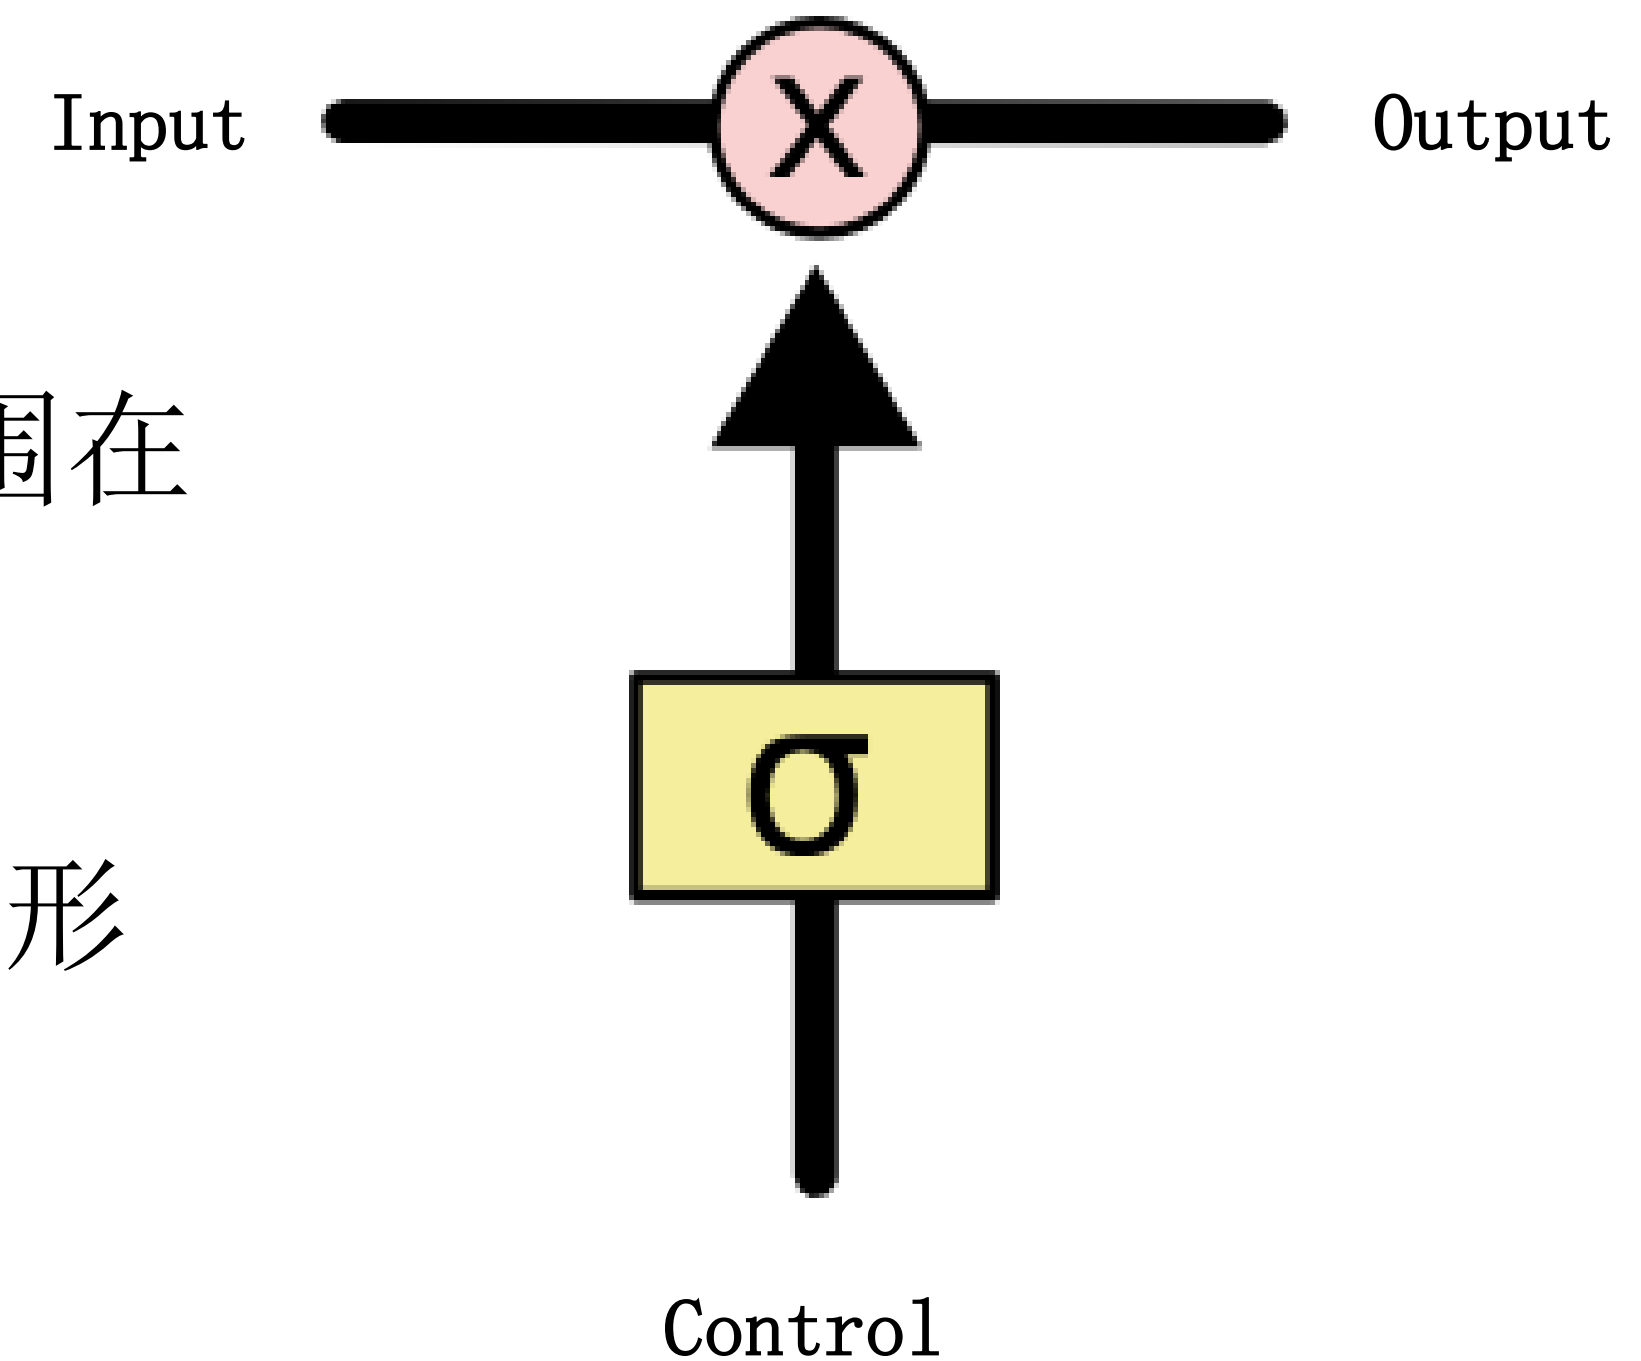
LSTM

- RNN训练有以下问题
 - RNN梯度爆炸
 - RNN梯度消失
- LSTM解决以上问题



门电路

- Input和Control形状一致
- Control经过Sigmoid函数后，变成一个范围在0-1之间的一个同形状的Tensor
- Input和 σ (Control) 元素相乘得到一个同形的Output



LSTM

- LSTM是RNN的一个改进，LSTM增加了一个主输入单元和其他三个辅助的门限输入单元：
- 输入门（Input gate）控制是否输入，遗忘门（Forget gate）控制是否存储，输出门（Output gate）控制是否输出。
- 辅助记忆单元可以寄存时间序列的输入，在训练过程中会利用后向传播的方式进行。
- 记忆单元和这些门单元的组合，大大提升了RNN处理远距离依赖问题的能力，解决RNN网络收敛慢的问题。

- RNN

$$h_t = \mathcal{H}(W_{xh}x_t + W_{hh}h_{t-1} + b_h) \quad (1)$$

$$y_t = W_{hy}h_t + b_y \quad (2)$$

- LSTM


$$i_t = \sigma(W_{xi}x_t + W_{hi}h_{t-1} + W_{ci}c_{t-1} + b_i) \quad (3)$$

$$f_t = \sigma(W_{xf}x_t + W_{hf}h_{t-1} + W_{cf}c_{t-1} + b_f) \quad (4)$$

$$c_t = f_t c_{t-1} + i_t \tanh(W_{xc}x_t + W_{hc}h_{t-1} + b_c) \quad (5)$$

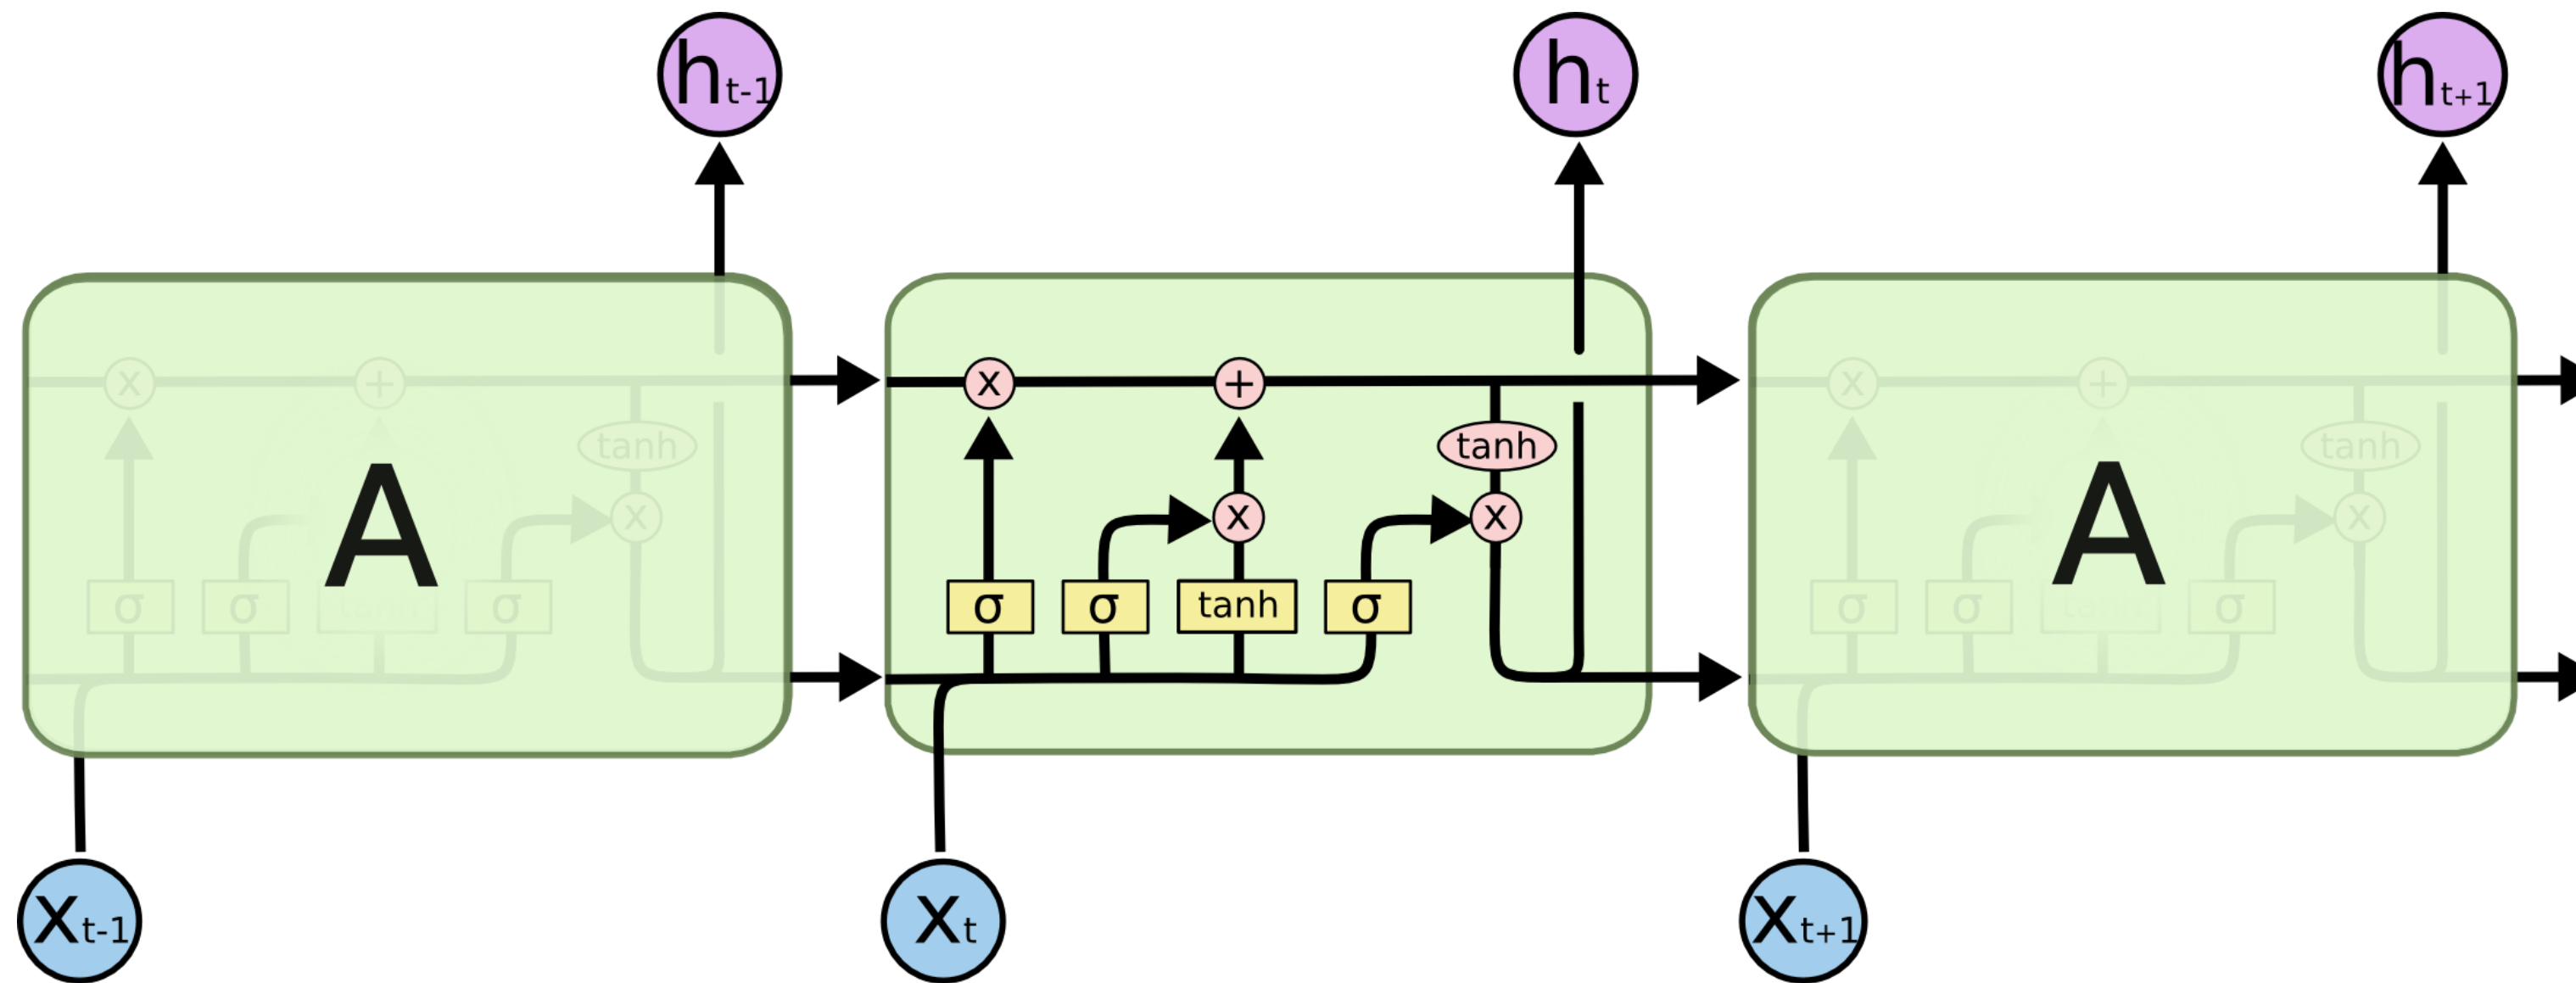
$$o_t = \sigma(W_{xo}x_t + W_{ho}h_{t-1} + W_{co}c_t + b_o) \quad (6)$$

$$h_t = o_t \tanh(c_t) \quad (7)$$



LSTMCe11


- LSTM internal



```
__init__(  
    units,  
    activation='tanh',  
    recurrent_activation='sigmoid',  
    use_bias=True,  
    kernel_initializer='glorot_uniform',  
    recurrent_initializer='orthogonal',  
    bias_initializer='zeros',  
    unit_forget_bias=True,  
    kernel_regularizer=None,  
    recurrent_regularizer=None,  
    bias_regularizer=None,  
    kernel_constraint=None,  
    recurrent_constraint=None,  
    bias_constraint=None,  
    dropout=0.0,  
    recurrent_dropout=0.0,  
    implementation=2,  
    **kwargs  
)
```

GRU

- Gated Recurrent Unit (GRU)
- 组合遗忘门 (forget gates) 和输入门 (input gates) 为单一的更新门 (Update gates)
- 合并LSTM的cell状态 (cell state) 和隐藏态 (hidden state)



$$z_t = \sigma(W_z \cdot [h_{t-1}, x_t])$$

$$r_t = \sigma(W_r \cdot [h_{t-1}, x_t])$$

$$\tilde{h}_t = \tanh(W \cdot [r_t * h_{t-1}, x_t])$$

$$h_t = (1 - z_t) * h_{t-1} + z_t * \tilde{h}_t$$

推荐阅读

- Understanding Convolutions
 - <http://colah.github.io/posts/2014-07-Understanding-Convolutions/>
- Conv Nets: A Modular Perspective
 - <http://colah.github.io/posts/2014-07-Conv-Nets-Modular/>
- The Unreasonable Effectiveness of Recurrent Neural Networks
 - <http://karpathy.github.io/2015/05/21/rnn-effectiveness/>
- Understanding-LSTMs
 - <http://colah.github.io/posts/2015-08-Understanding-LSTMs/>

谢谢！