Dense & CNN & RNN

人工神经网络

- 连接主义观点：将大量的神经元之间，按照拓扑连接结构，构成人工神经网络。
- 网络的拓扑结构
  - 不同神经元之间的连接关系。
  - 前馈网络（feedforward）、反馈网络（feedback）和记忆网络（memory network）

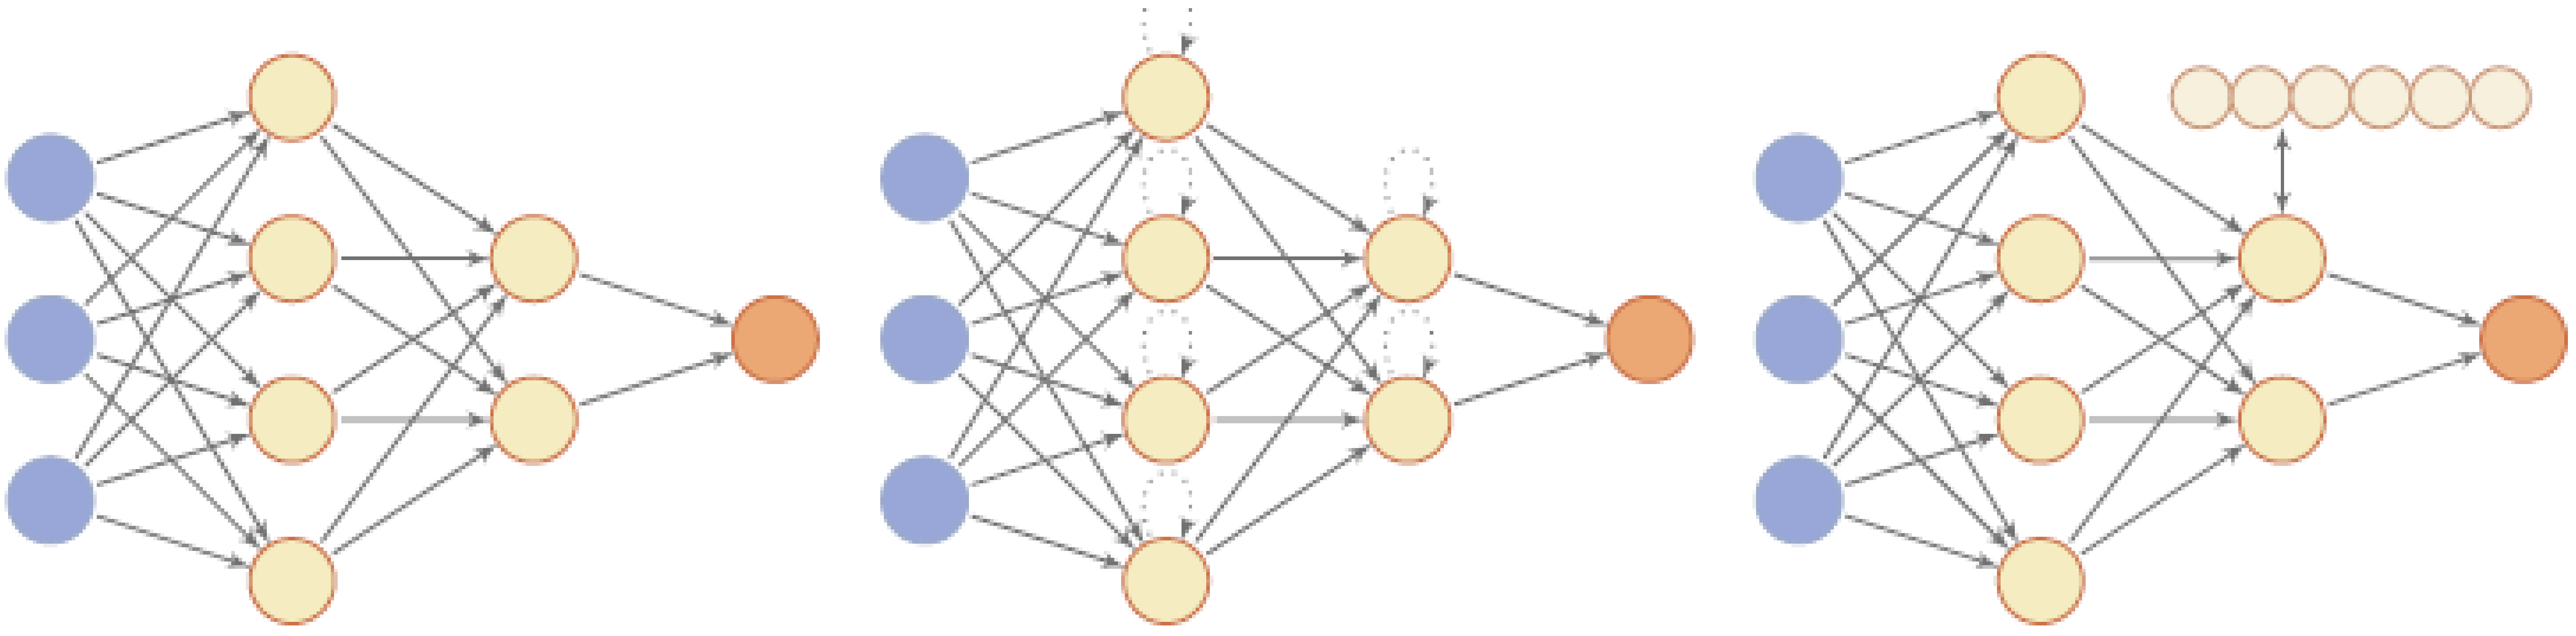

(a) 前馈网络　(b) 反馈网络　(c) 记忆网络

TensorFlow学习路线： Dense与CNN

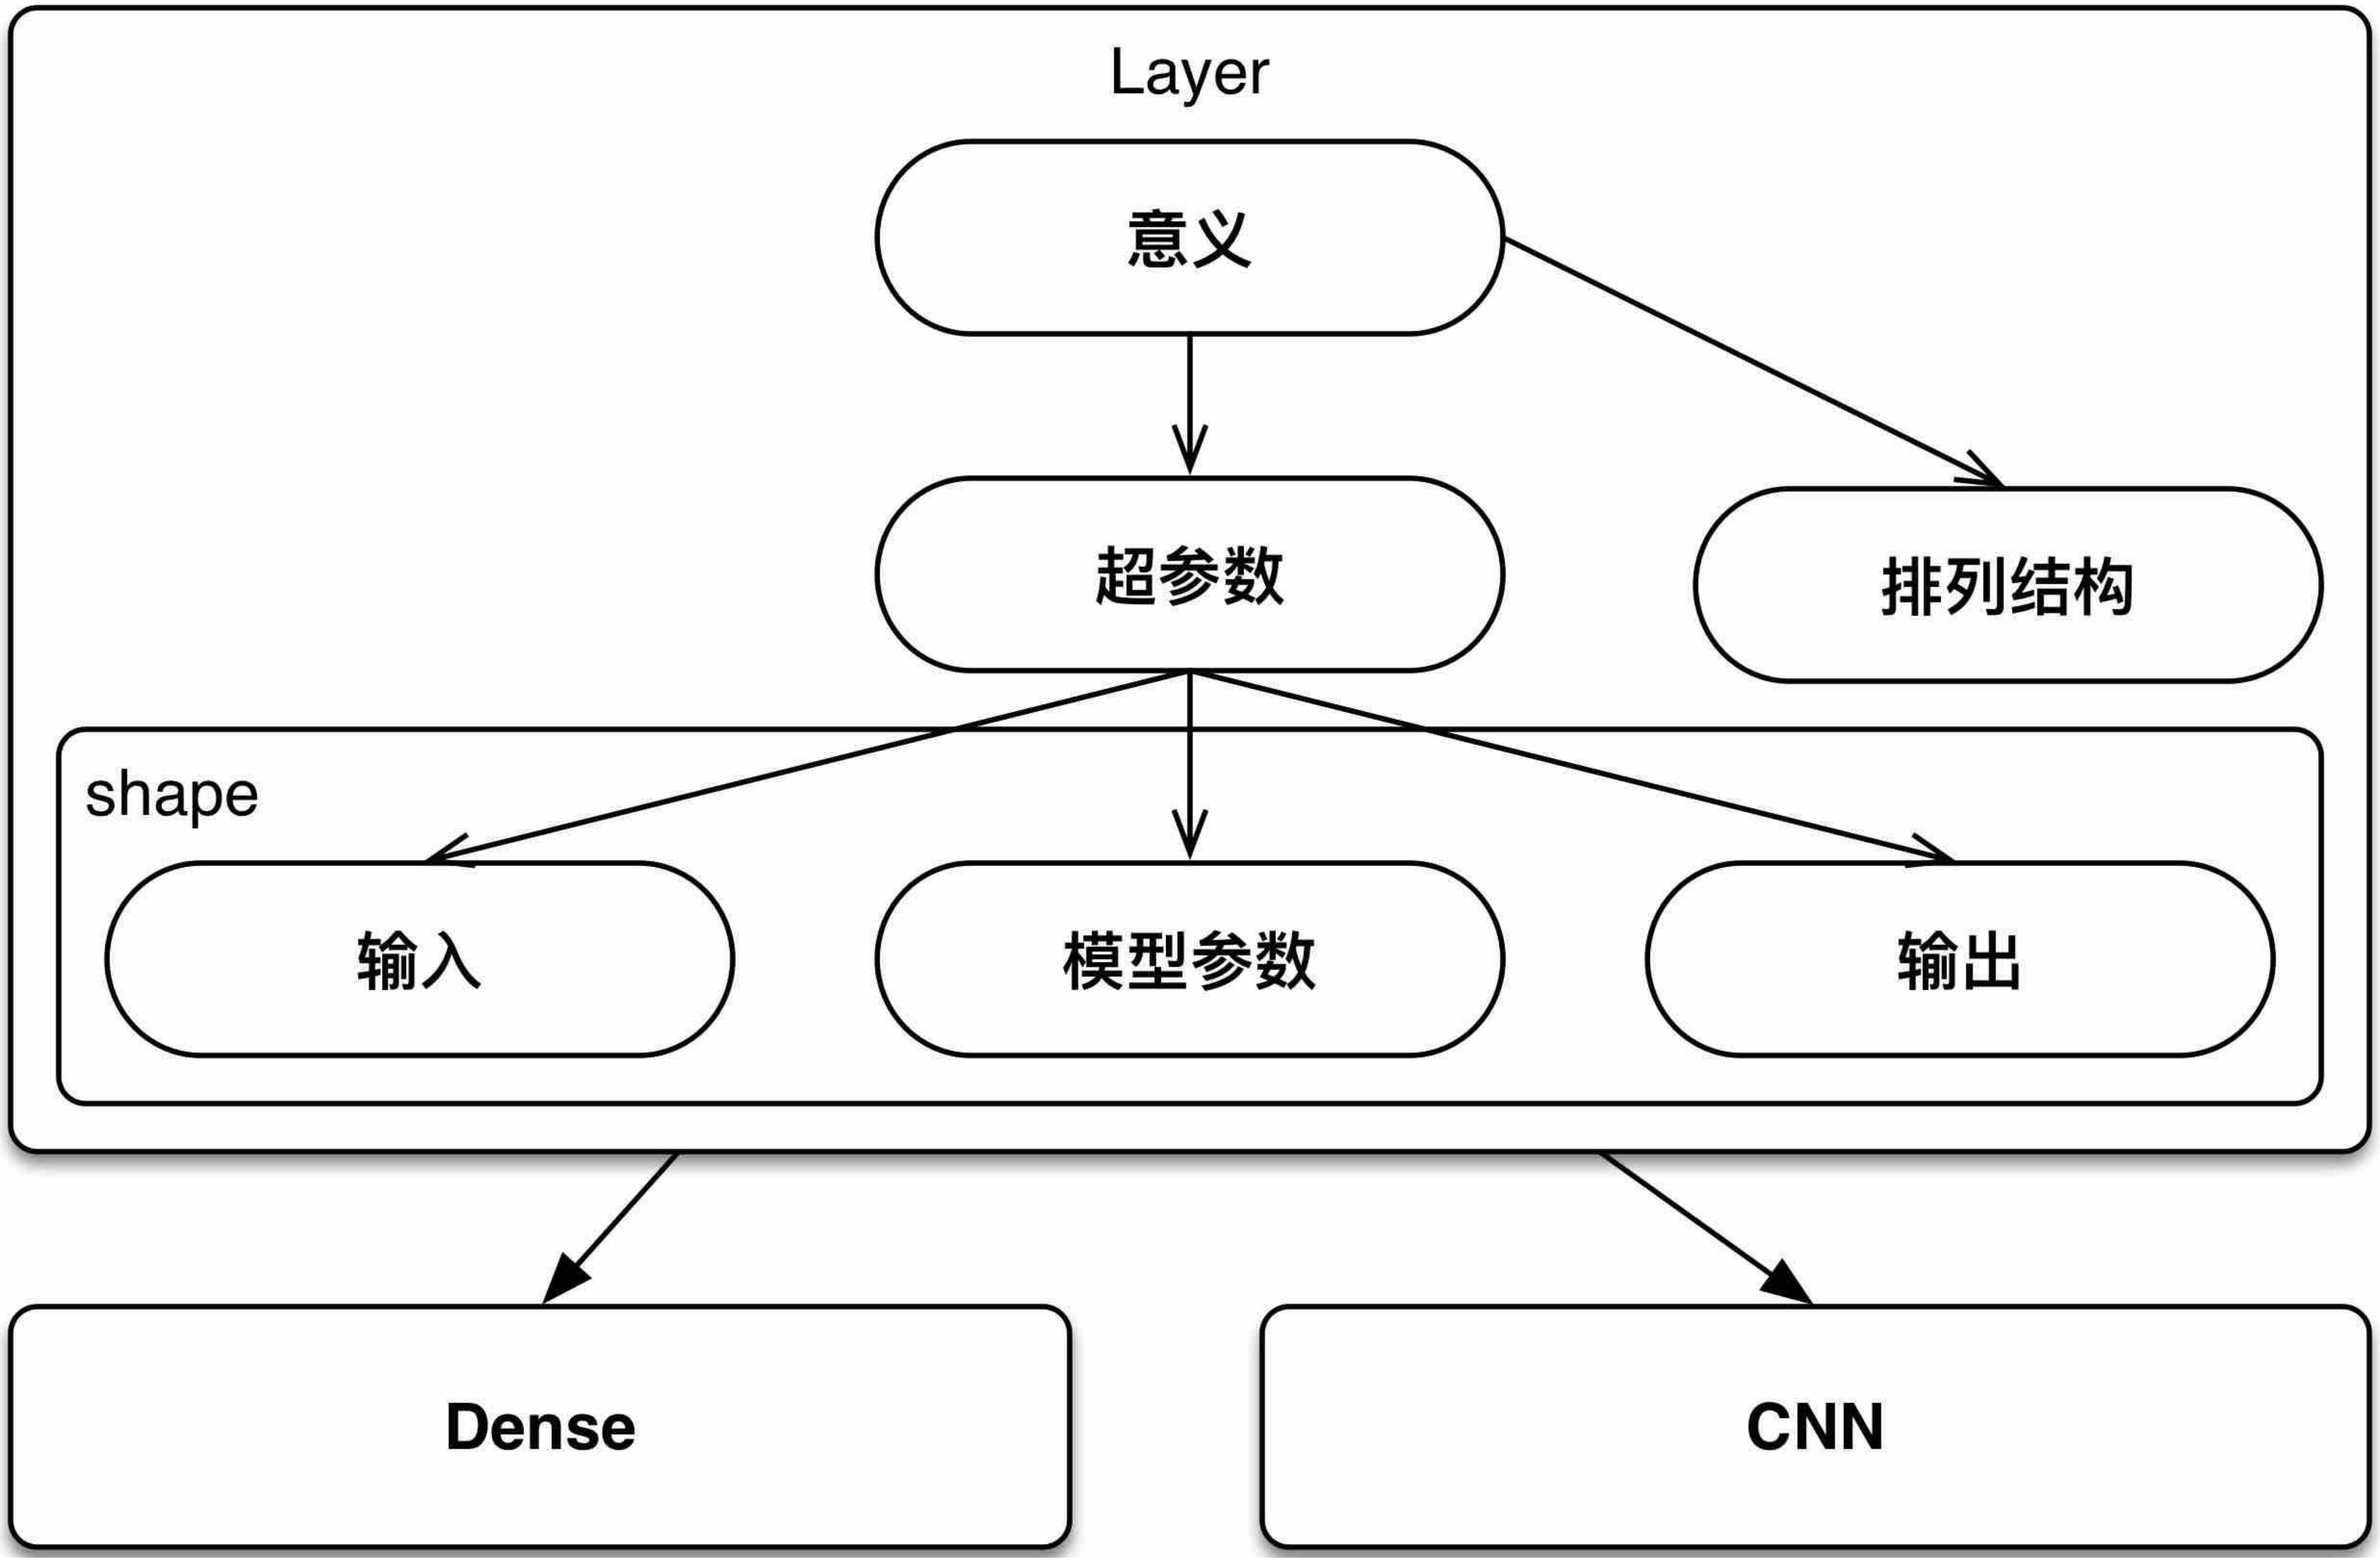

TensorFlow学习路线： RNN与LSTM

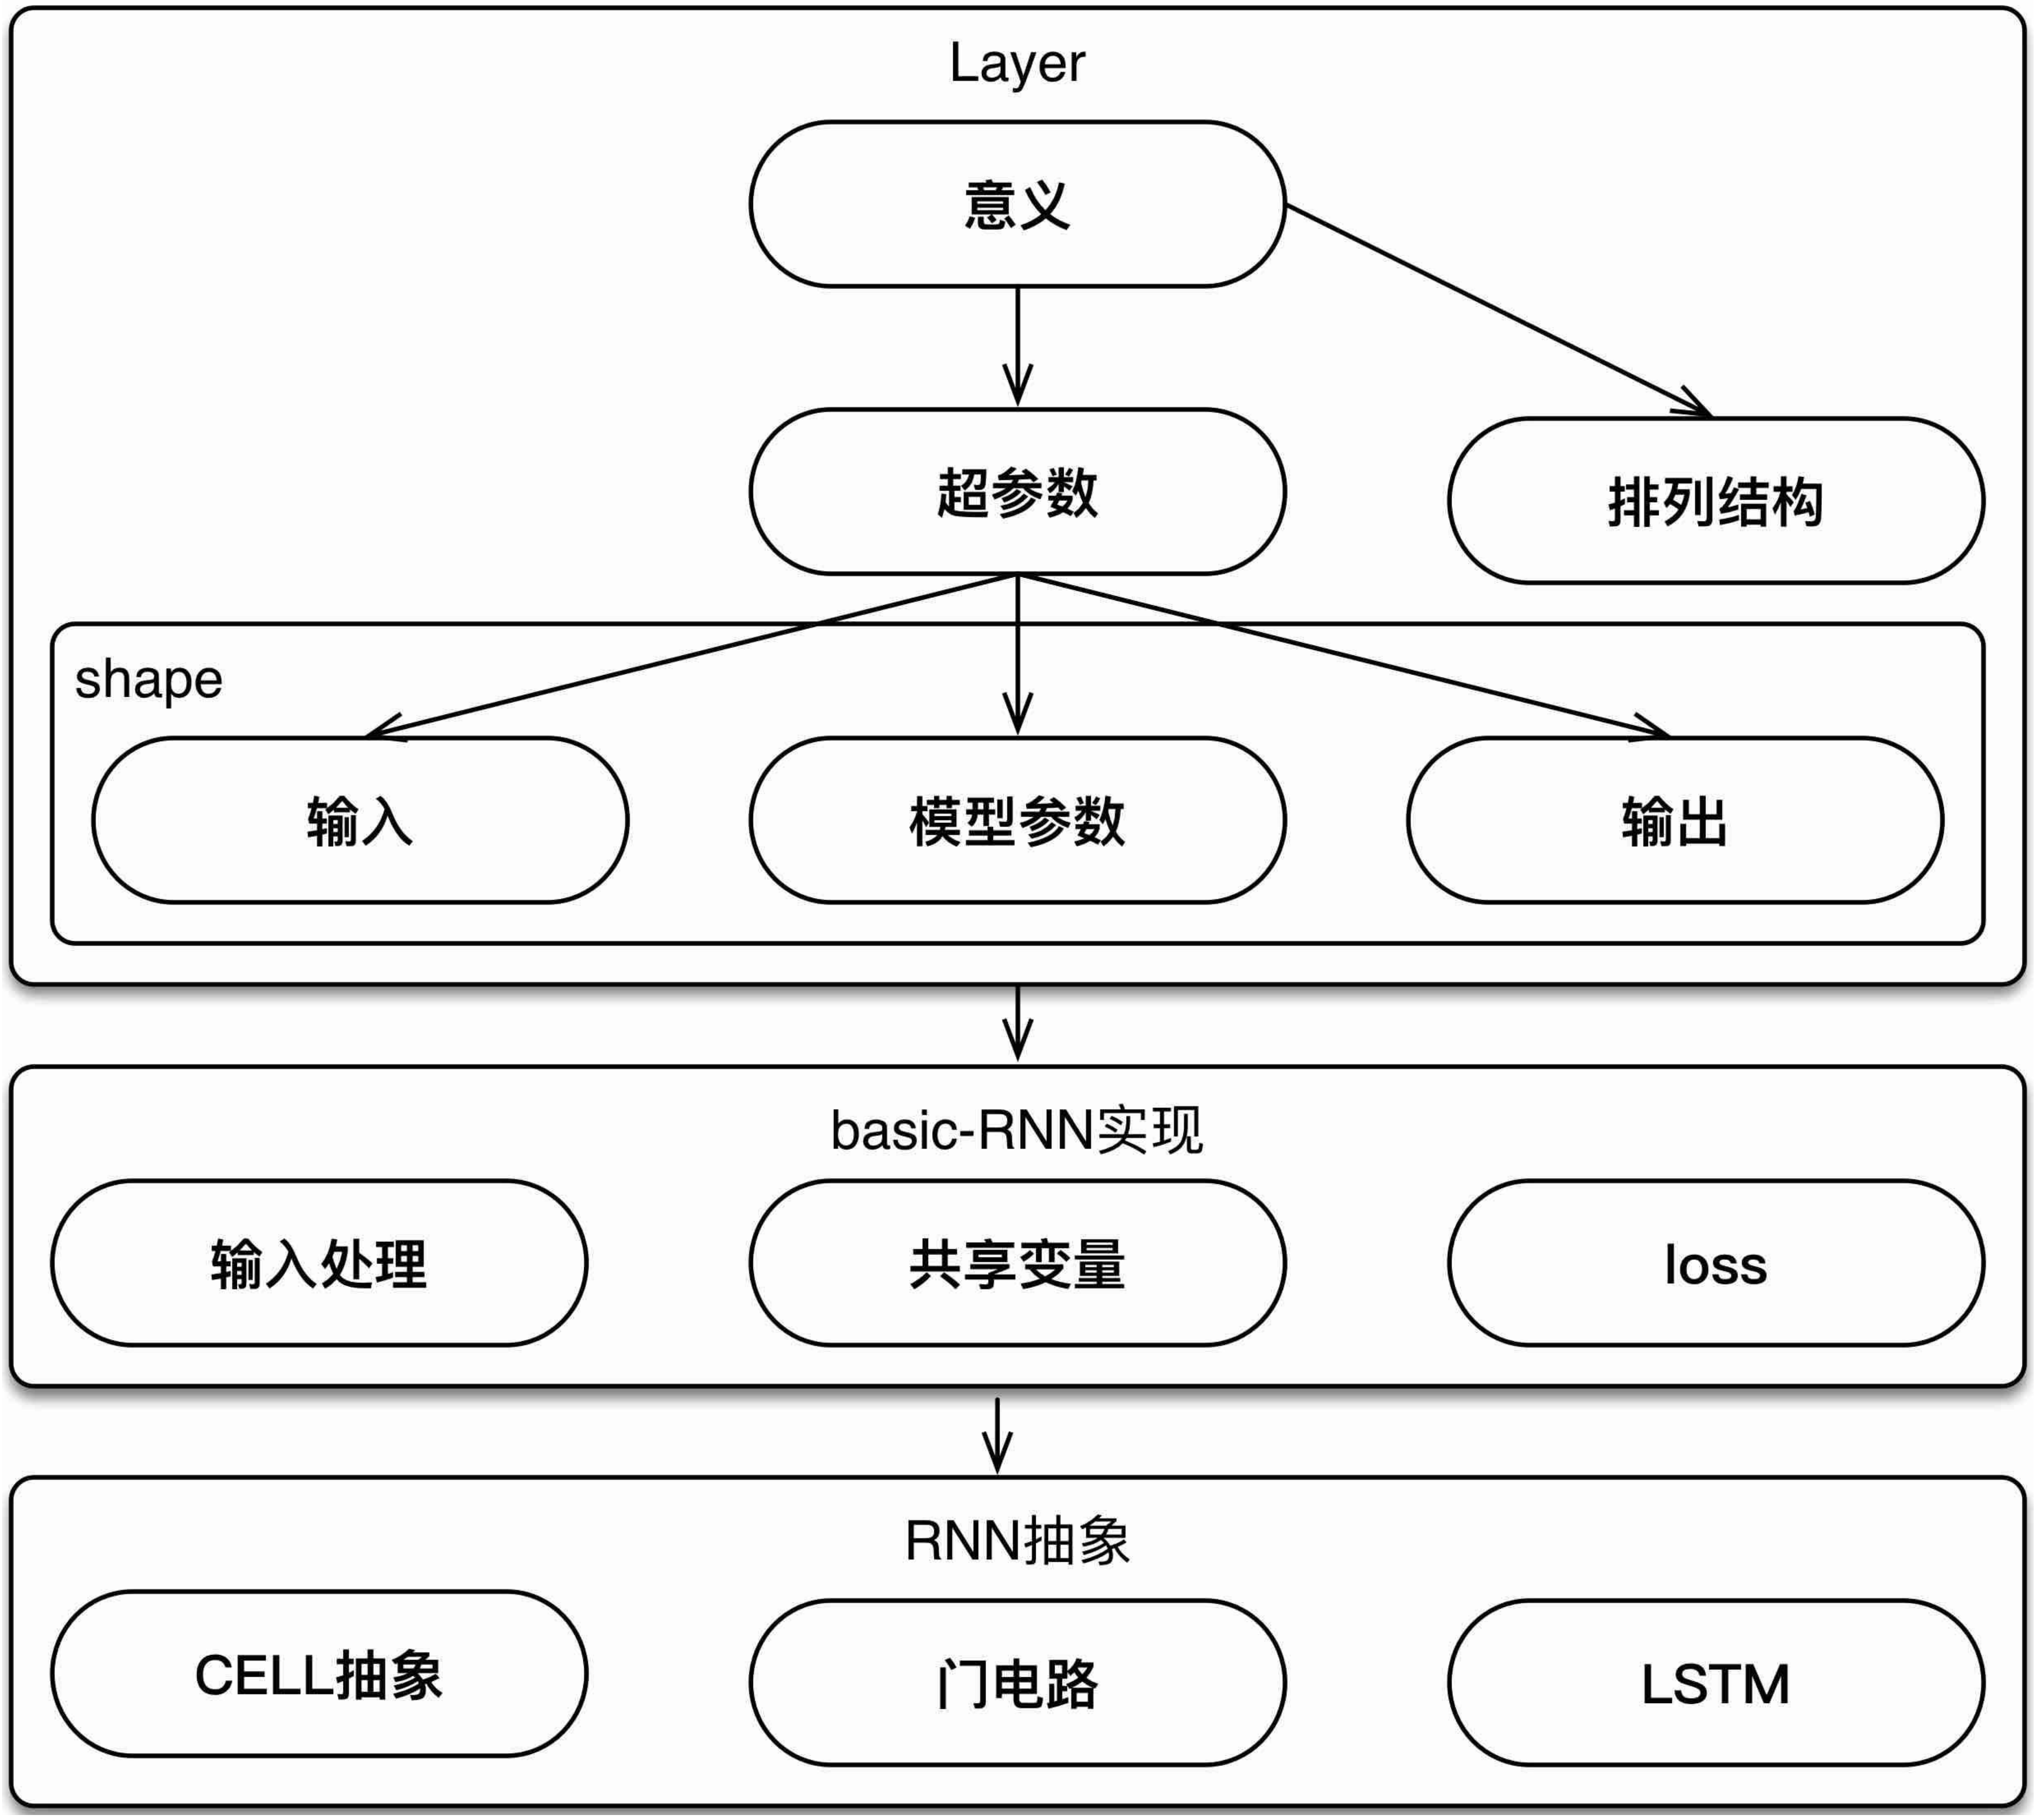

Dense

学习路线

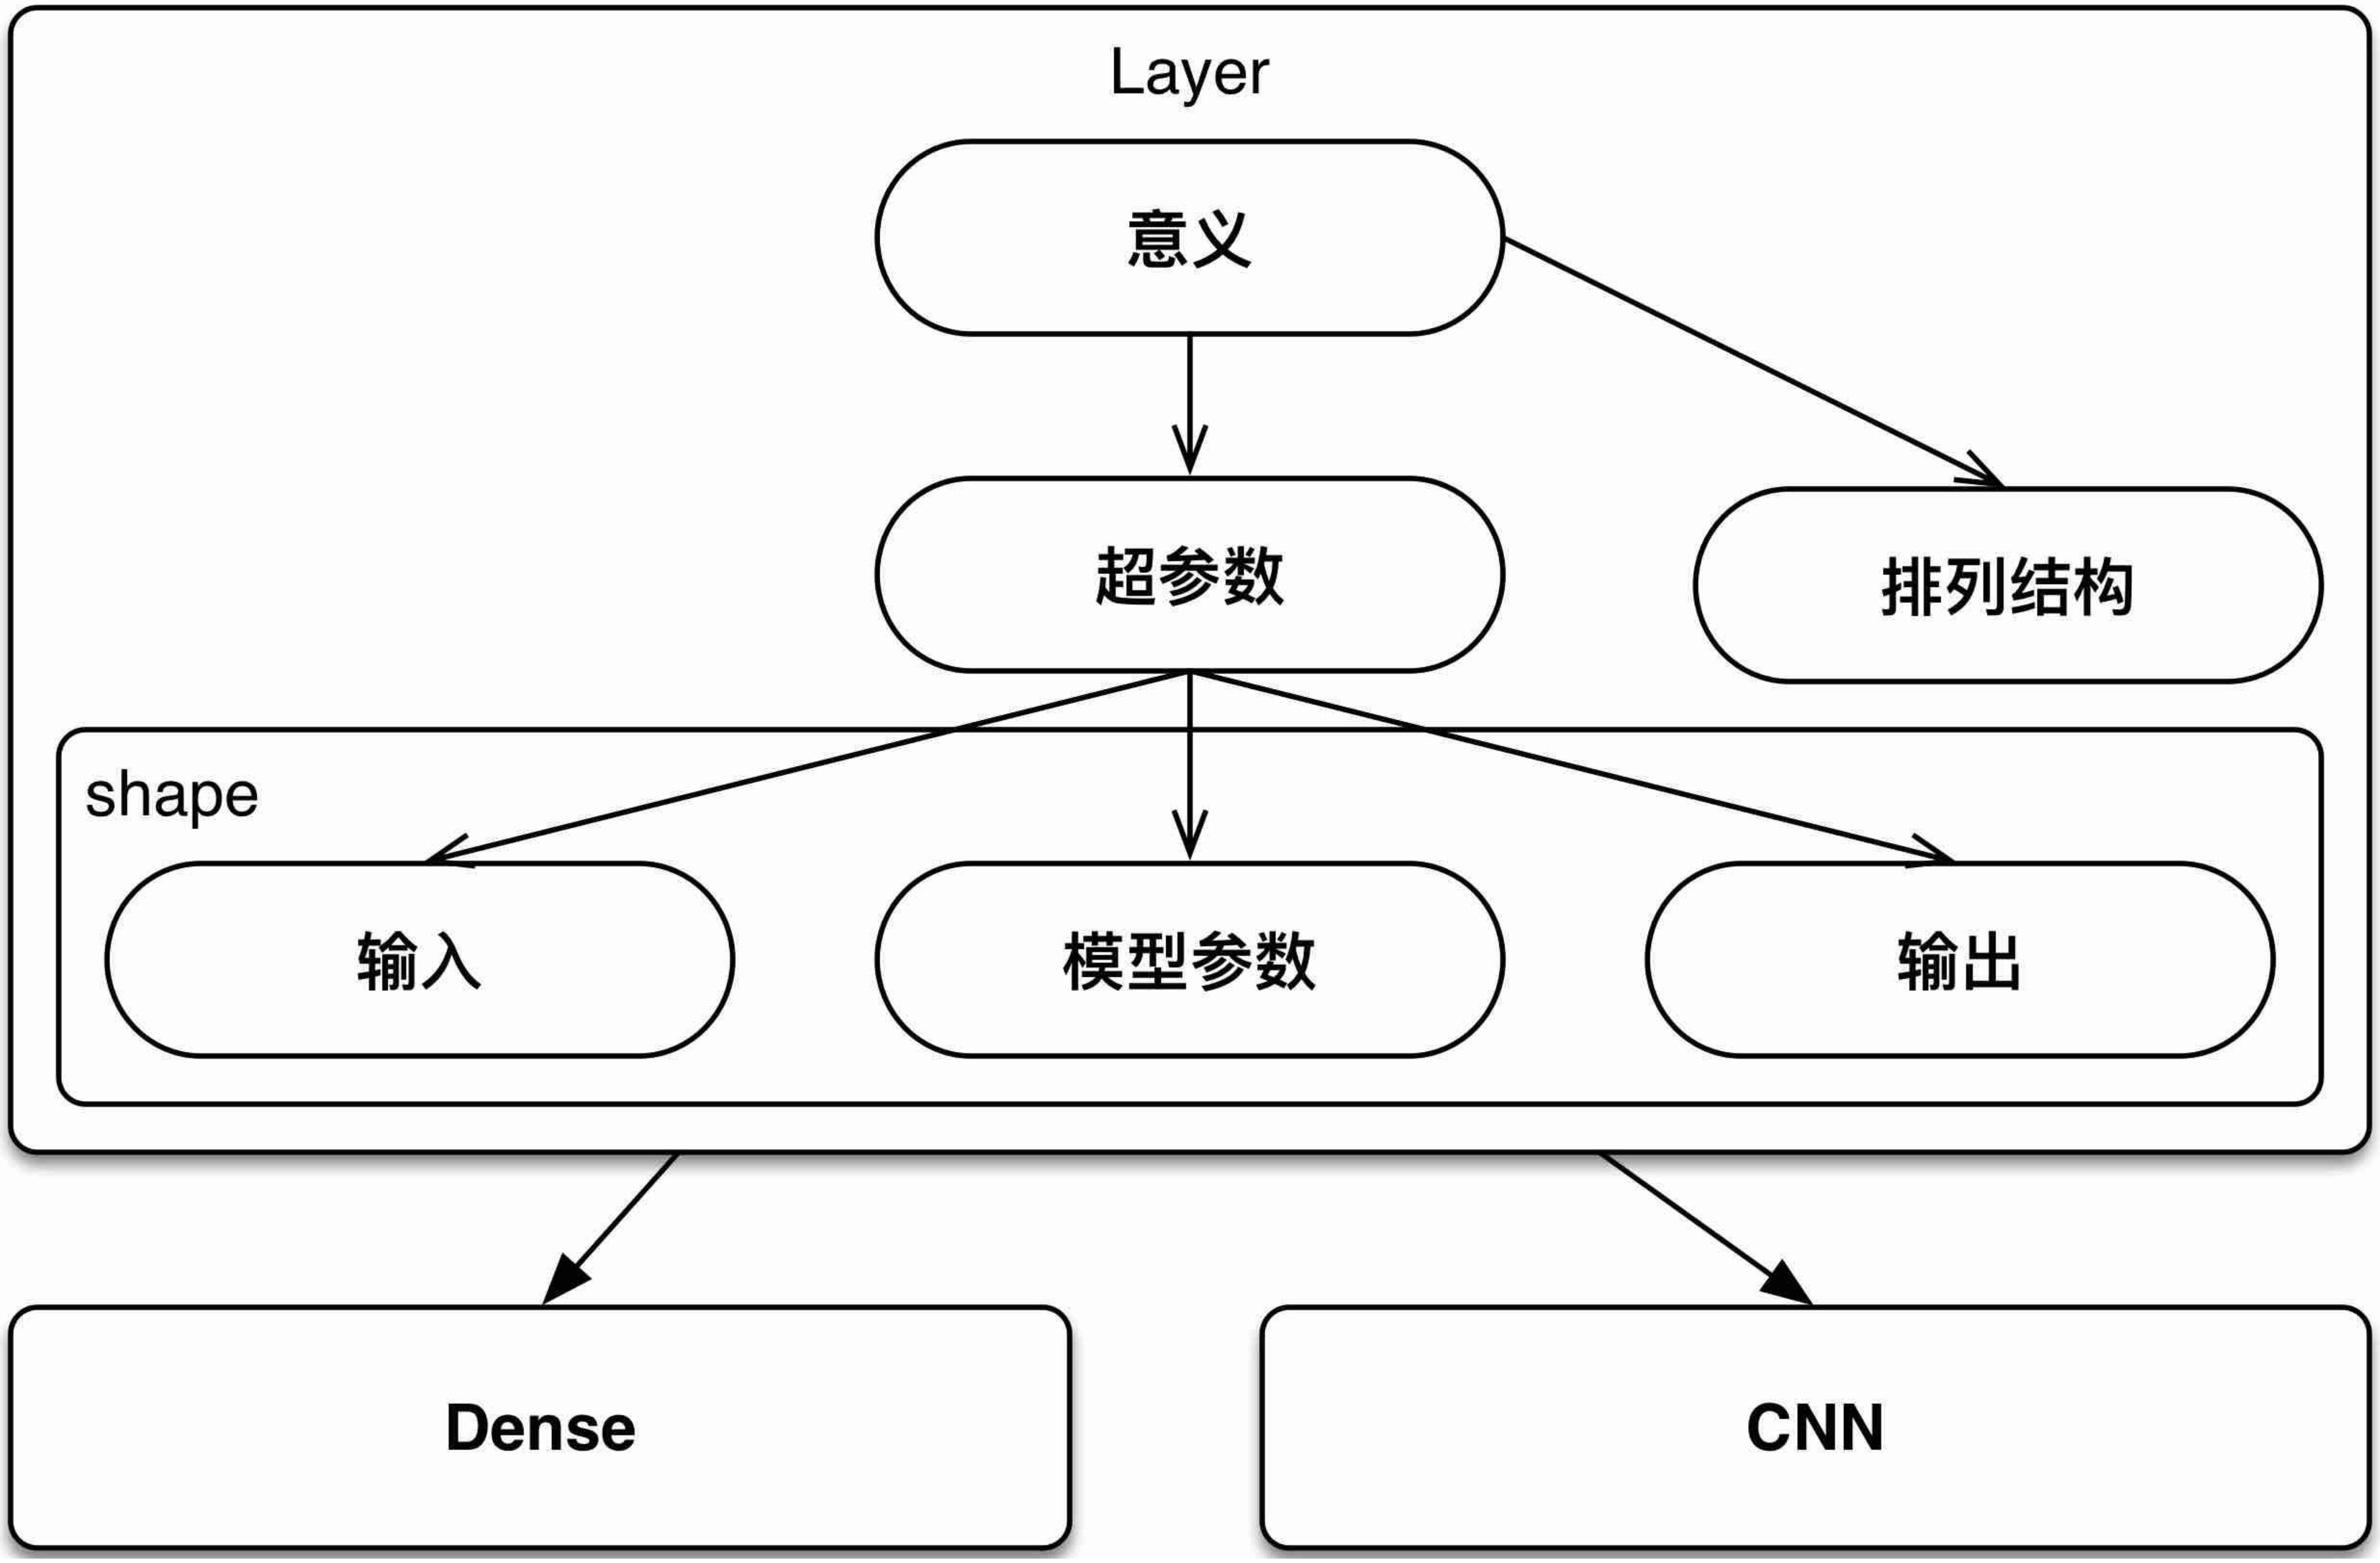

Tensor形象化表示

- 对于一个4*5*6的Tensor
  - rank ： 3d
  - length: 4， 5， 6
  - shape: [4， 5， 6]
  - volume: 4*5*6=120

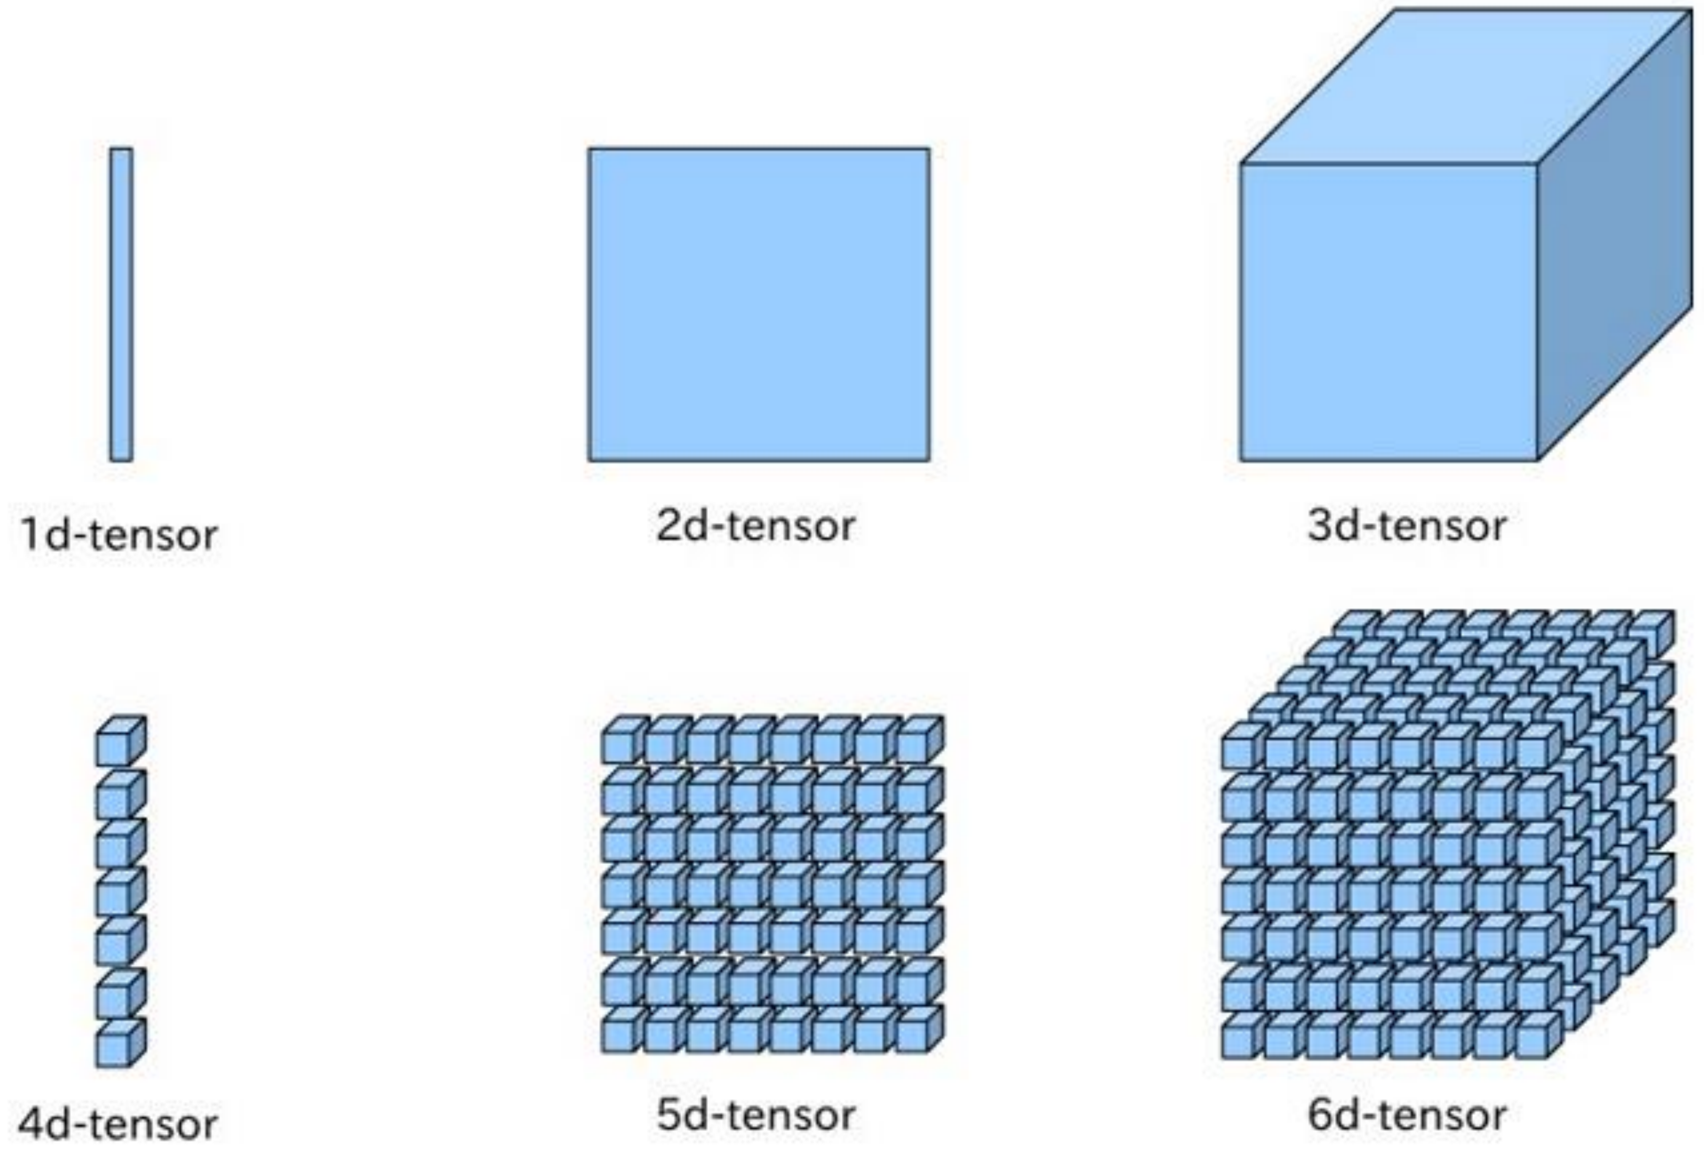

多层前馈网络（Multilayer feedforward networks）

- 前馈网络结构（feedforward）是一种计算图（Computational Graph）
- 别名：多层全连接网络（FCN）、多层感知机（MLP）、多个密集层网络（Dense）
- 神经网络有3个输入，2个输出，中间有1个隐藏层，有1个输出层，共有5个神经元。

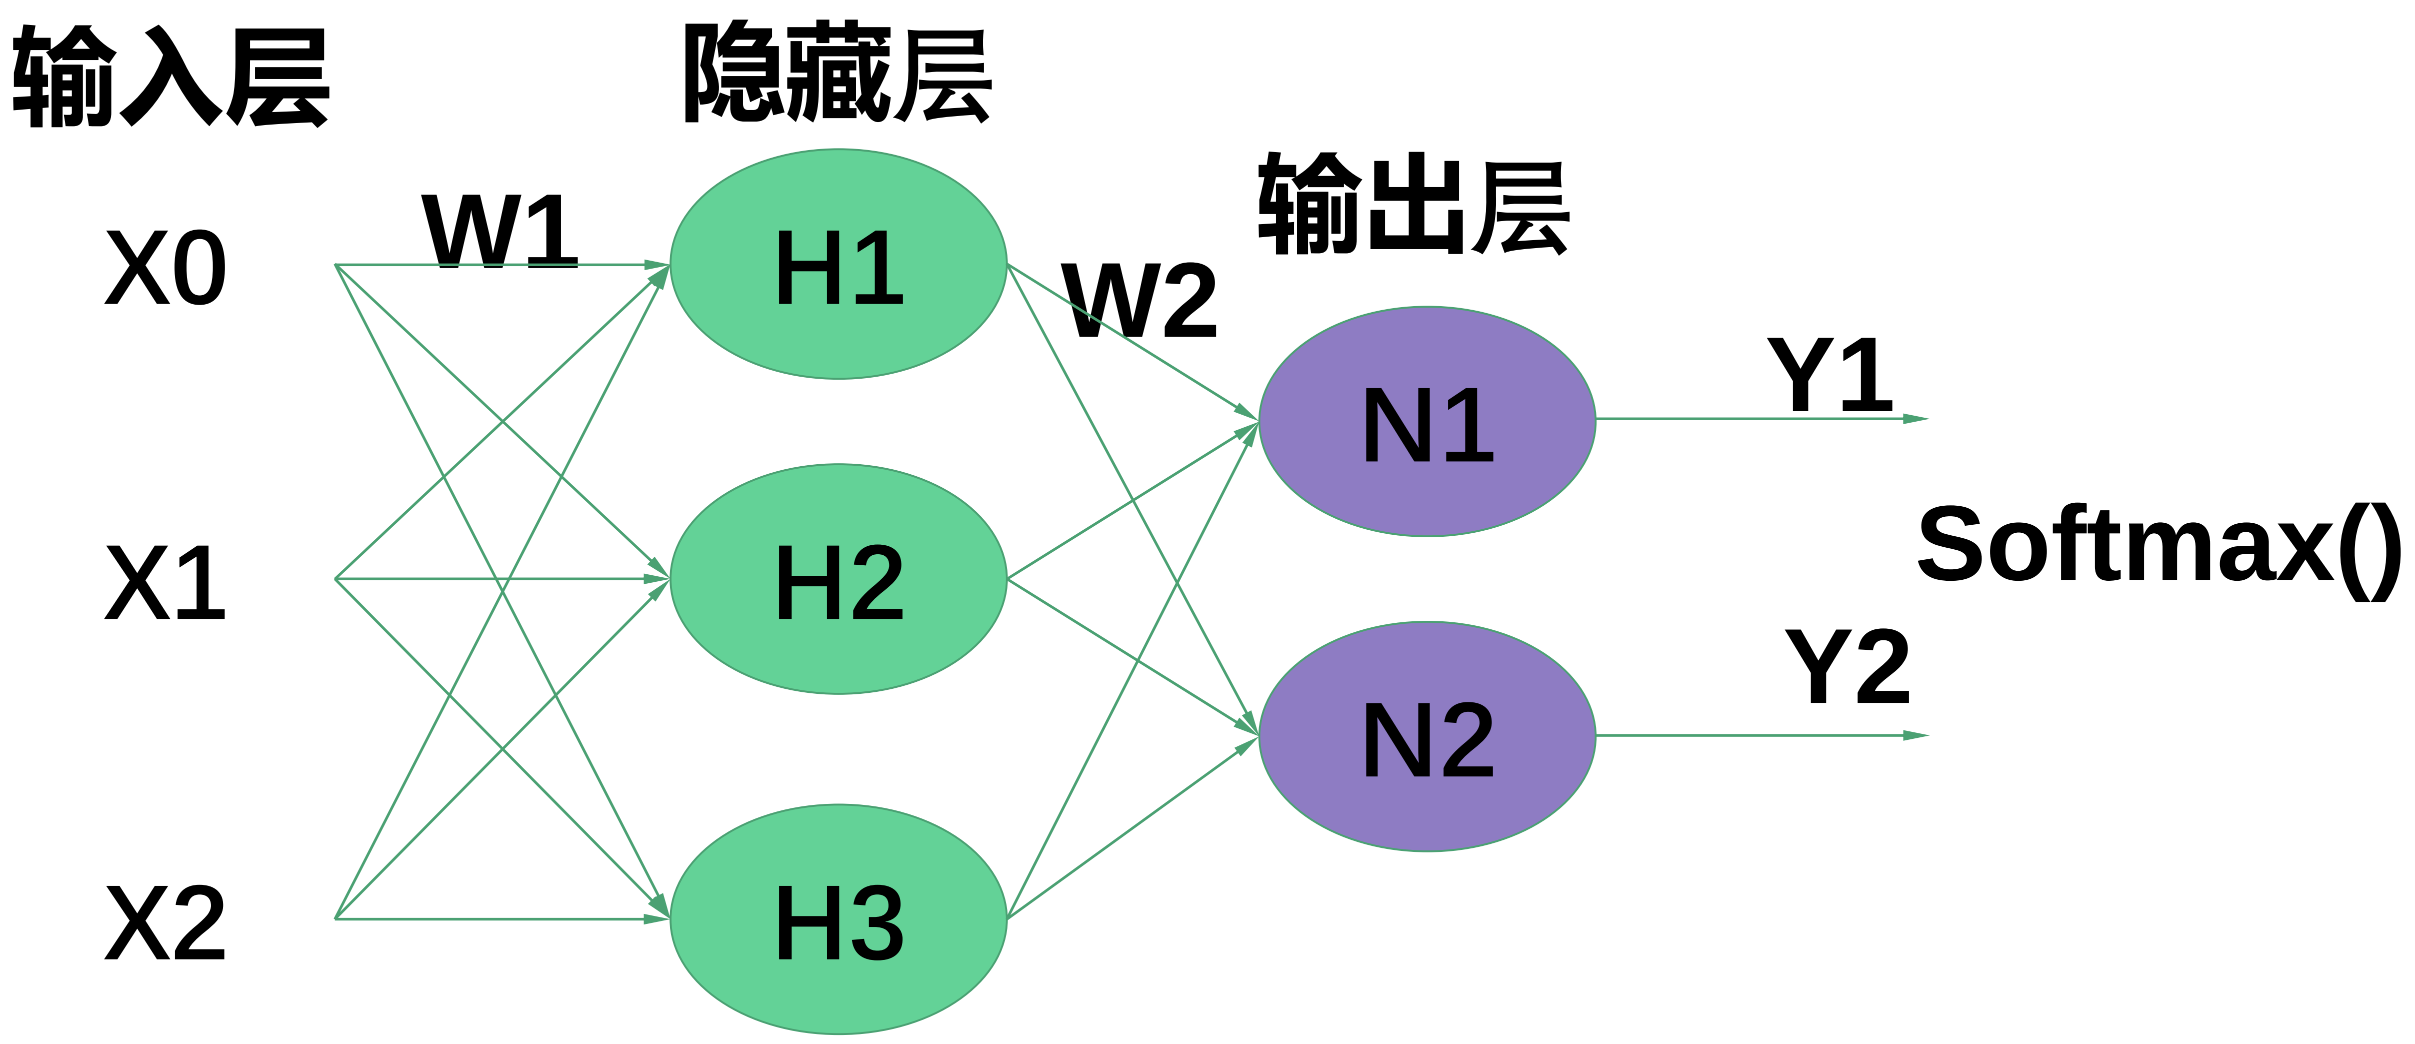

Neuron → Layer

- 单个神经元:
  - 输入是1d, 参数是1d, 输出是0d
- 一层神经元构成一个Layer
  - 显然输出的shape和Layer的shape一致.
- batch_size
  - 会影响输出的shape
  - 并不会影响参数的shape

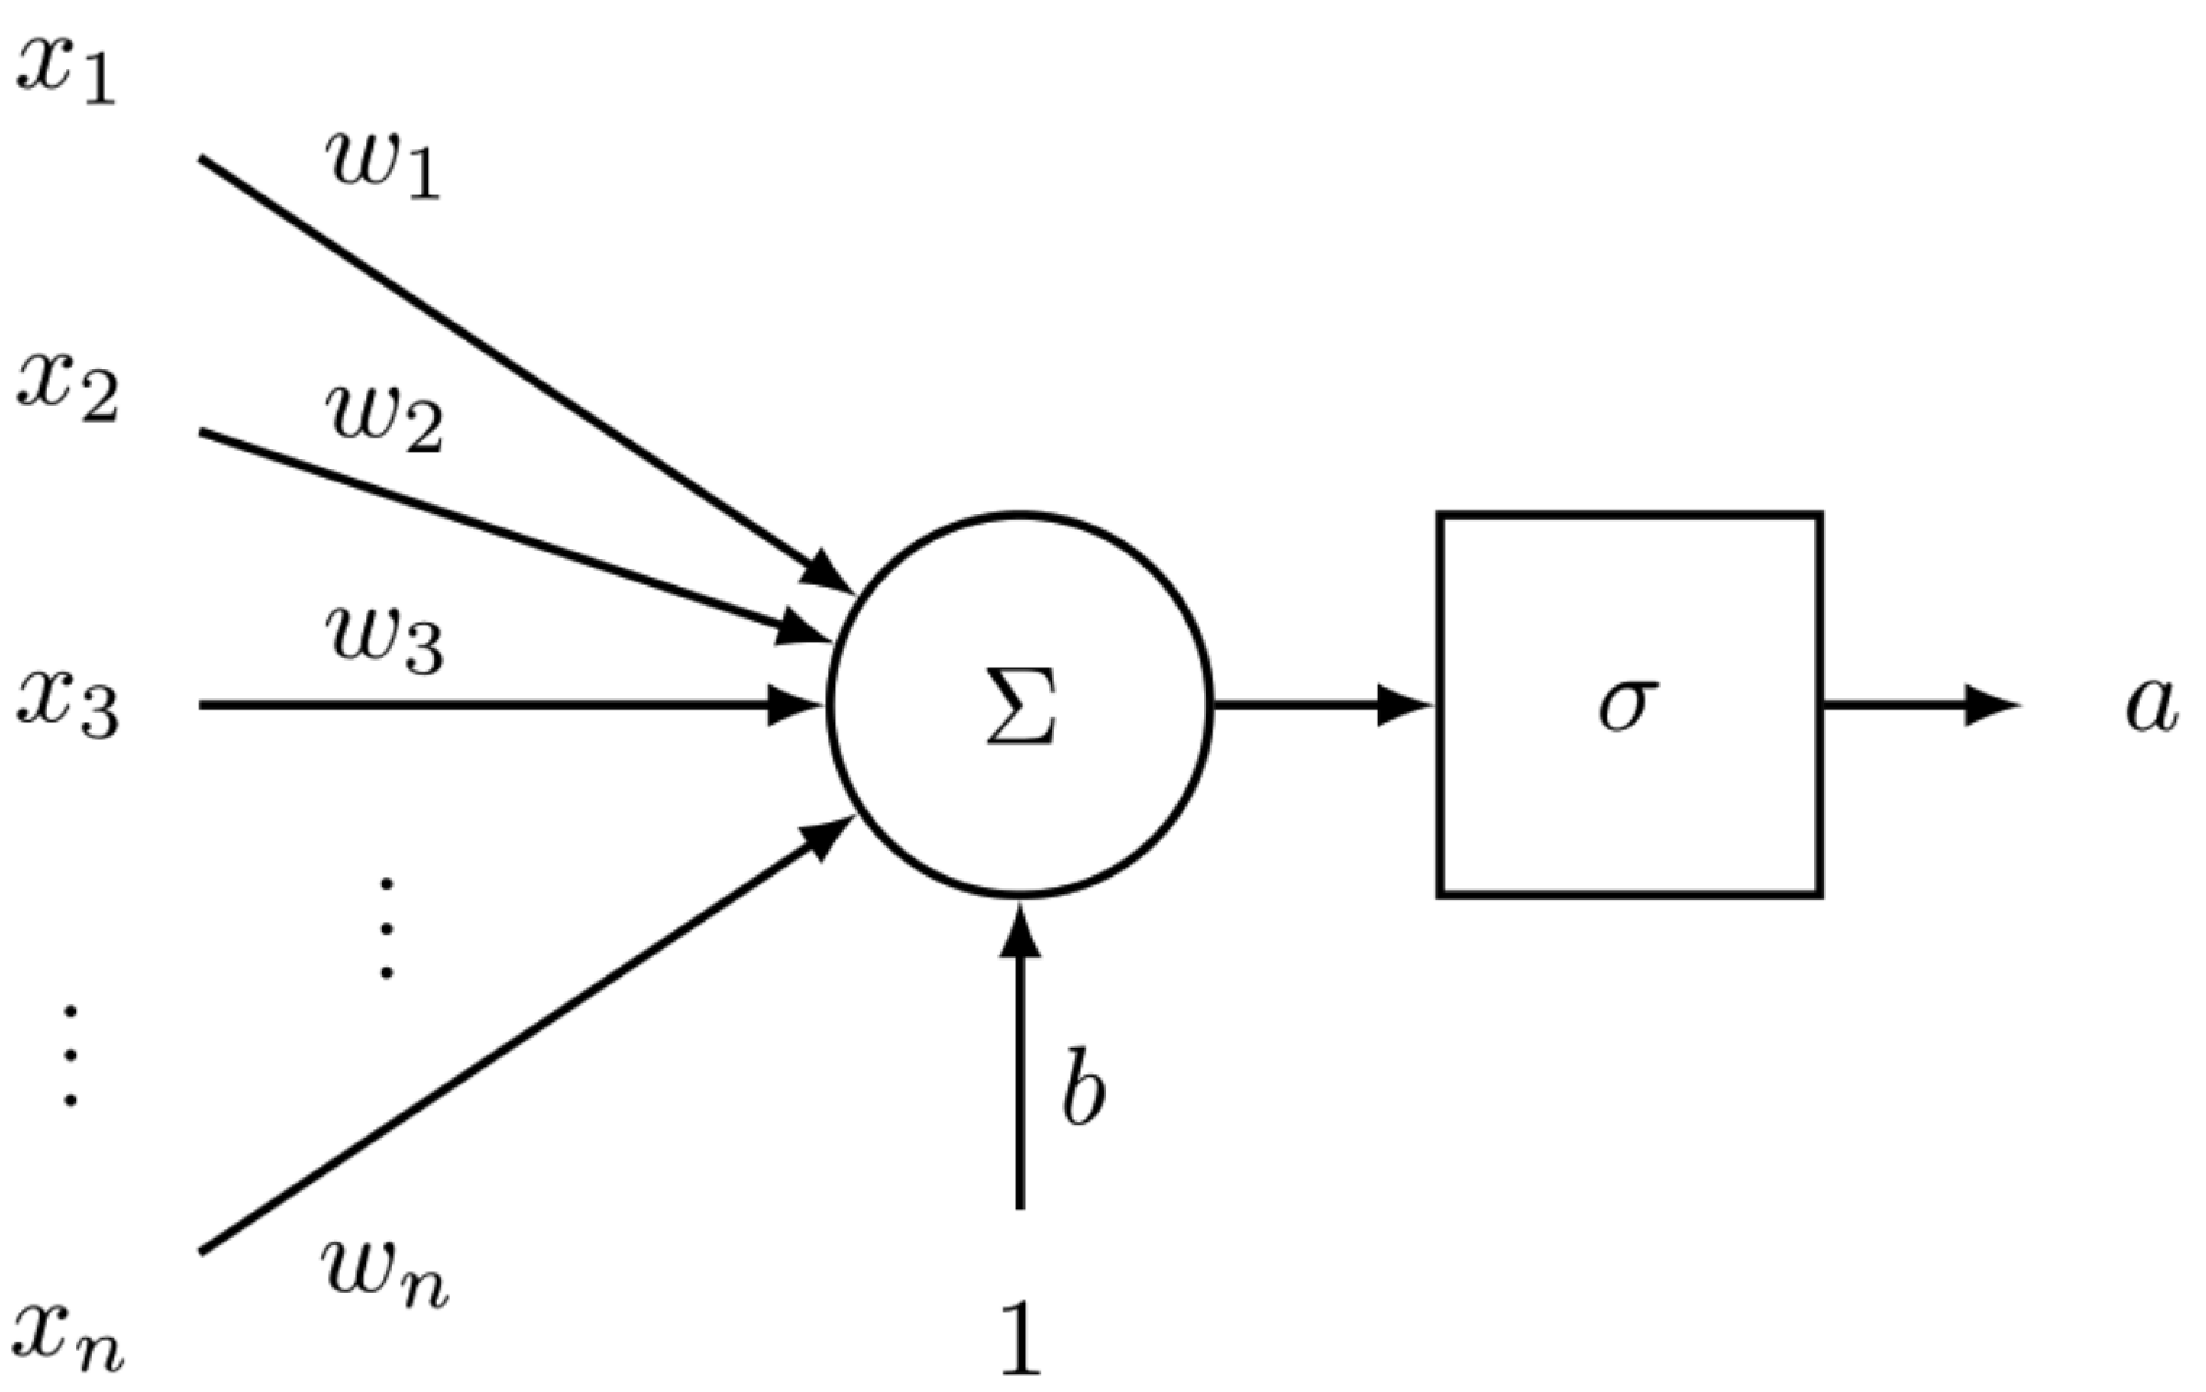

Dense

- 排列结构：Layer的结构是1d
- 超参数：神经元的个数U
- shape:
  - input = L
  - weights = L* U
  - output = U
- 意义：多个Dense层构成MLP（Multi-layer Perceptron， 多层感知机），用于解分类问题.

```
tf.layers.dense(
    inputs,
    units,
    activation=None,
    use_bias=True,
    kernel_initializer=None,
    bias_initializer=tf.zeros_initializer(),
    kernel_regularizer=None,
    bias_regularizer=None,
    activity_regularizer=None,
    kernel_constraint=None,
    bias_constraint=None,
    trainable=True,
    name=None,
    reuse=None
)
```

https://tensorflow.google.cn/api_docs/python/tf/keras/layers/Dense?hl=en

Softmax处理

- 输出层的Softmax 处理，计算出一个概率分布:

$$g(z_m) = \frac{e^{z_m}}{\sum_k e^{z_k}}$$

- 所有分量之和为 1,所有输出的数值是正的。

numpy_activation_function.ipynb

https://tensorflow.google.cn/api_docs/python/tf/keras/layers/Softmax?hl=en

图像处理

- 图像的表示-每个像素是数字
- 手写字体MNIST数据集，
  - 灰度图像，
  - 二值图像，黑白：
  - 0代表黑色， 1代表白色
- 时尚MNIST数据集（Fashion MNIST）
  - 彩色图像（RGB）：红(Red)，绿 (Green)， 蓝(Blue)
  - 对应的值域从0到255，对应8位2进制数字
  - 24位二进制数字

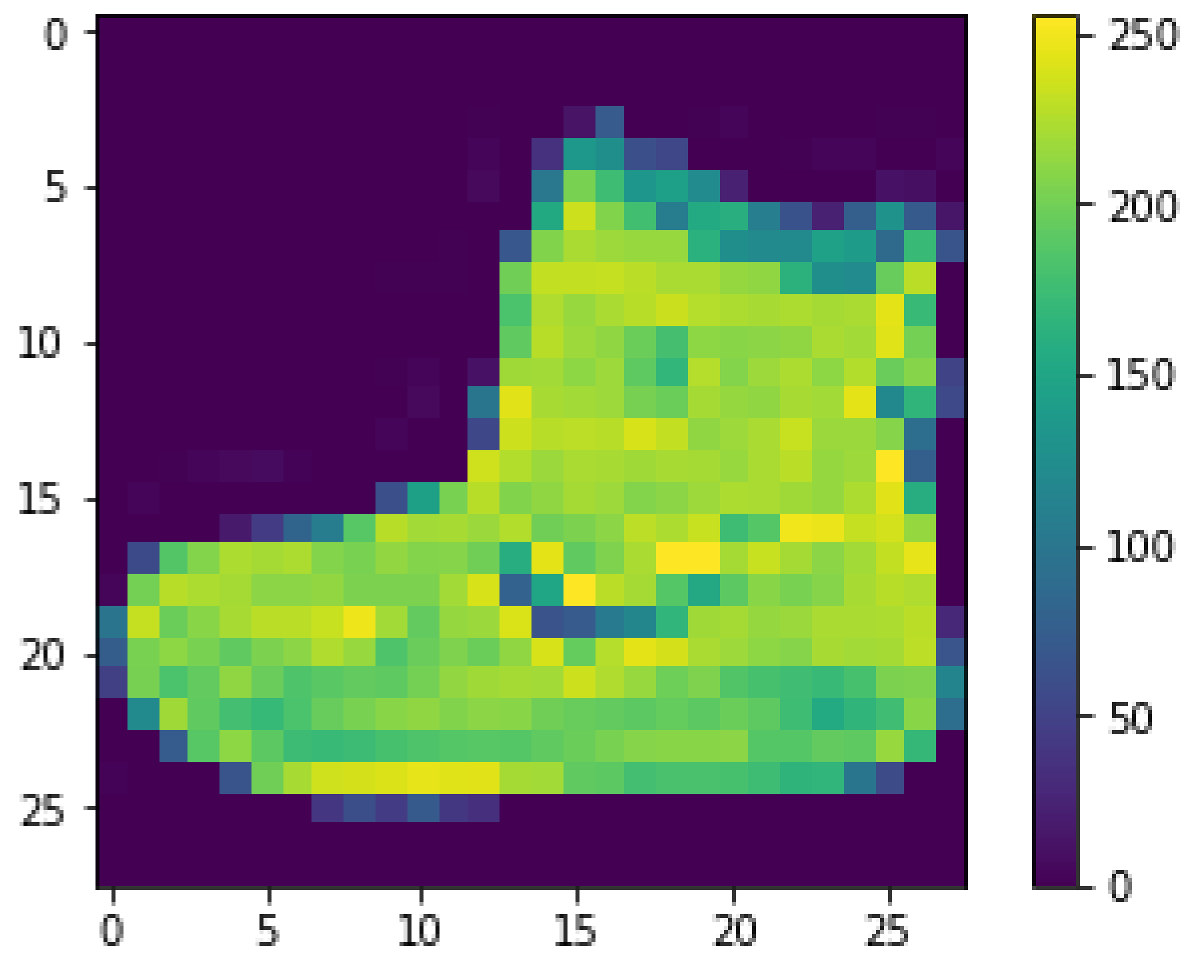

MLP处理图像

- MLP 分类器（多层Dense）
- MLP来处理一张图像
  - 图像单个像素点的颜色RGB值表示
  - 一张200x200x3的图片
  - 单个神经元有200*200*3 = 120,000参数!（参数量太大！怎么办？）

CNN

卷积运算（Convolution）

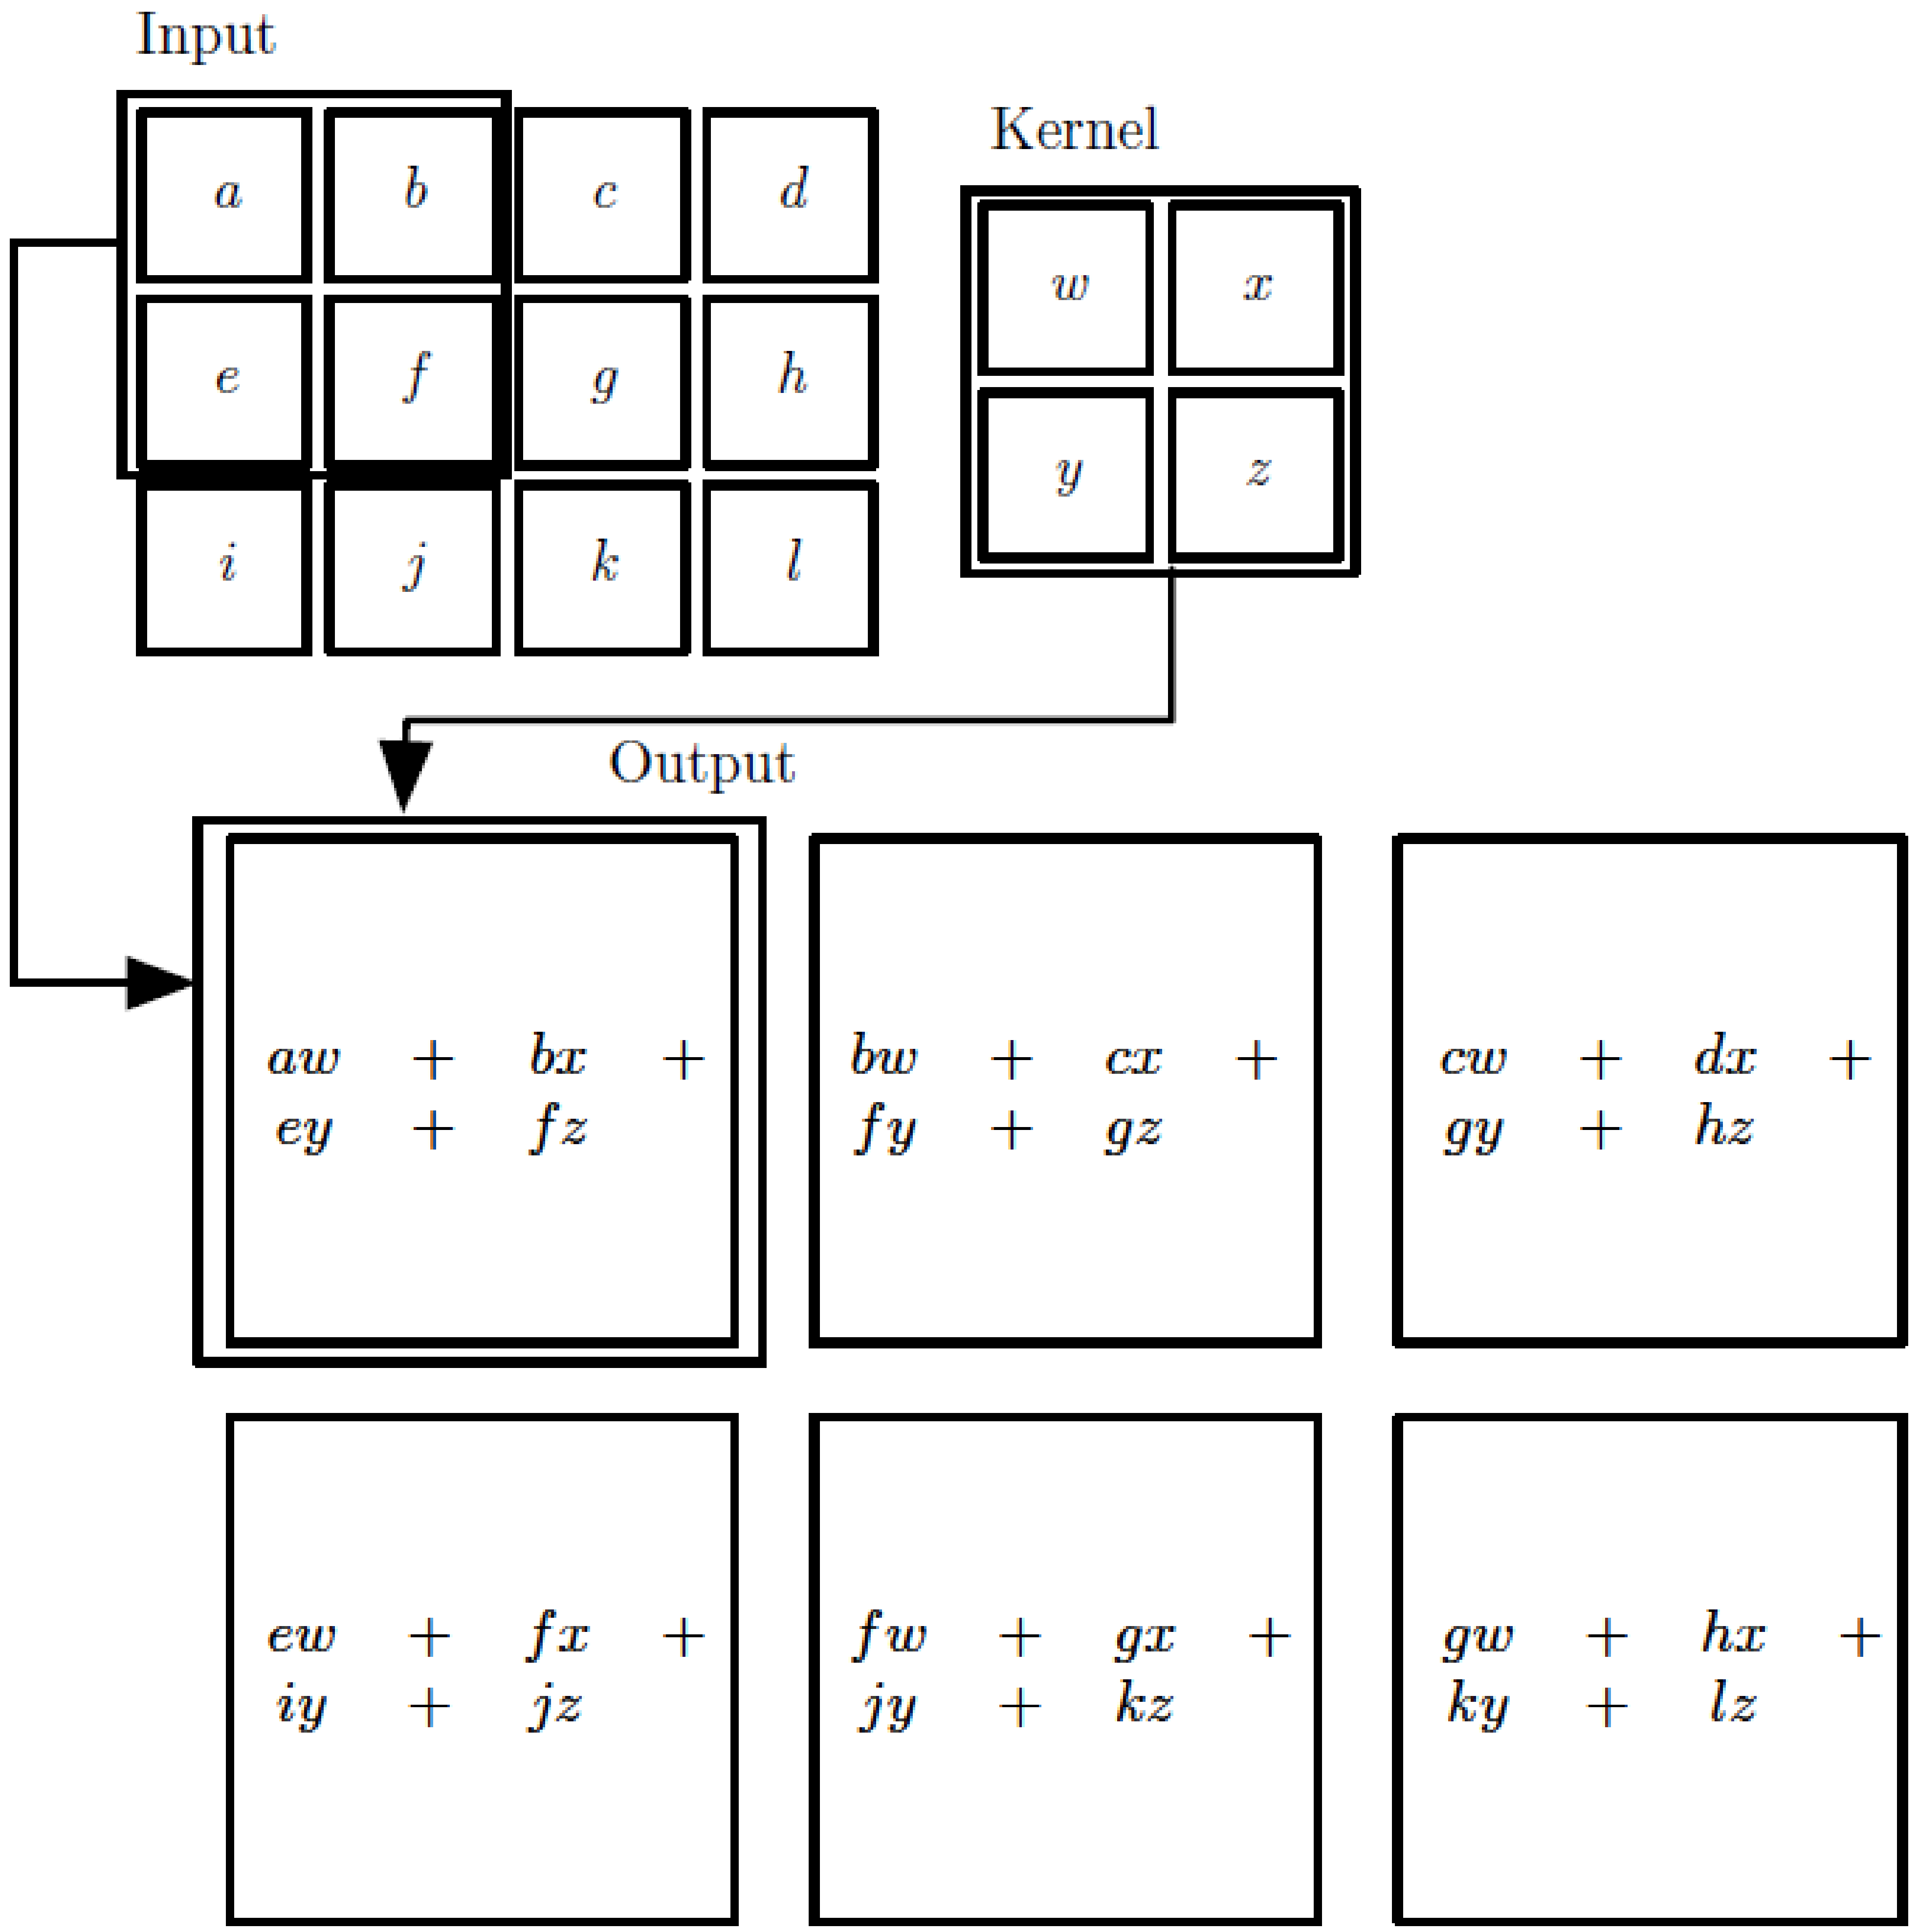

- 卷积是一种张量运算
- 输入是多维数组的数据
- 卷积核是一个多维数组，参数由学习算法得到的
- 卷积核数目一般选32、64等
- 这些多维数组都是张量（Tensor）。

Understanding Convolutions, http://colah.github.io/posts/2014-07-Understanding-Convolutions/

2d卷积核

- 卷积核是一个多维数组，参数由学习算法得到的
- 定义输入的长度(W)，卷积核的大小(F)，核移动的步长stride(S)，zero padding(P)
- 输出的长度L = (W-F+2P)/S+1
- 并行化：做一个和输出一样大小的Layer，Layer里面所有的神经元参数都一样！

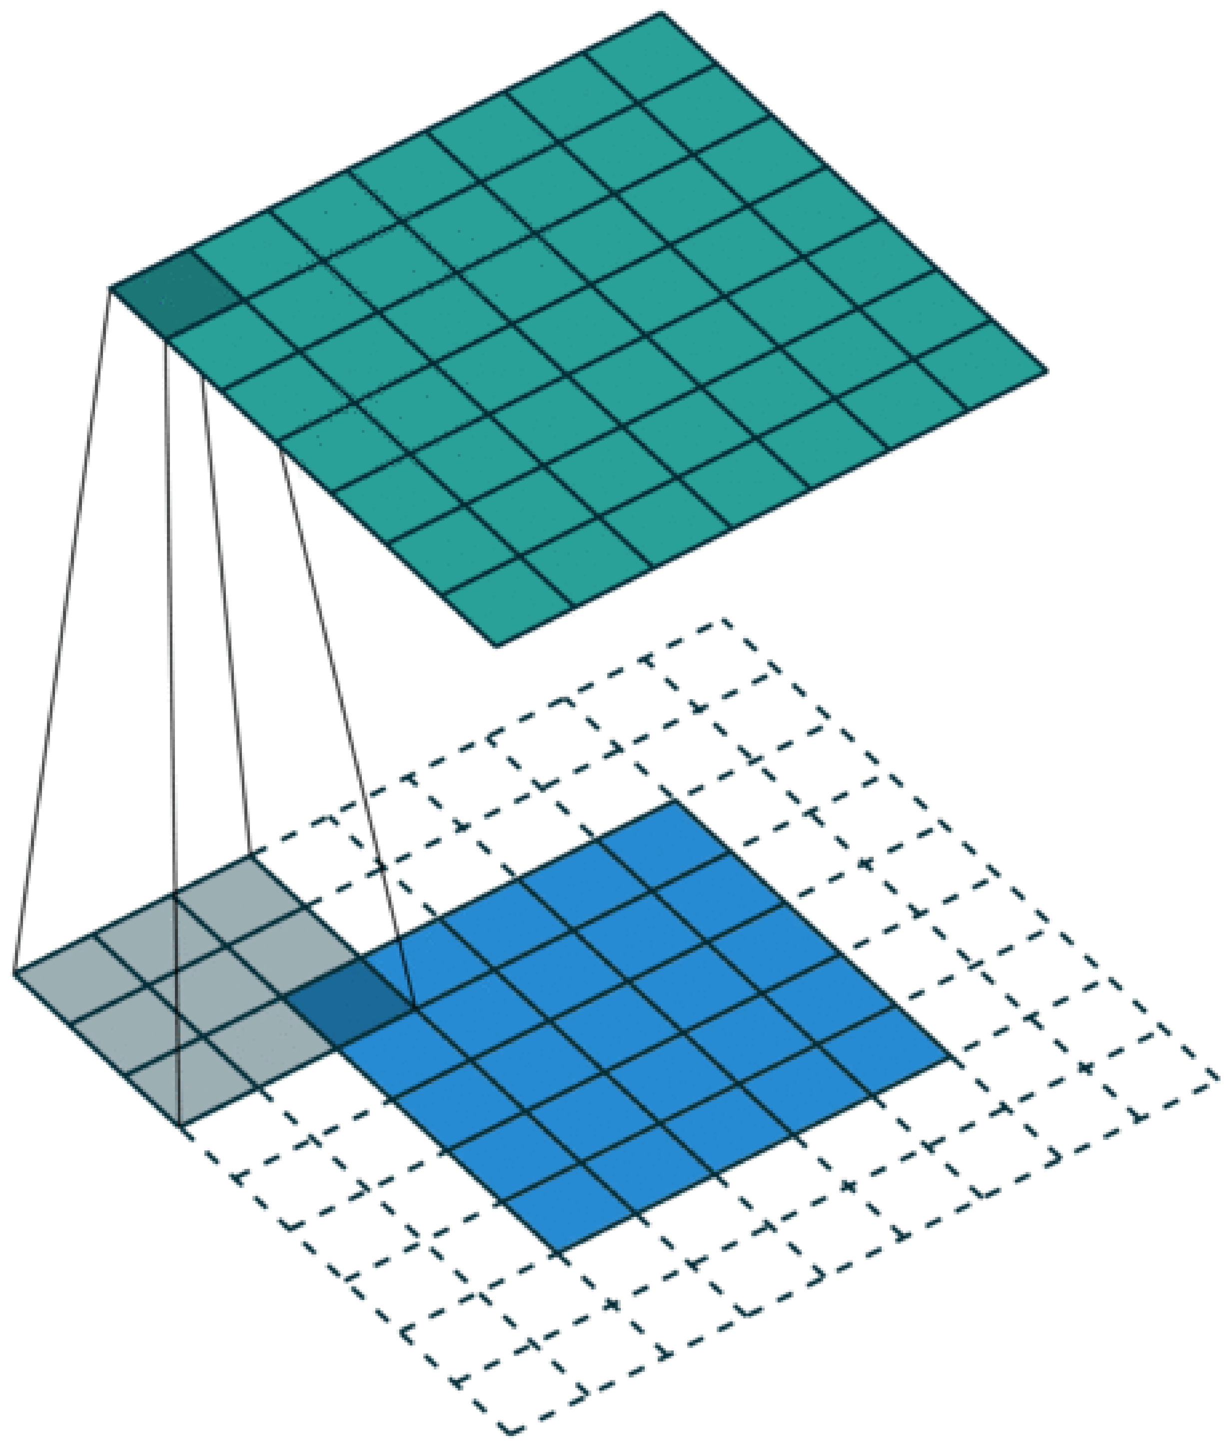

3d卷积核

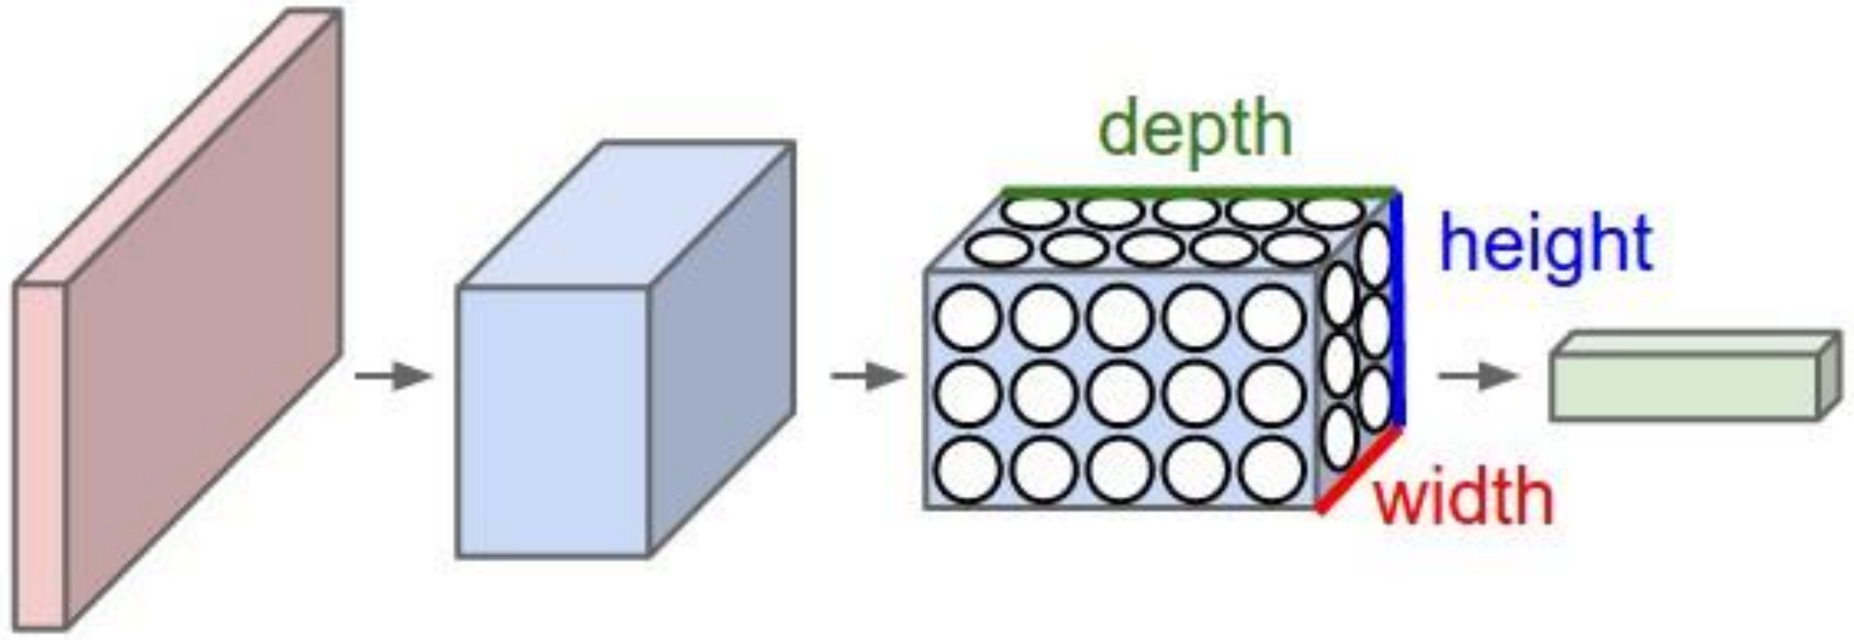

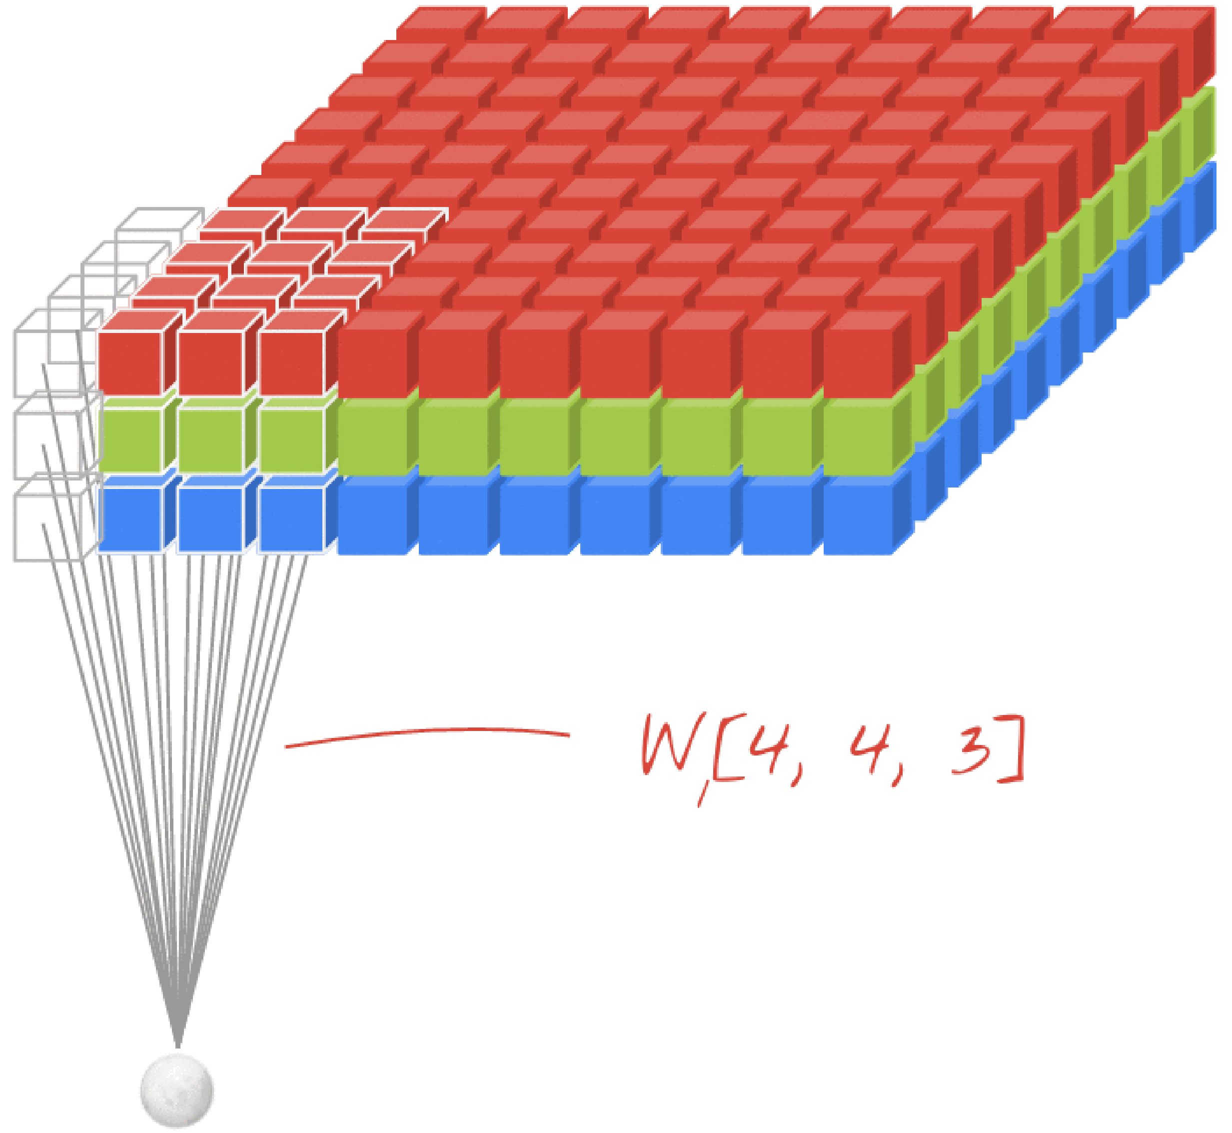

- 输入是3d的
- 有多个卷积核

CNN

- 卷积网络（Convolutional neural network，CNN）
- 特点：局部区域的权重W共用（weight sharing）（空间维度）
- 每一个卷积层后通常紧跟着一个下采样层(subsample)，如最大池化(max-pooling）方法完成下采样。

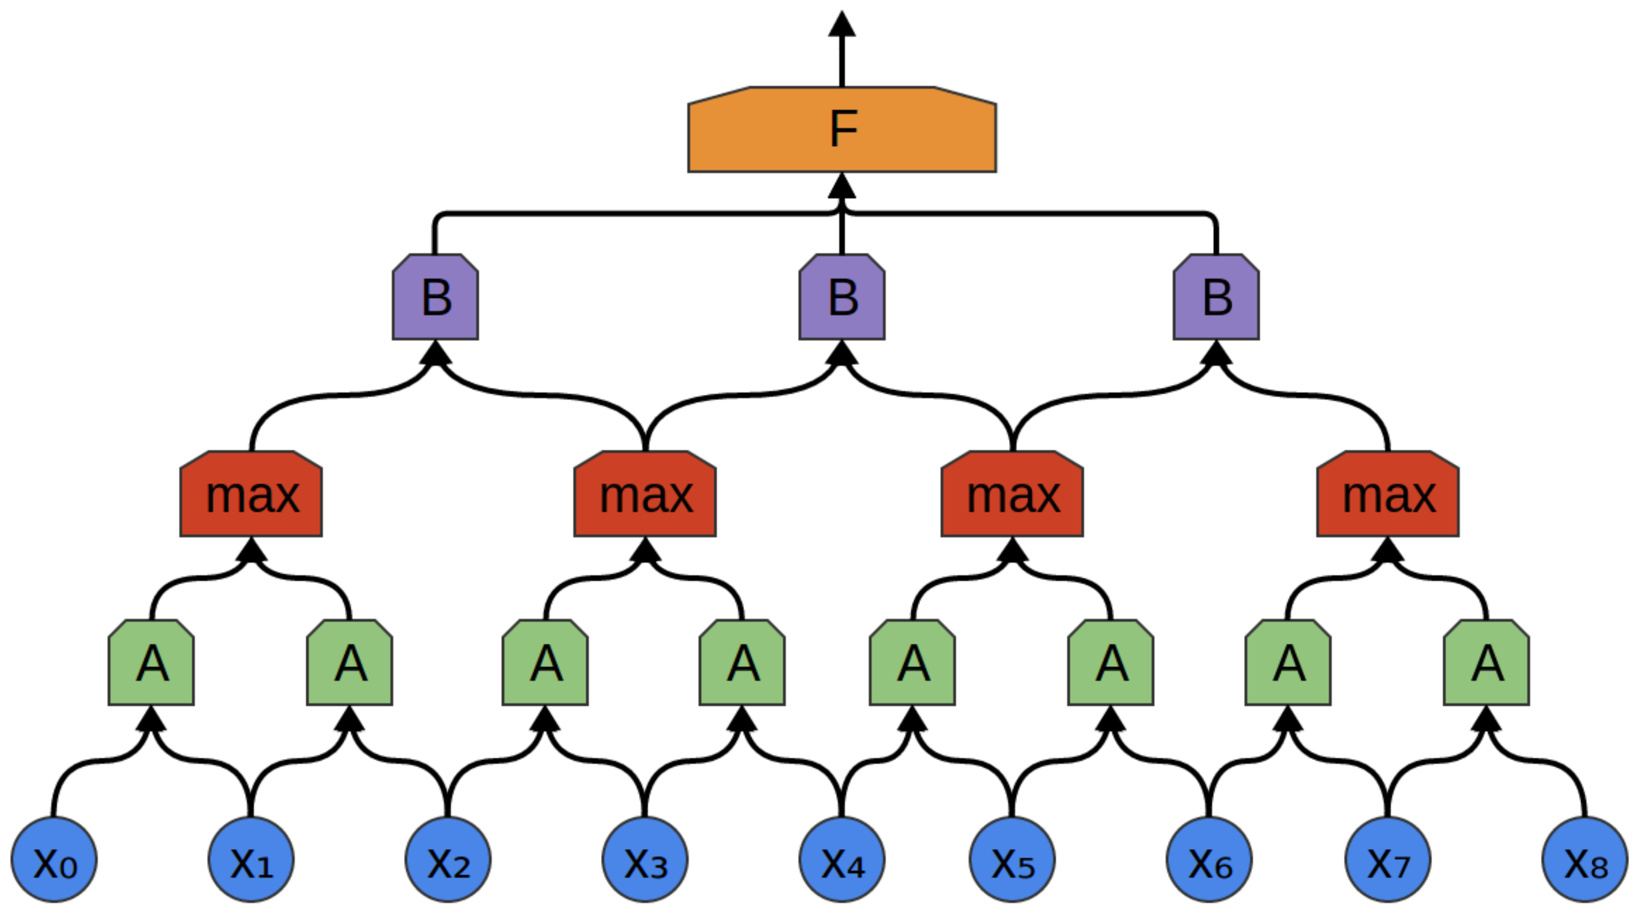

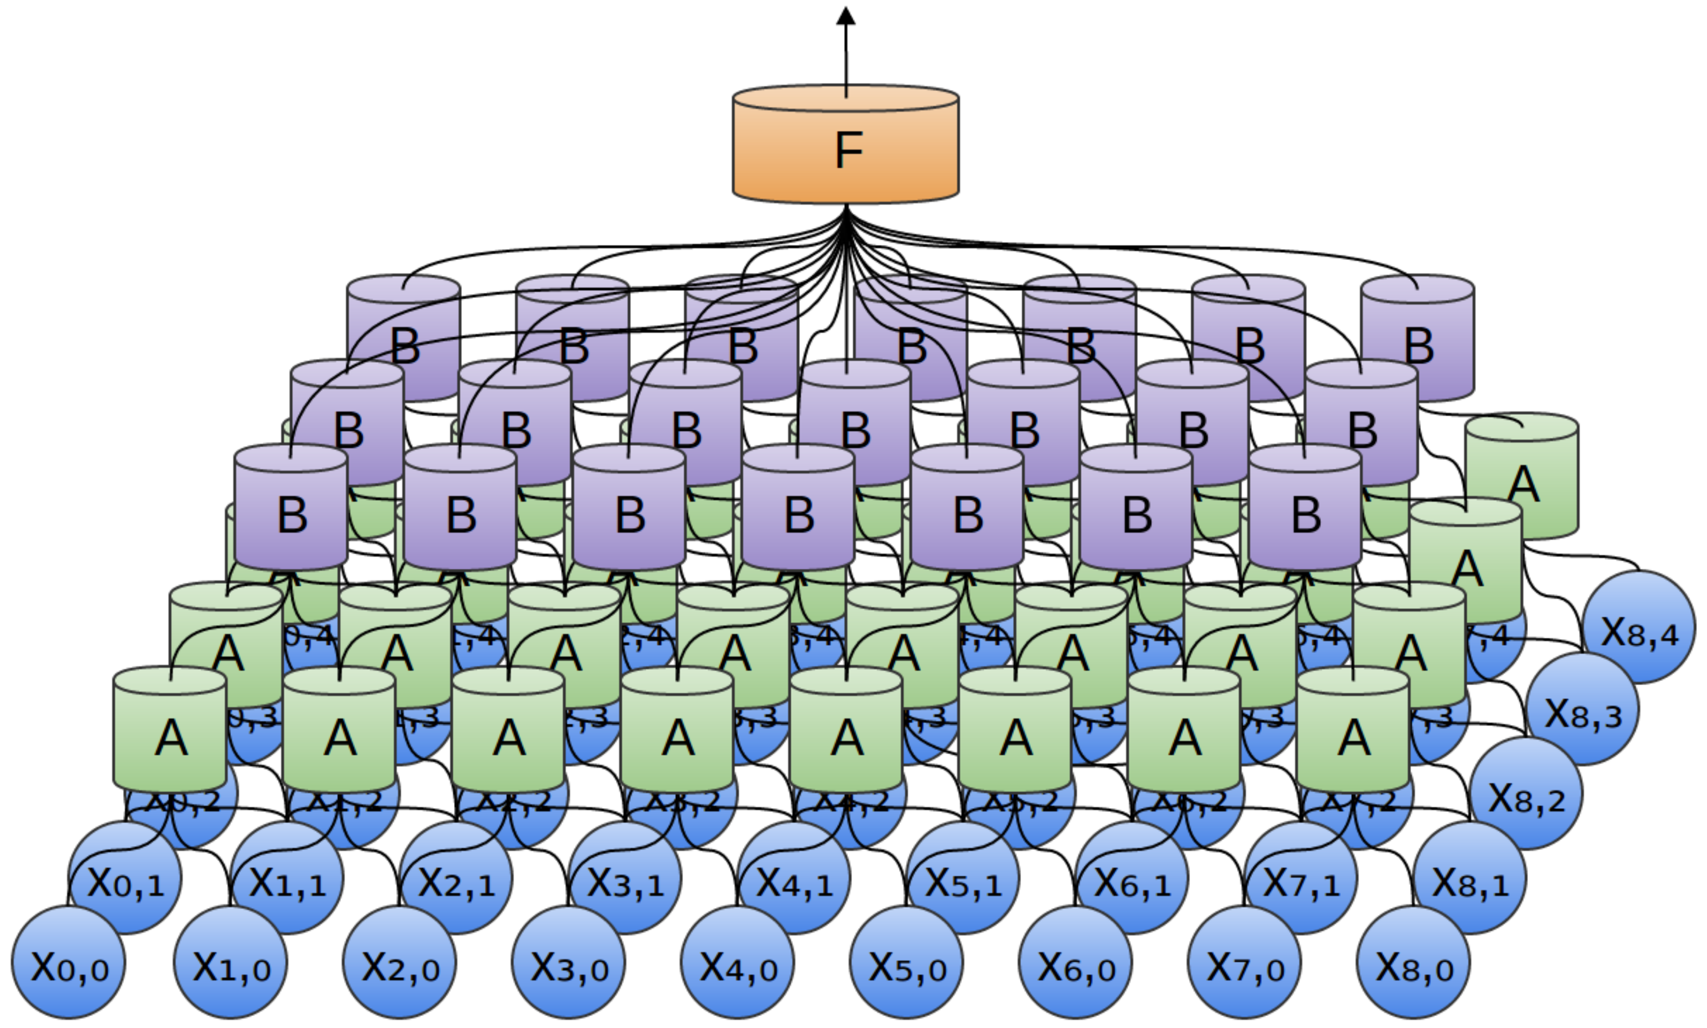

[Conv Nets: A Modular Perspective, http://colah.github.io/posts/2014-07-Conv-Nets-Modular/](http://colah.github.io/posts/2014-07-Conv-Nets-Modular/)

CNN组成

- 卷积层（convolutional layers）
- 采样层（pooling layers）
- 正则层（normalization layers）（如 dropout)

卷积层

- 意义：用于处理图像.
- 排列结构：Layer的结构是3d
- 超参数：卷积核个数(D)，核大小(F)，padding(P)，strides(S)
- shape:
  - Input = W*W*3
  - L = (W-F+2P)/S+1
  - Layer = L*L*D
  - Weights = F*F*D
  - Output = L*L*D

```
tf.layers.conv2d(
    inputs,
    filters,
    kernel_size,
    strides=(1, 1),
    padding='valid',
    data_format='channels_last',
    dilation_rate=(1, 1),
    activation=None,
    use_bias=True,
    kernel_initializer=None,
    bias_initializer=tf.zeros_initializer(),
    kernel_regularizer=None,
    bias_regularizer=None,
    activity_regularizer=None,
    kernel_constraint=None,
    bias_constraint=None,
    trainable=True,
    name=None,
    reuse=None
)
```

https://tensorflow.google.cn/api_docs/python/tf/keras/layers/Conv2D?hl=en

Pooling层

- 意义：采样，缩小模型大小
- 排列结构：Layer的结构是3d
- 超参数： pooling_type, window_shape, padding, strides
- 一个2*2核， strides=2的pooling层，等于减少75%的输出
- pooling层并不会改变tensor的深度

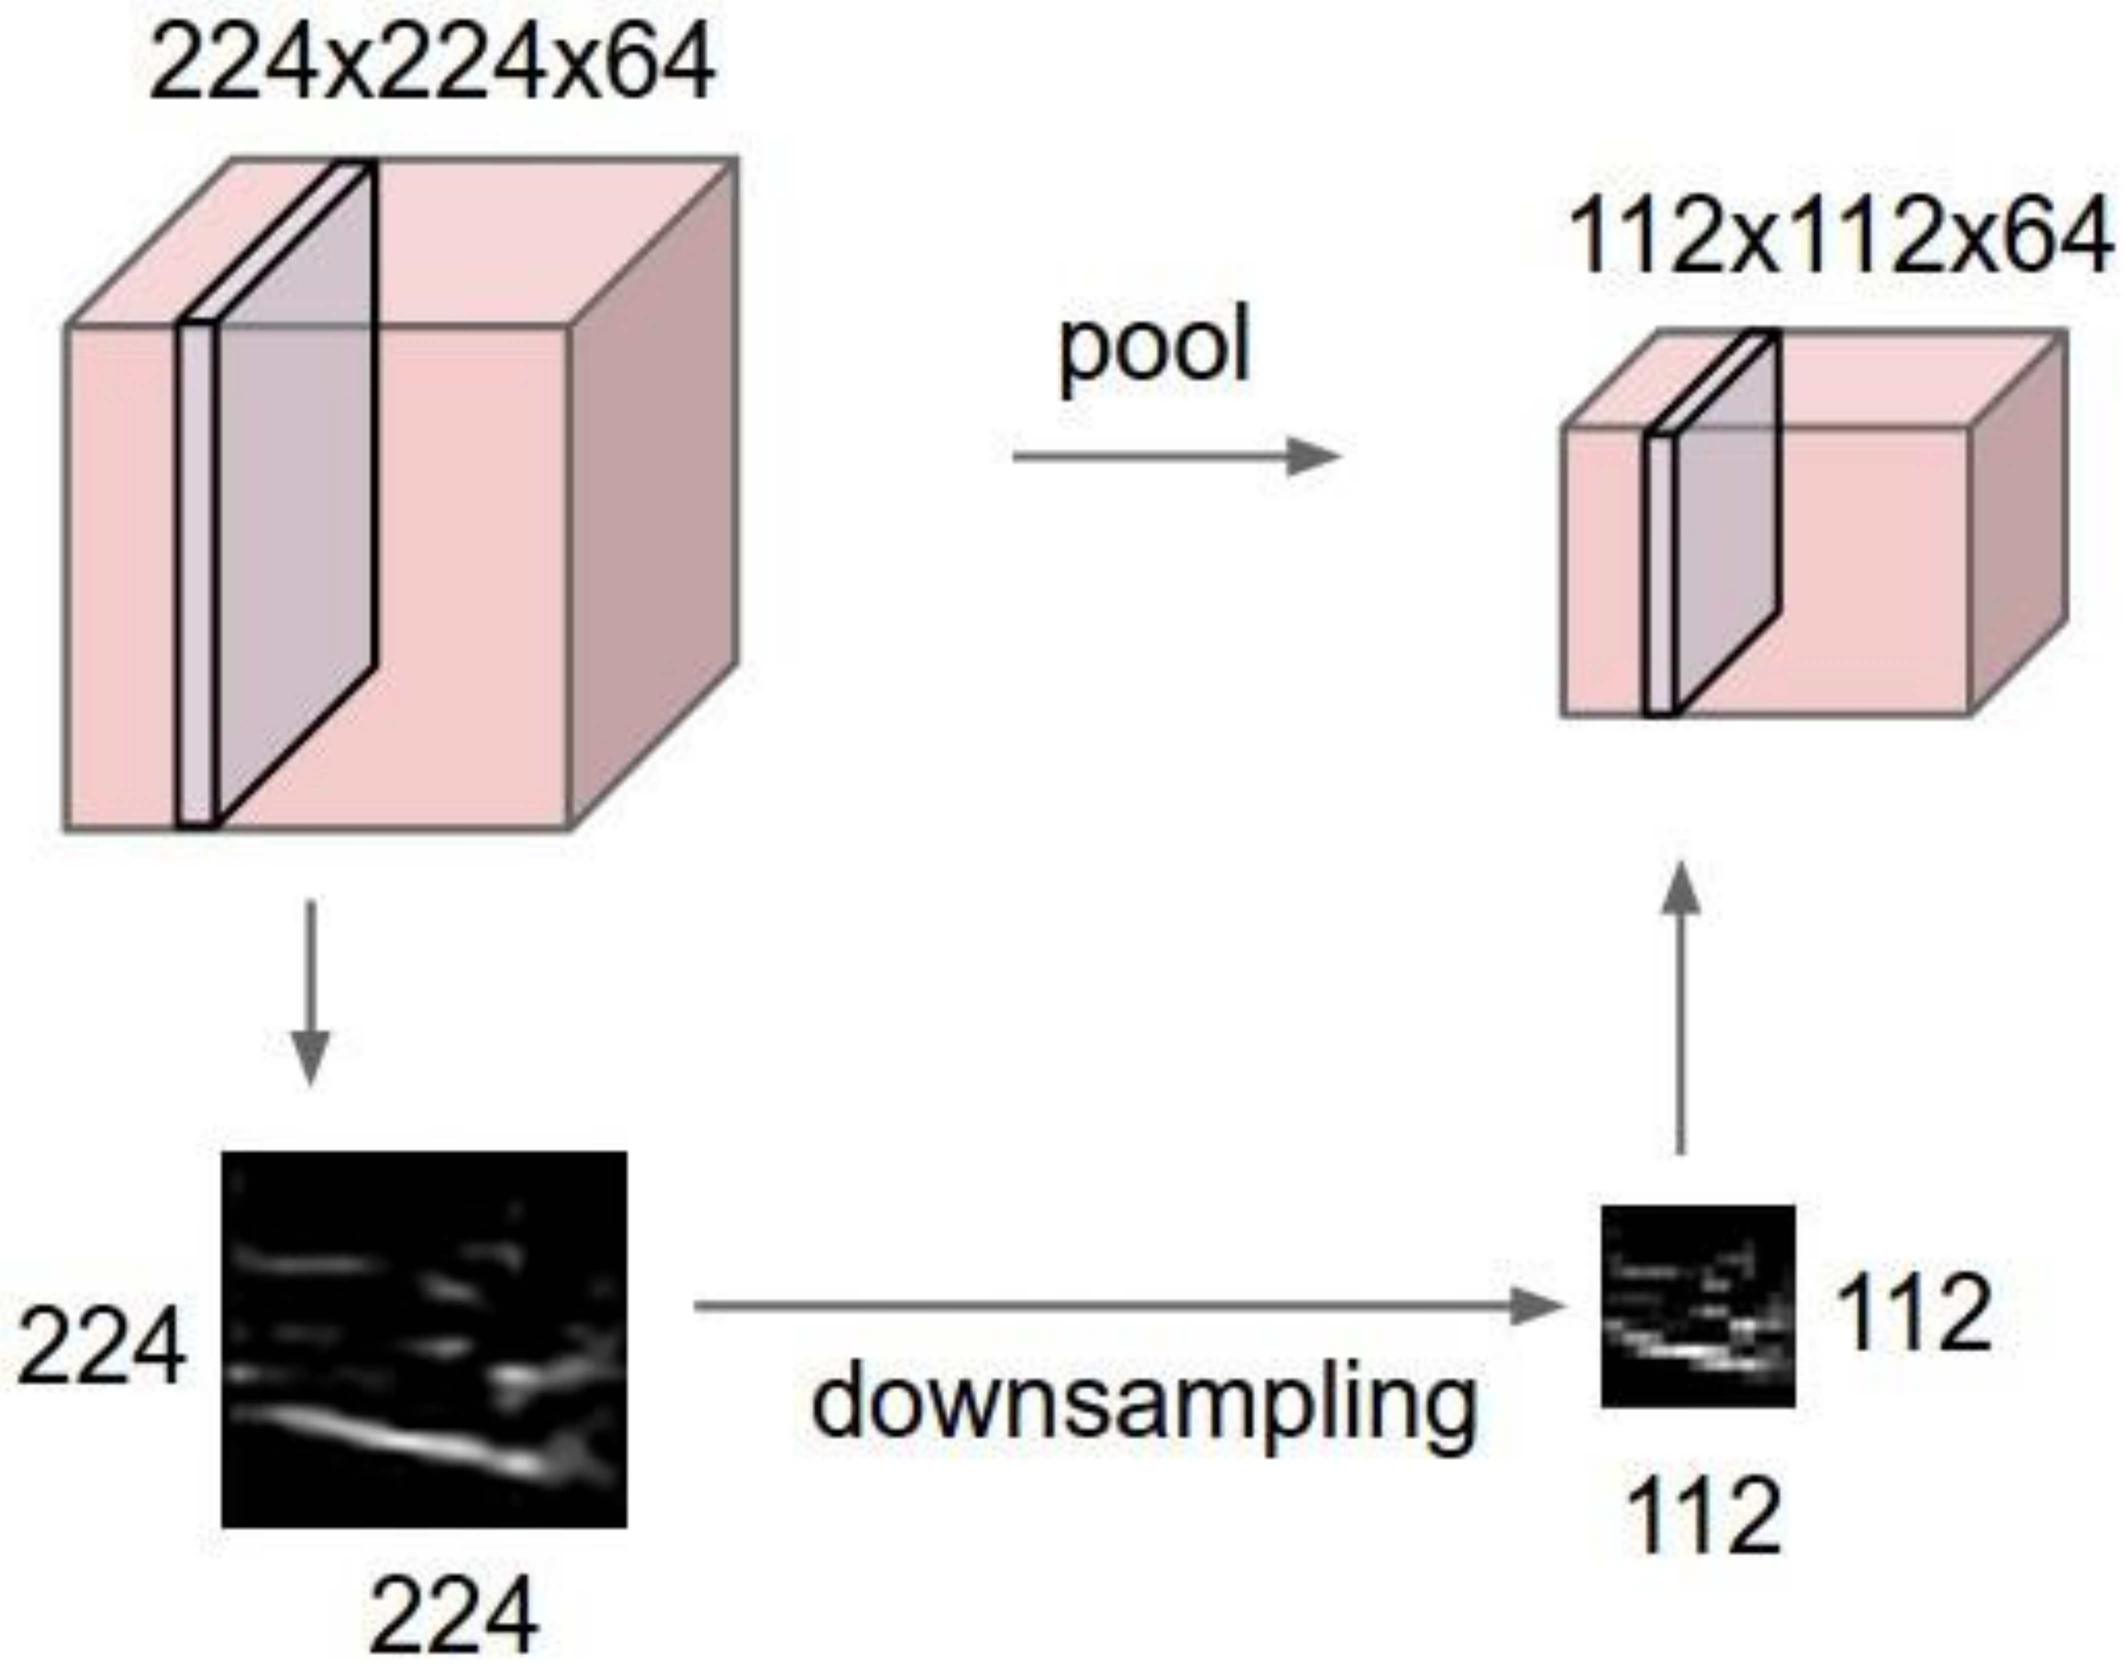

https://tensorflow.google.cn/api_docs/python/tf/keras/layers/MaxPool2D?hl=en

Dropout层

- 意义：减少CNN过拟合问题
- 超参数：keep_prob 丢弃率
- 对于所有的输入，有keep_prob概率保留并乘以1/keep_prob，以保证前后总和大致相等，否则输出0

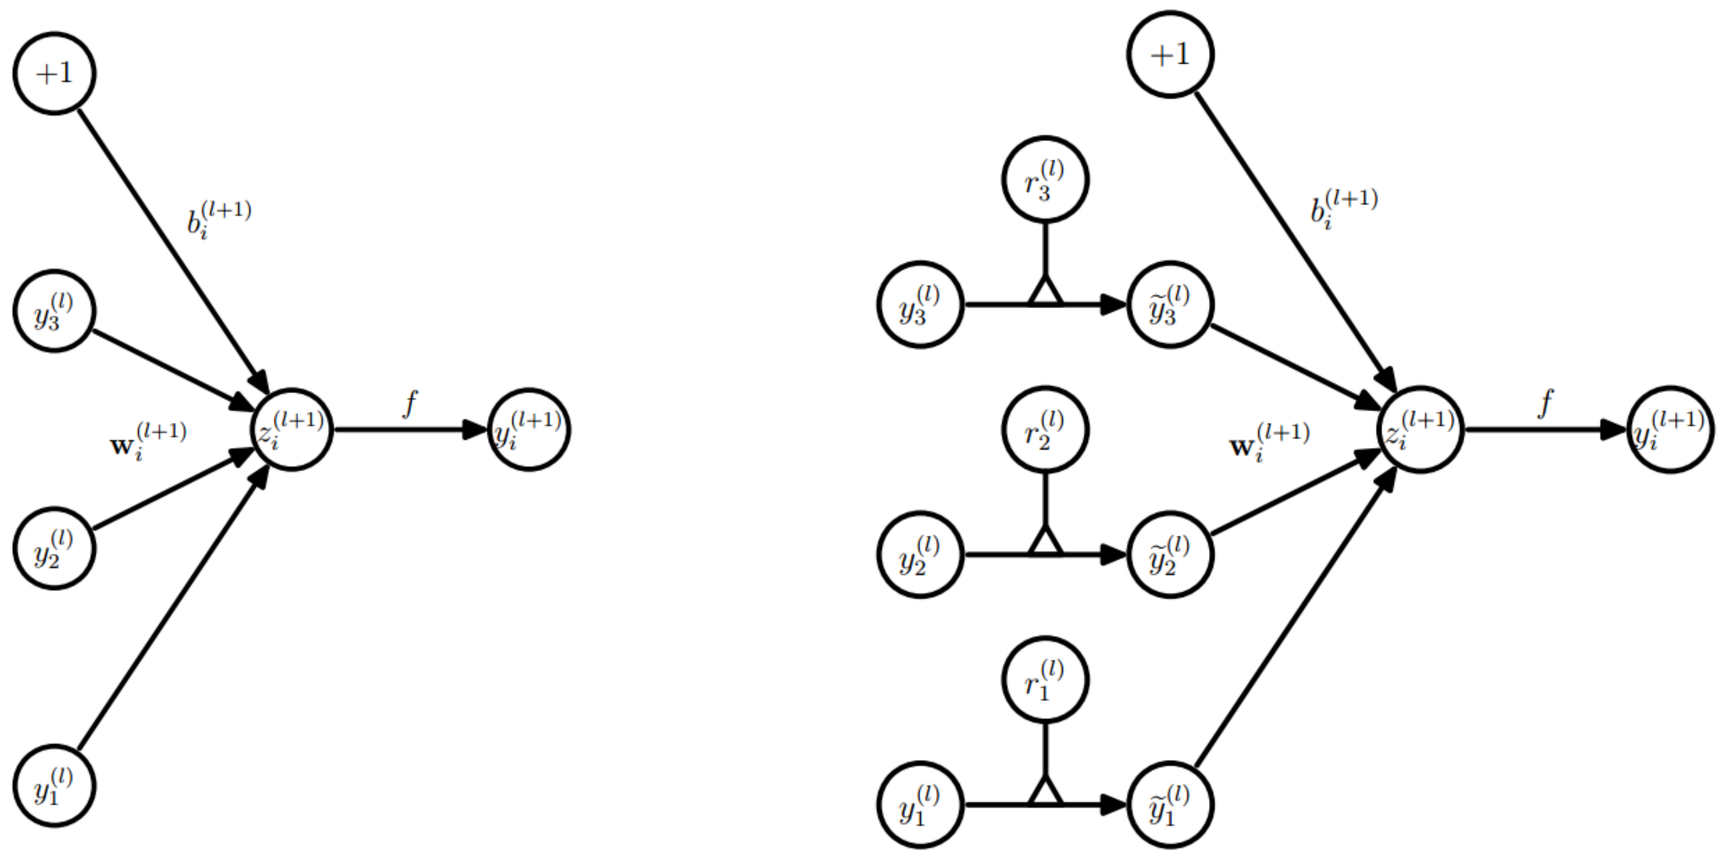

(a) Standard network (b) Dropout network

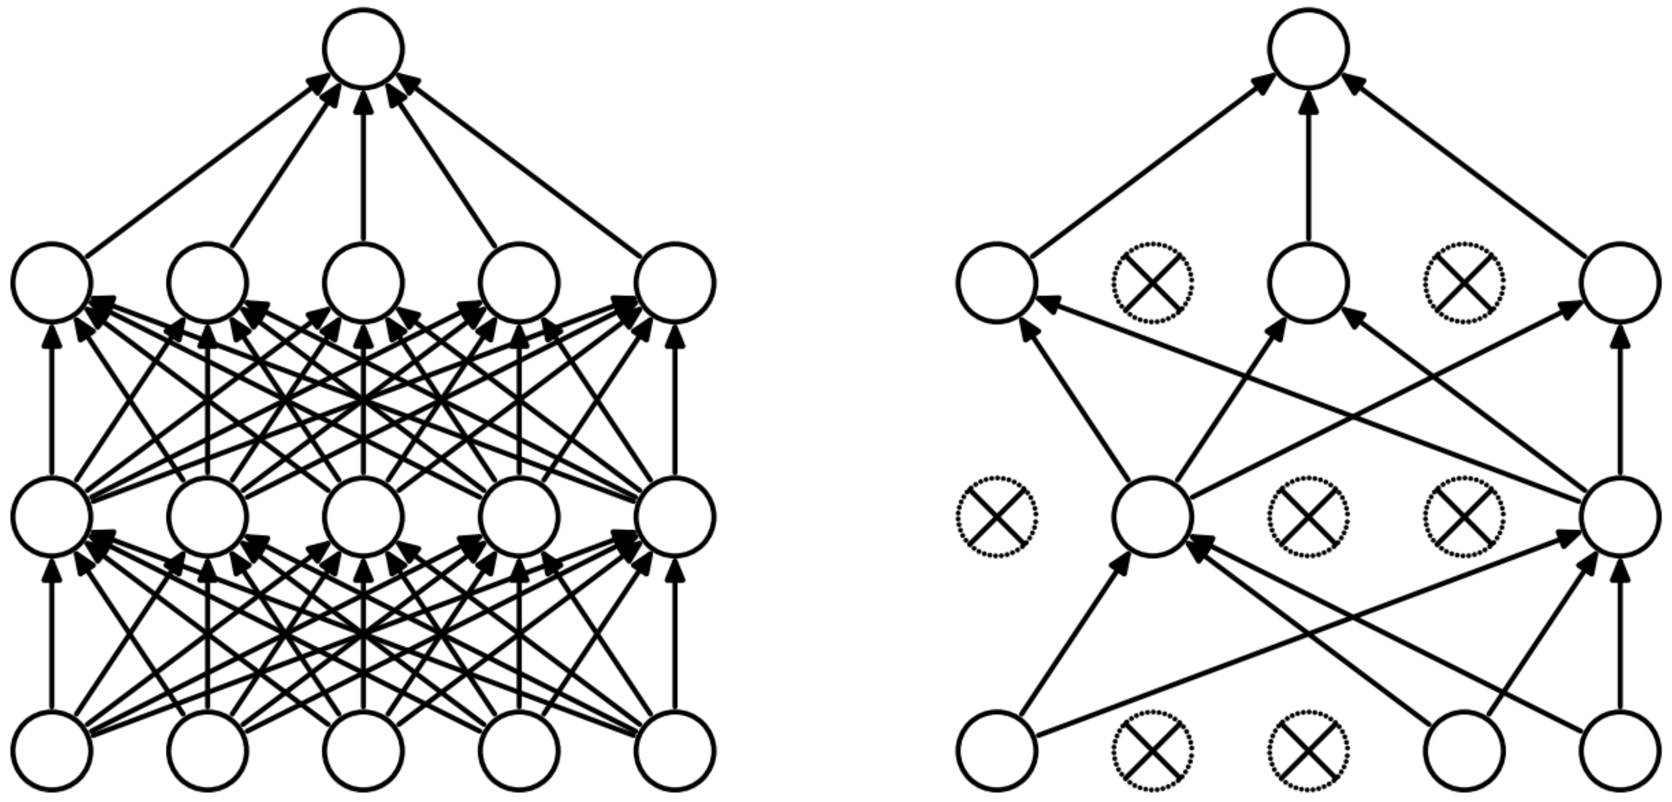

(a) Standard Neural Net (b) After applying dropout.

https://tensorflow.google.cn/api_docs/python/tf/keras/layers/Dropout?hl=en

共享Variable

```
def my_image_filter(input_images):
    with tf.variable_scope("conv1"):
        # Variables created here will be named "conv1/weights", "conv1/biases".
        relu1 = conv_relu(input_images, [5, 5, 32, 32], [32])
    with tf.variable_scope("conv2"):
        # Variables created here will be named "conv2/weights", "conv2/biases".
        return conv_relu(relu1, [5, 5, 32, 32], [32])
```

```
with tf.variable_scope("model") as scope:
  output1 = my_image_filter(input1)
  scope.reuse_variables()
  output2 = my_image_filter(input2)
```

生成两套参数

```
with tf.variable_scope("model") as scope:
  output1 = my_image_filter(input1)
  scope.reuse_variables()
  output2 = my_image_filter(input2)
```

共享一套参数

https://tensorflow.google.cn/programmers_guide/variables#sharing_variables

课后阅读作业

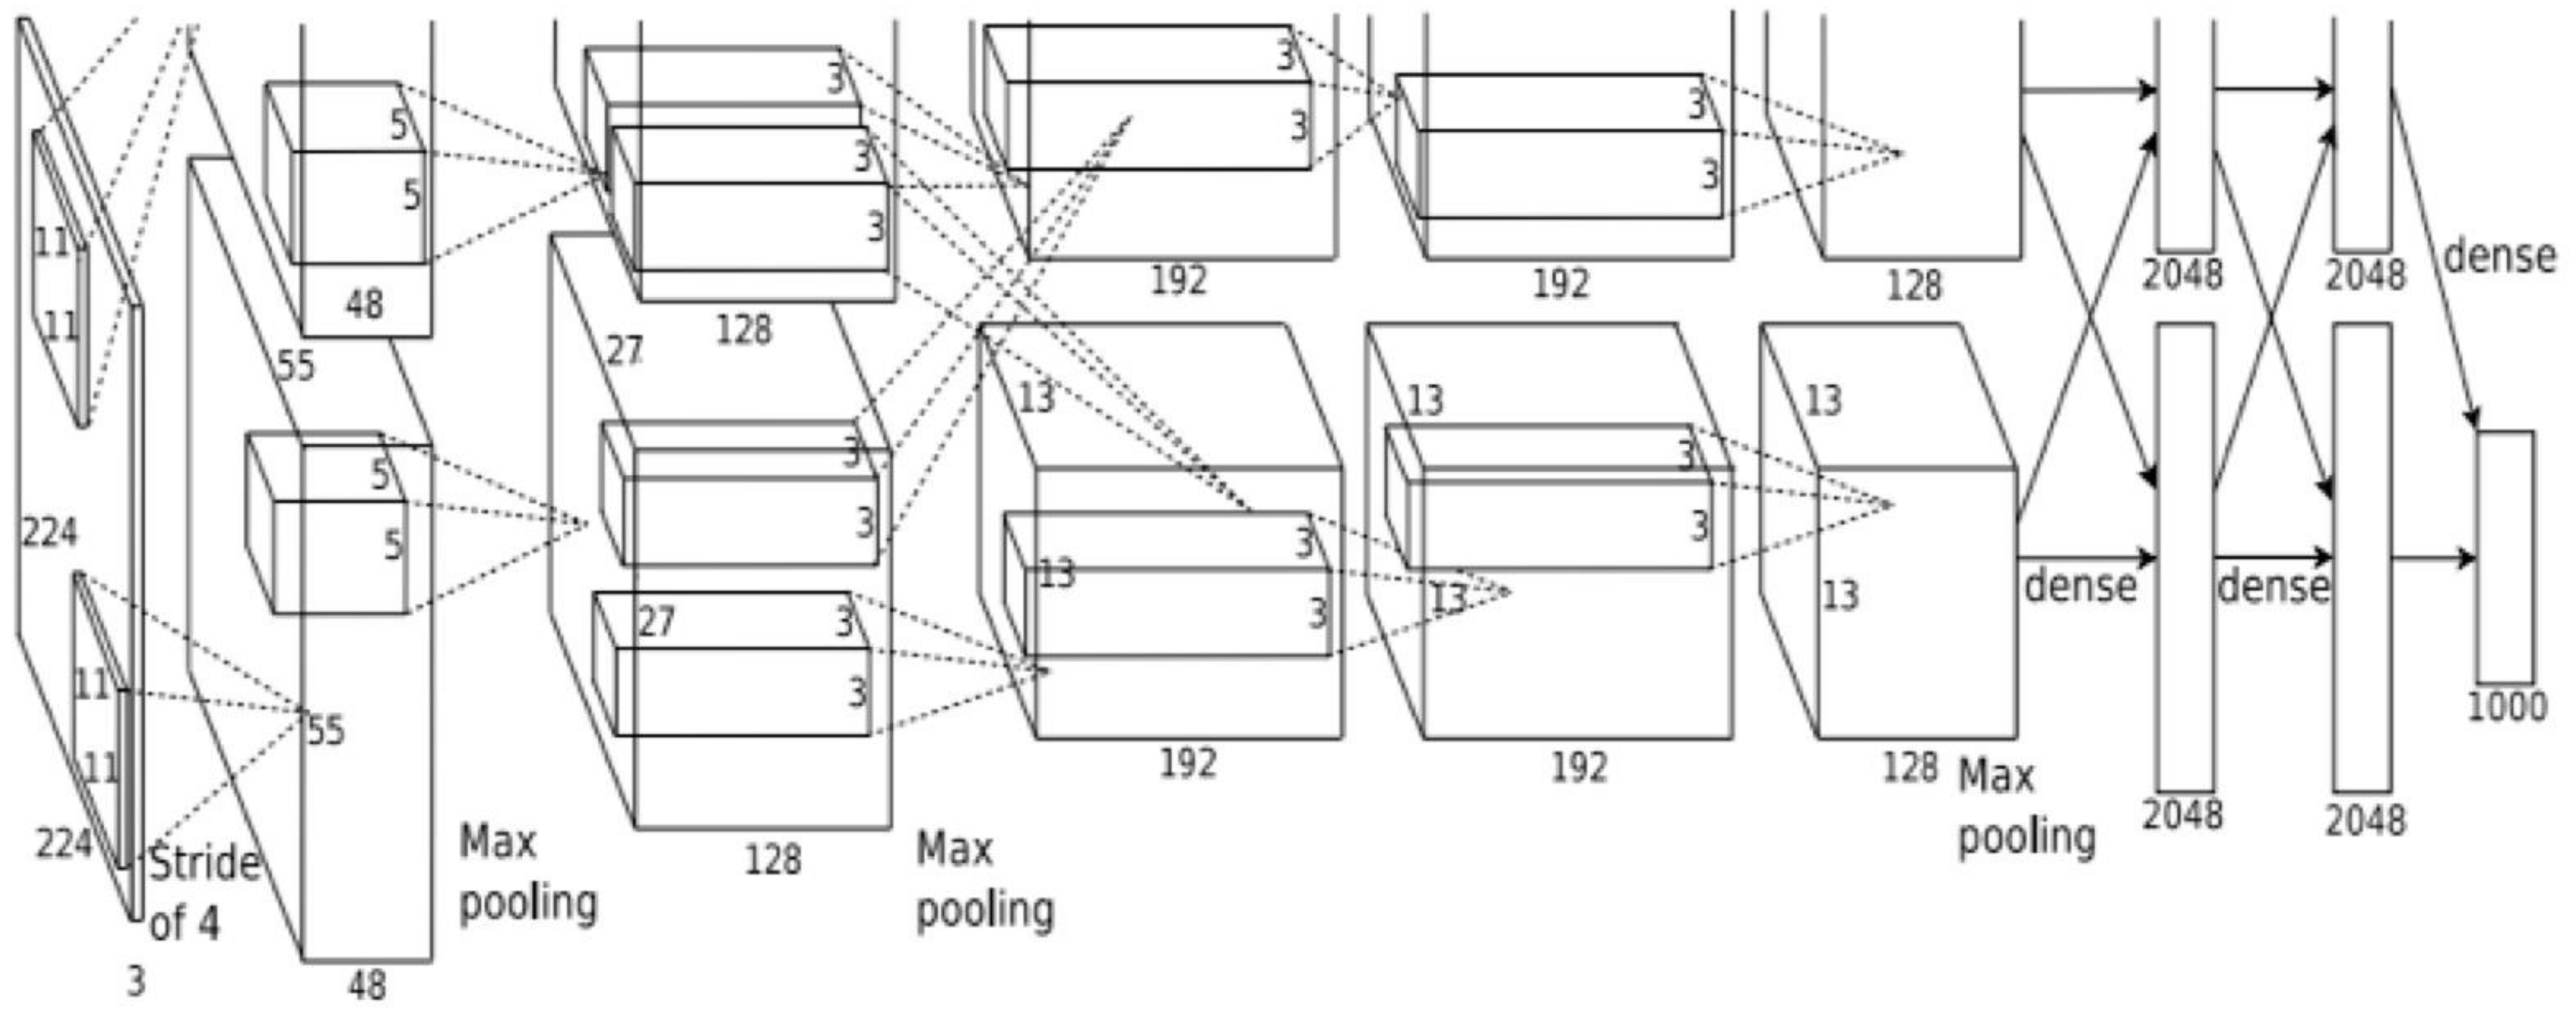

Alex Krizhevsky, Ilya Sutskever and Geoffrey E. Hinton. ″ImageNet classification with deep convolutional neural networks.″ NIPS 2012.

Simple RNN

学习路线

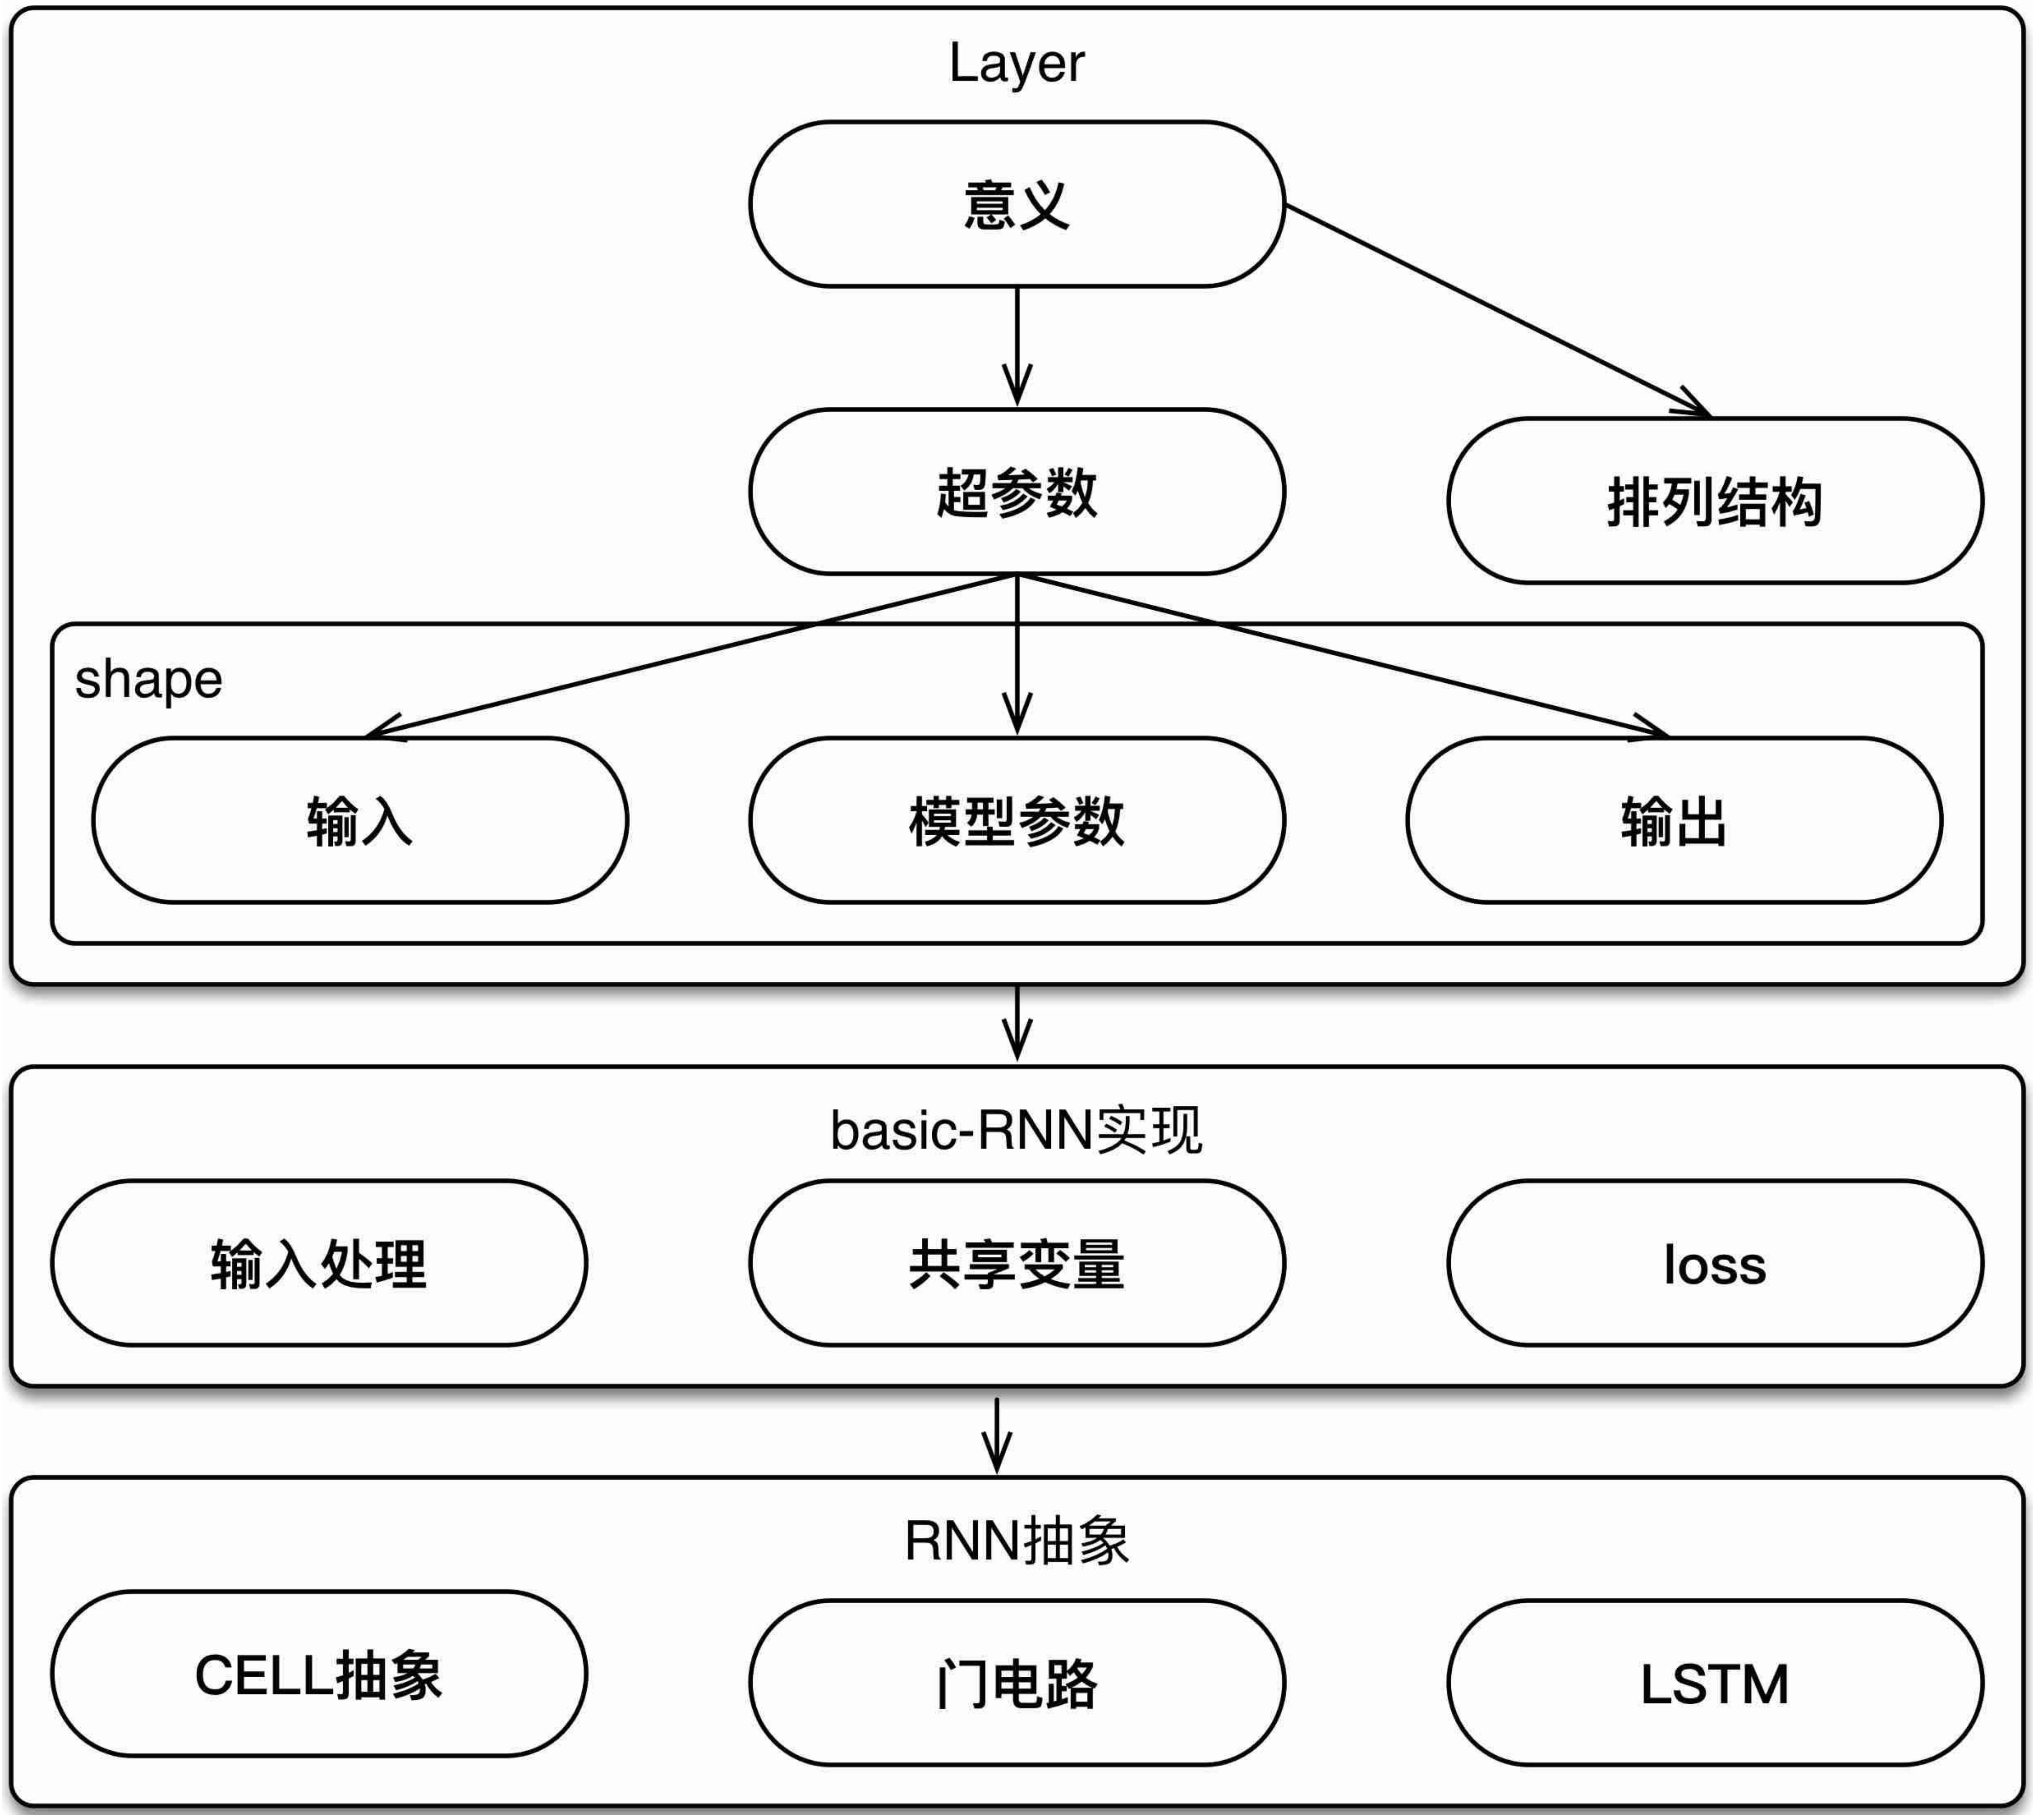

Layer
意义
超参数
排列结构
shape
输入
模型参数
输出
basic-RNN实现
输入处理
共享变量
loss
RNN抽象
CELL抽象
门电路
LSTM

RNN

- 循环网络结构
  - y是训练目标
  - L是损失函数
  - o是网络输出
  - h是状态（隐藏单元）
  - x是网络输入
- 计算图的时间步上展开
- 举例：天气预测

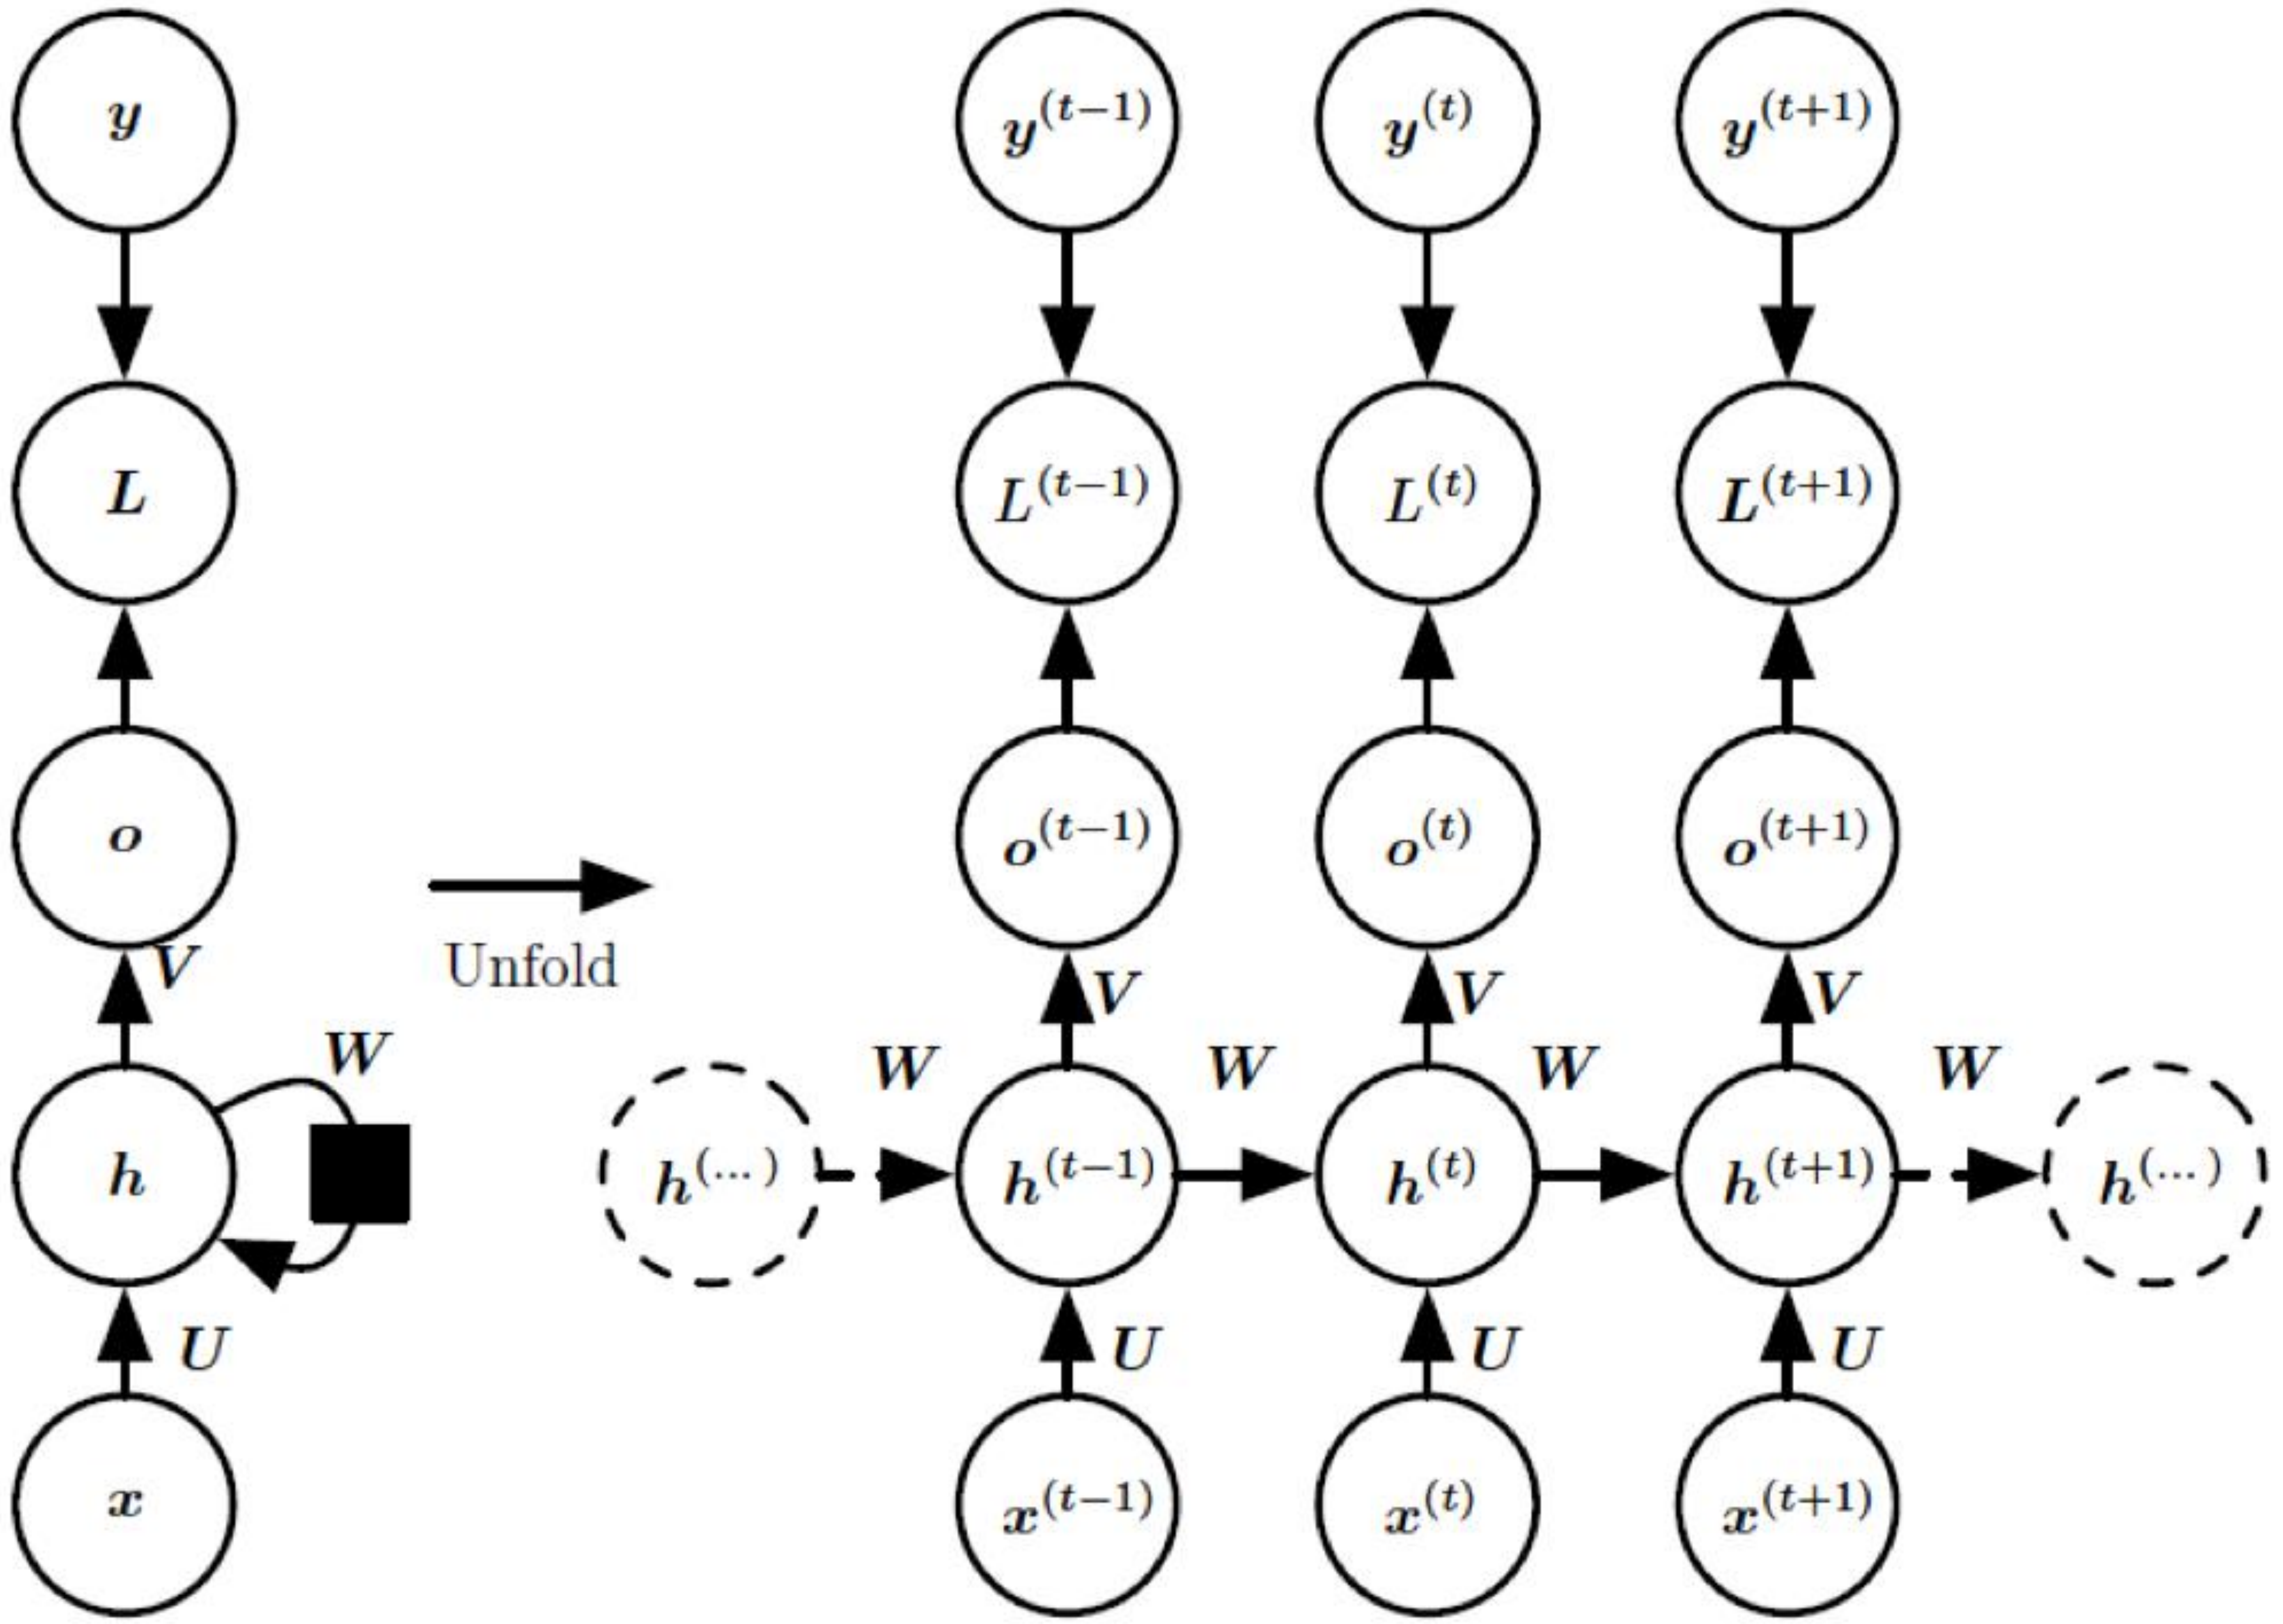

权重共享

- 循环神经网络在不同的时间步上采用相同的U、V、W参数
- 输入到隐藏的连接由权重矩阵U 参数化
- 隐藏到输出的连接由权重矩阵V 参数化
- 隐藏到隐藏的循环连接由权重矩阵W 参数化

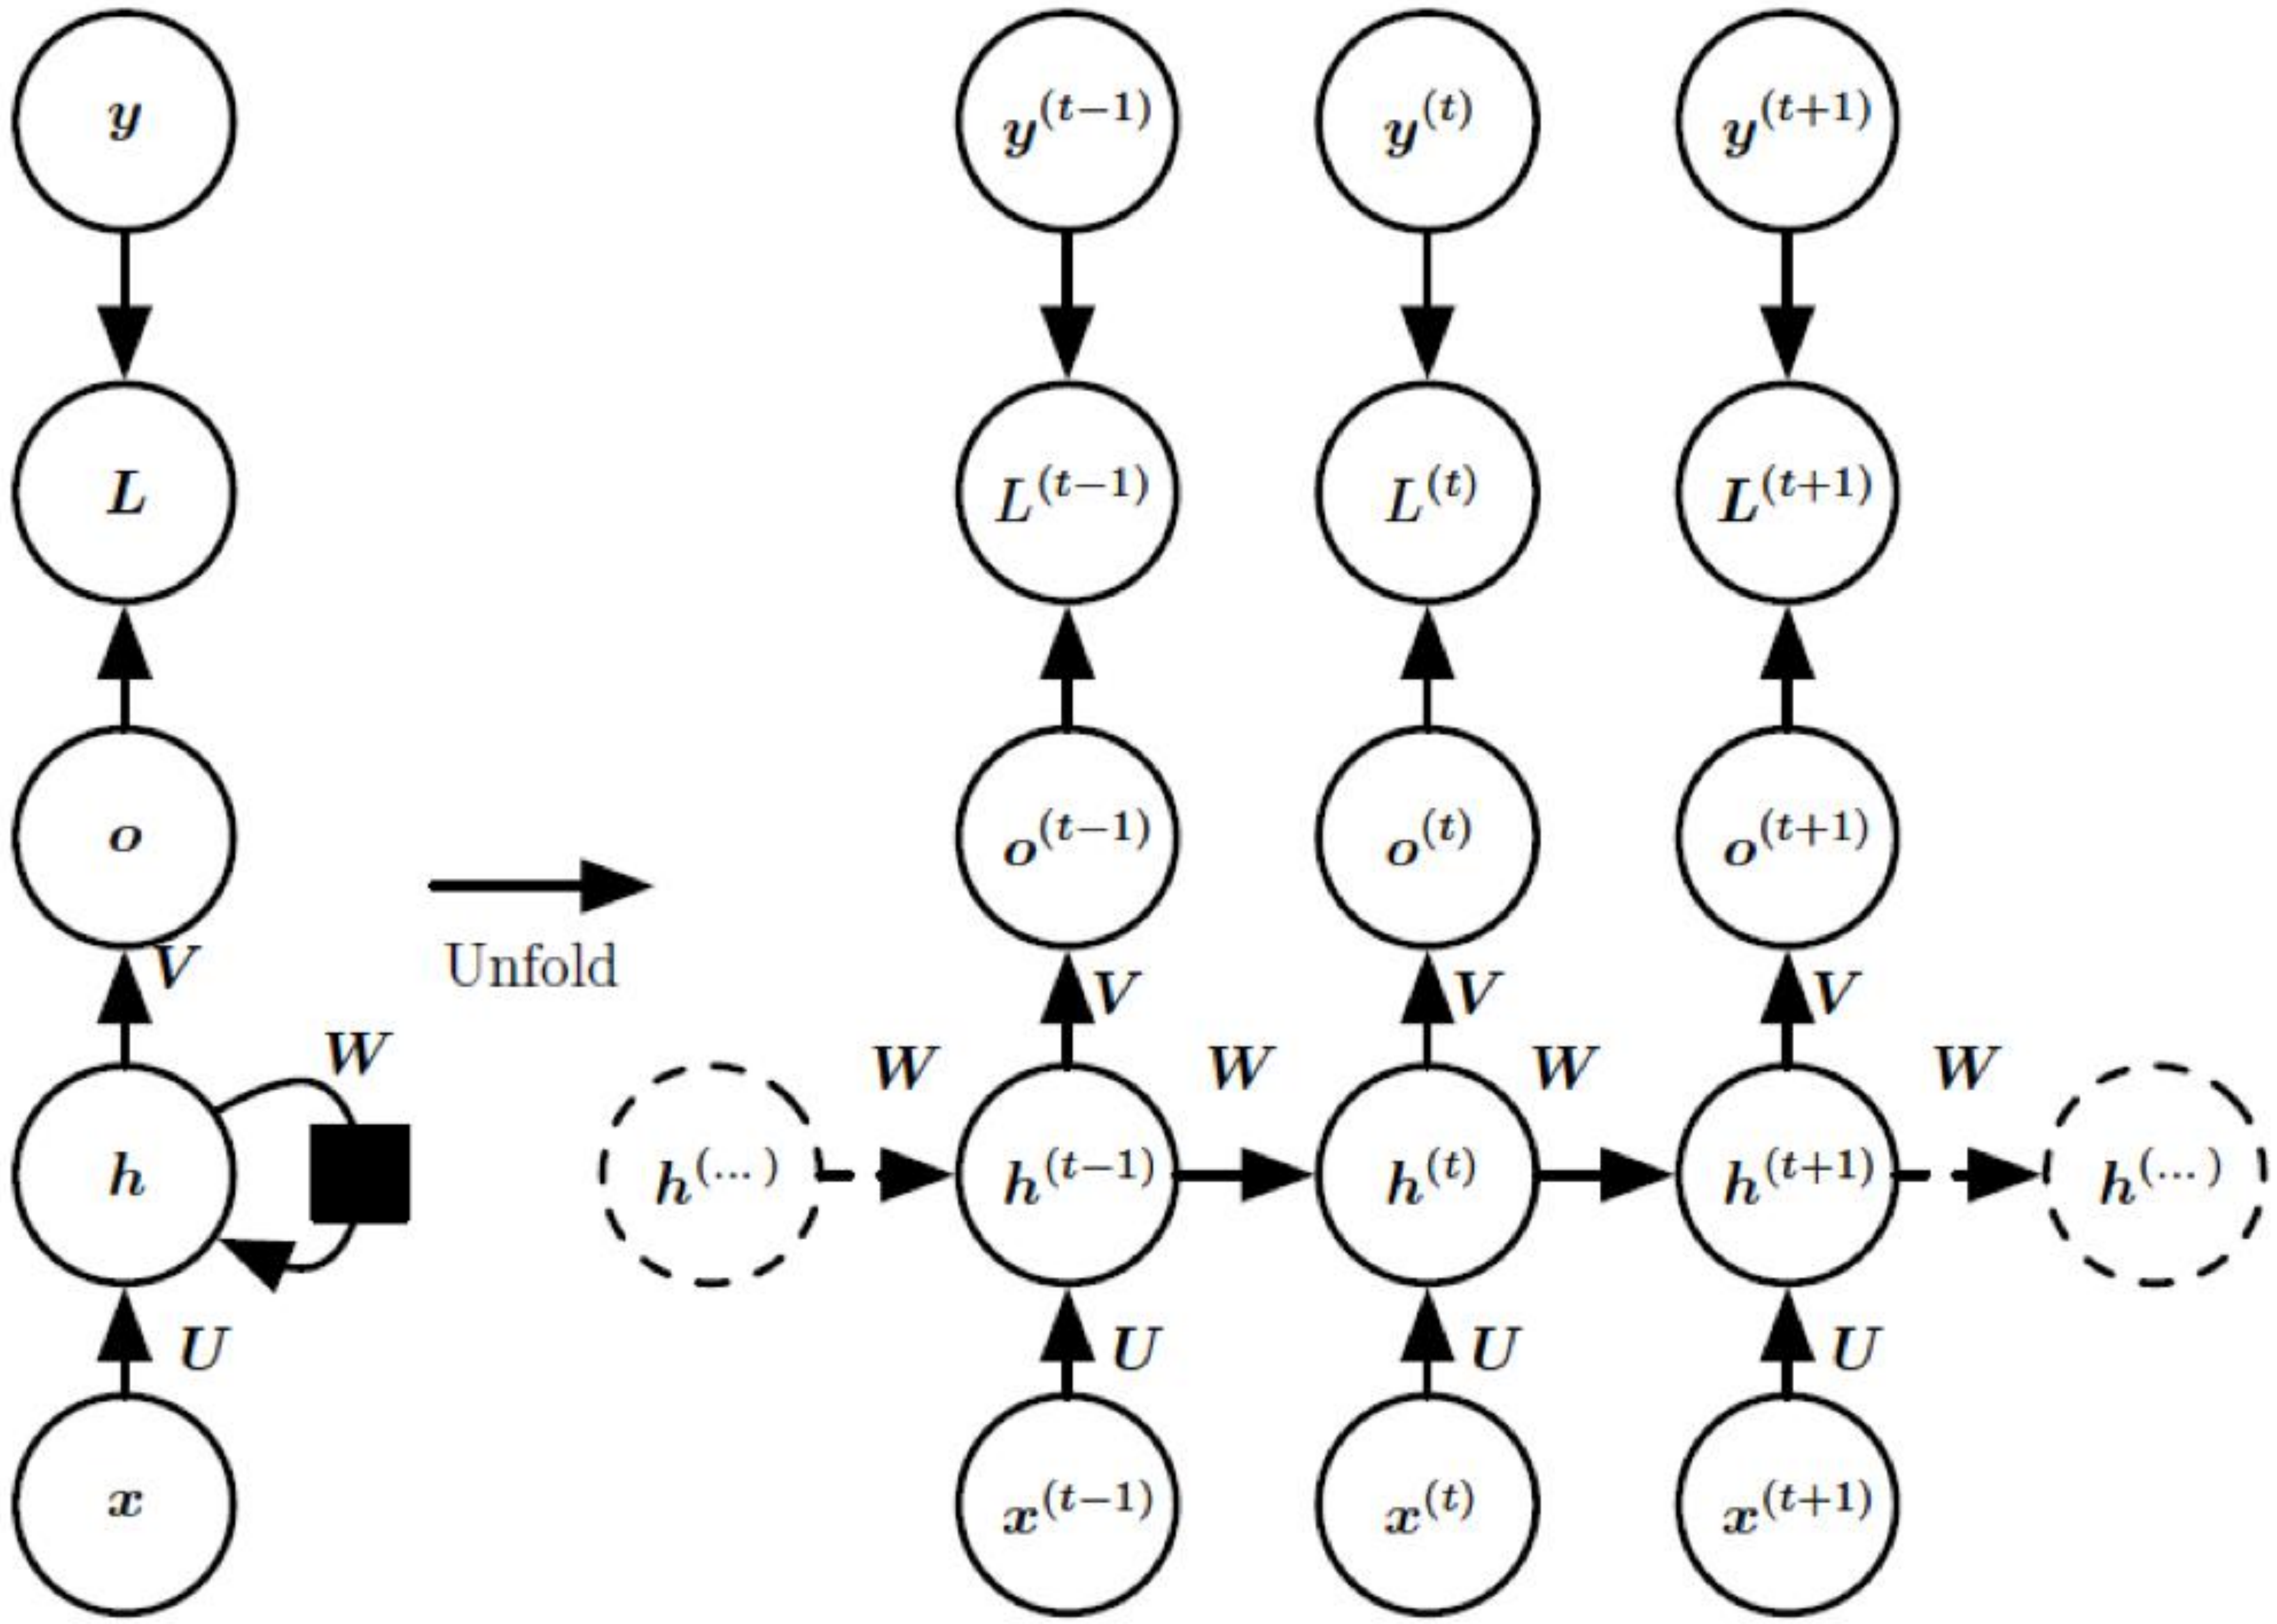

计算图

$$\boldsymbol{a}^{(t)} = \boldsymbol{b} + \boldsymbol{W}\boldsymbol{h}^{(t-1)} + \boldsymbol{U}\boldsymbol{x}^{(t)},$$

$$\boldsymbol{h}^{(t)} = \tanh(\boldsymbol{a}^{(t)}),$$

$$\boldsymbol{o}^{(t)} = \boldsymbol{c} + \boldsymbol{V}\boldsymbol{h}^{(t)},$$

$$\hat{\boldsymbol{y}}^{(t)} = \text{softmax}(\boldsymbol{o}^{(t)}),$$

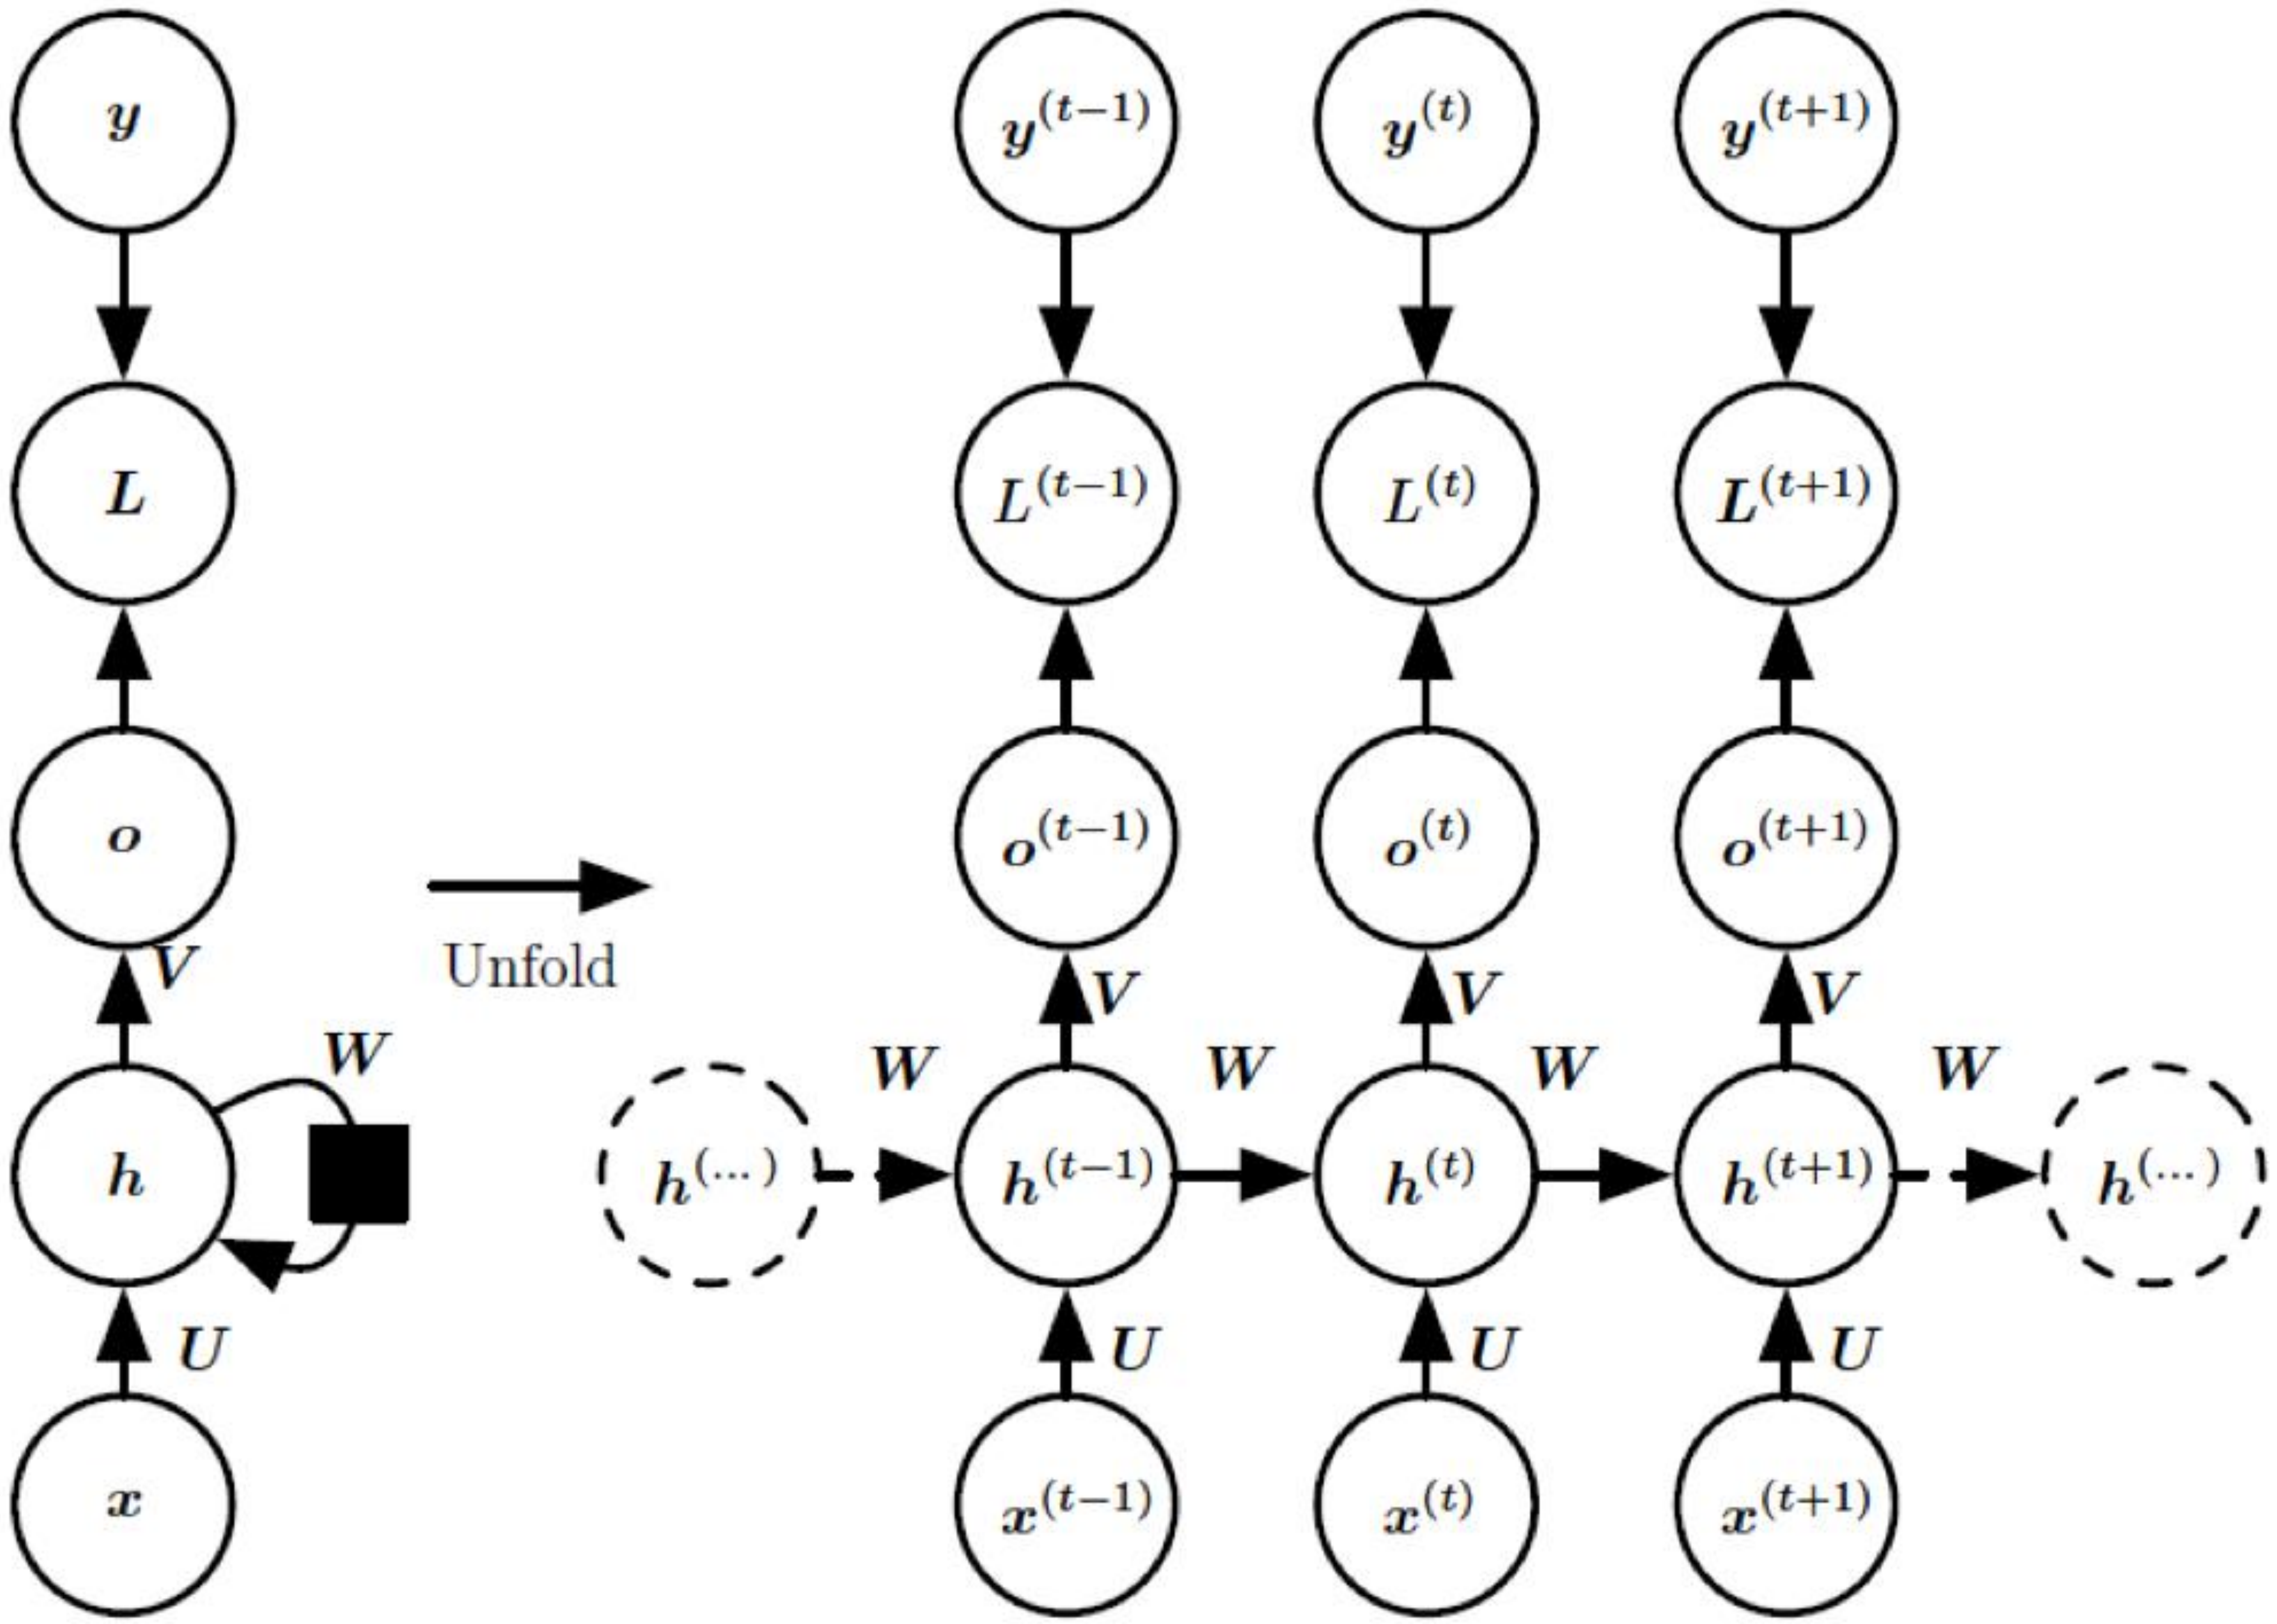

- 循环网络将一个输入序列映射到相同长度的输出序列。
- 信息流动路径：信息在时间上向前（计算输出和损失）和向后（计算梯度）的思想。
- U、V 和W分别对应于输入到隐藏、隐藏到输出和隐藏到隐藏的连接的权重矩阵。
- b 和c 是偏置向量。

basic-rnn 实现

```
iter: 646500, p: 1300, loss: 0.019042
----
 y = tf.get_variable("by", [vocab_size], initializer=initializer)
        by  = tf.get_variable("by", [vocab_size], dtype=tf.float32, name="state:
 hprev_val = np.zeros([1, hidden_size])

while True:
```

- Andrej Karpathy的min-char-rnn tf版本实现
- 实现了一个自动写代码的程序，输入程序就是本身

min-char-rnn-tensorflow.py

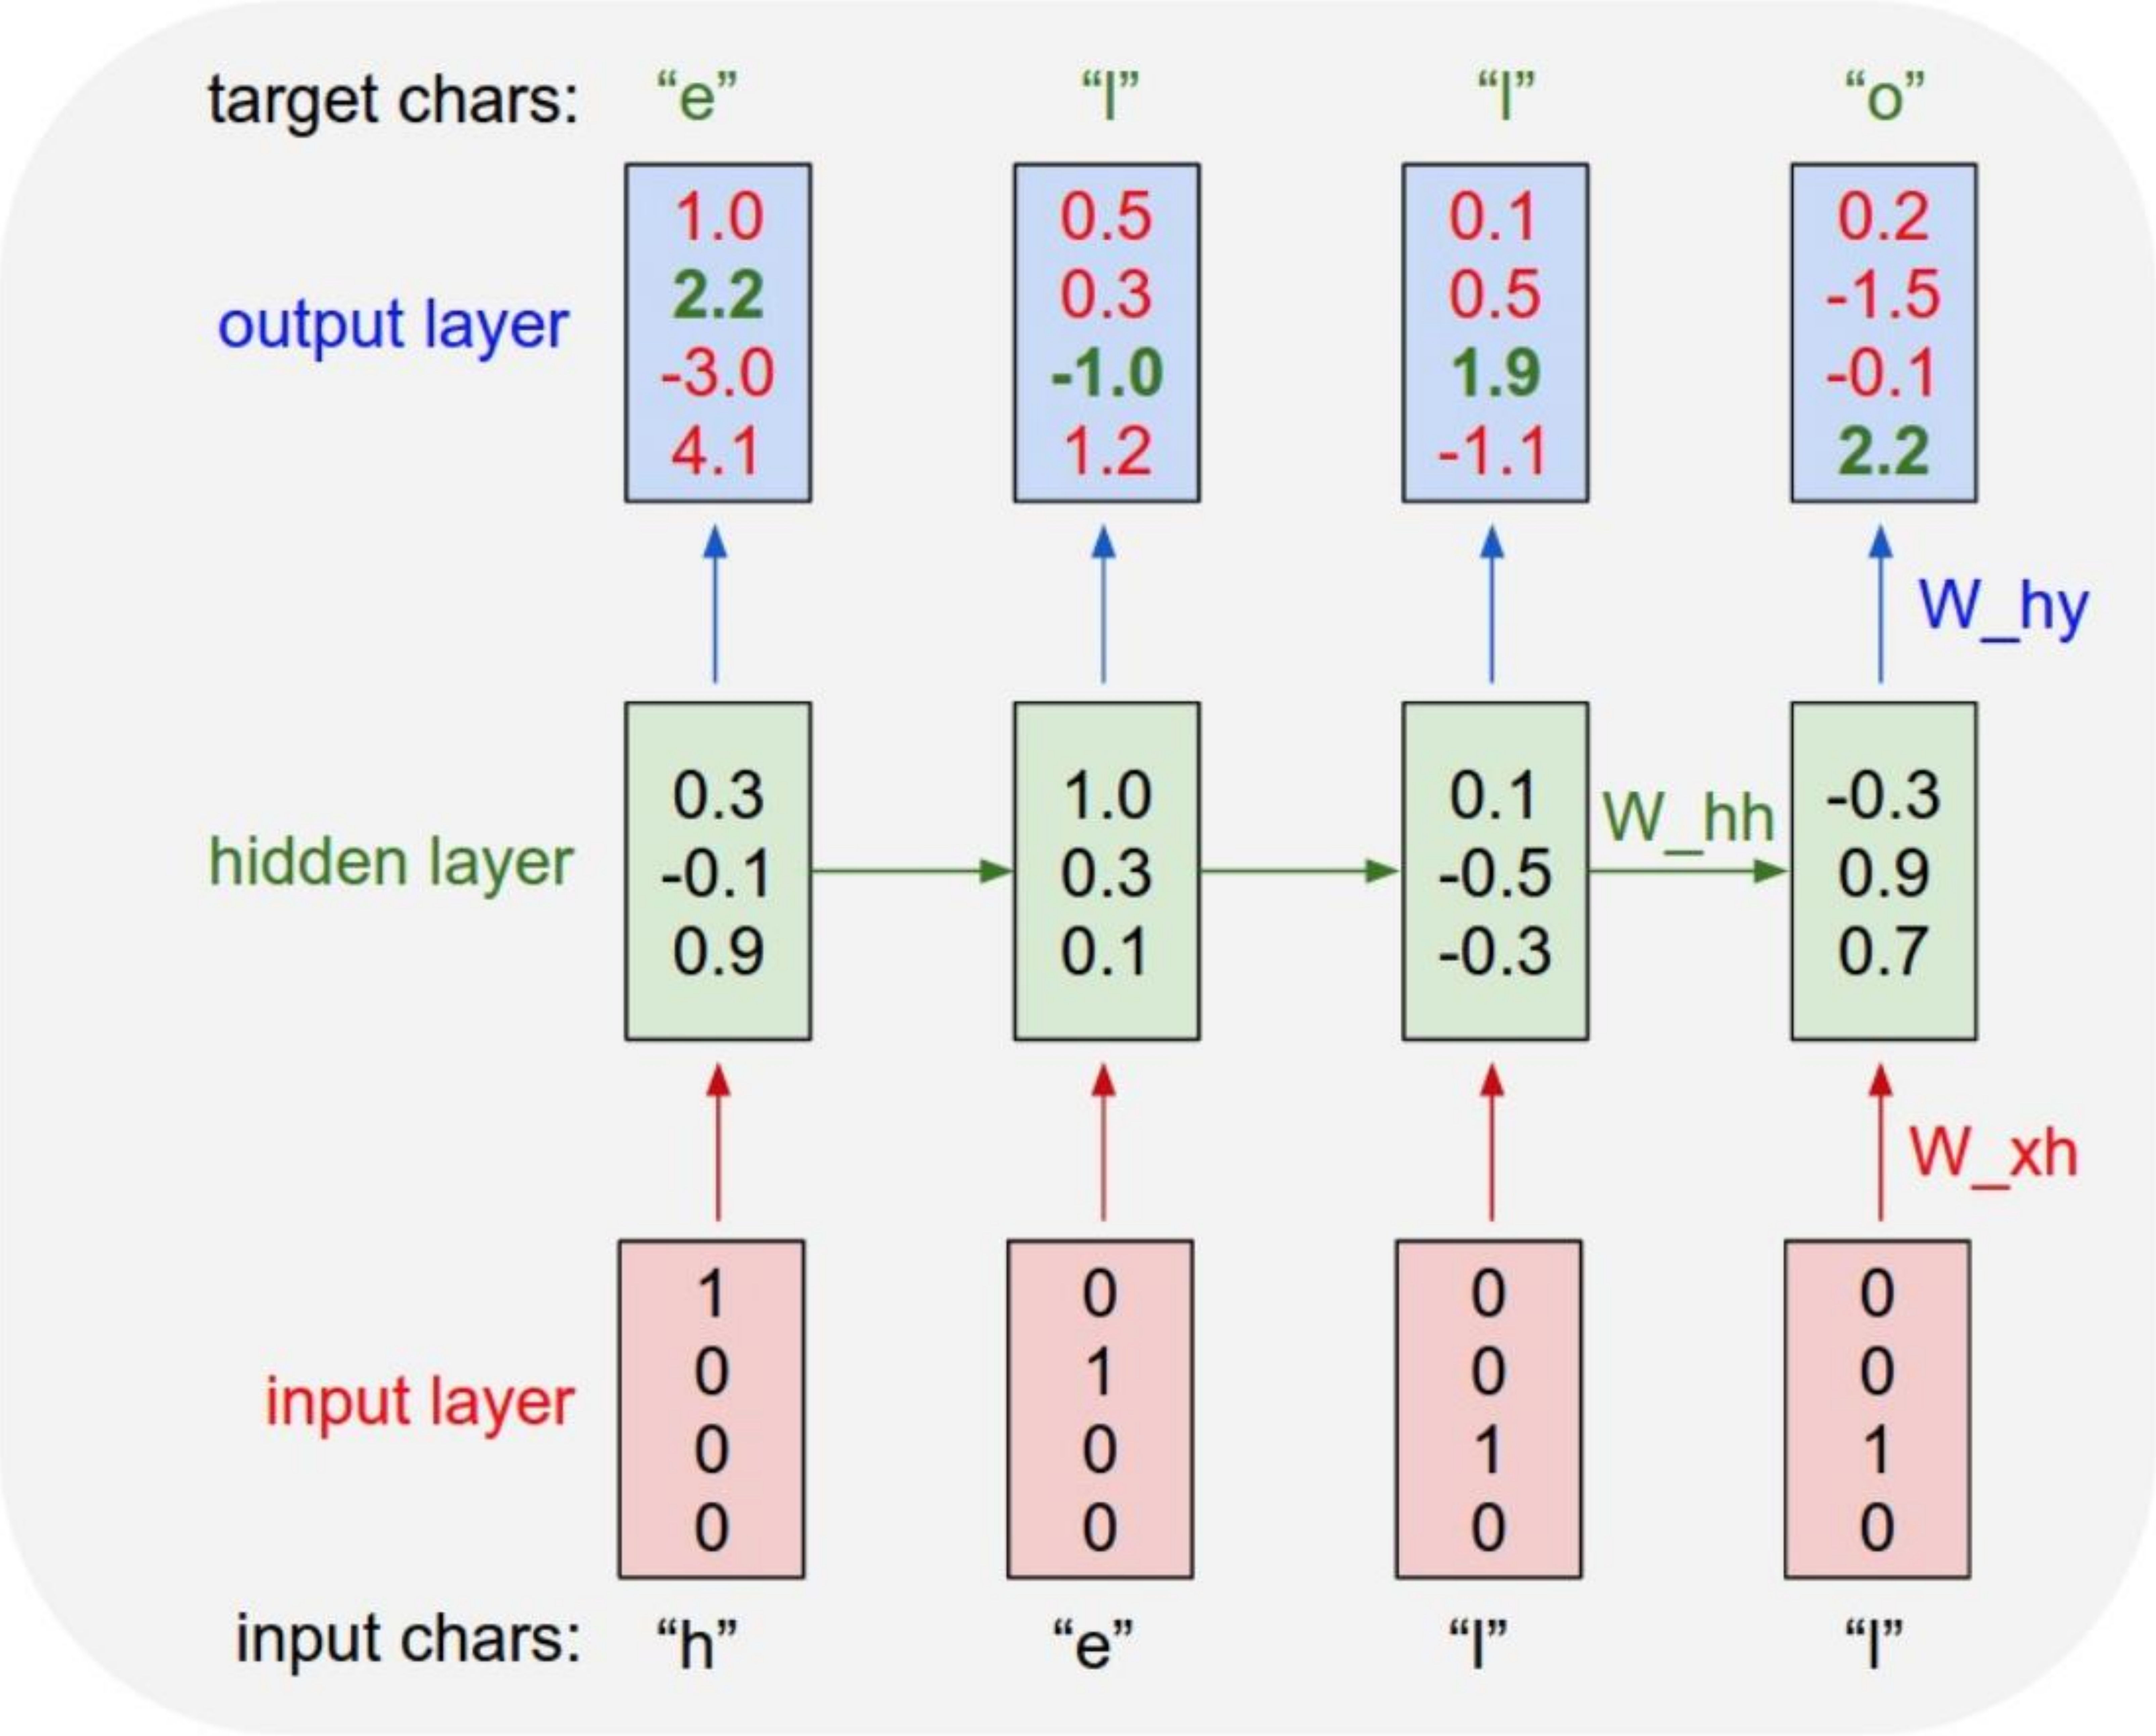

target chars: "e" "l" "l" "o"
output layer
1.0 2.2 -3.0 4.1
0.5 0.3 -1.0 1.2
0.1 0.5 1.9 -1.1
0.2 -1.5 -0.1 2.2
W_hy
hidden layer
0.3 -0.1 0.9
1.0 0.3 0.1
0.1 -0.5 -0.3
-0.3 0.9 0.7
W_hh
W_xh
input layer
1 0 0 0
0 1 0 0
0 0 1 0
0 0 1 0
input chars: "h" "e" "l" "l"

输入和loss处理

- 给定序列长度(模型超参数)，把输入序列化
- one-hot 离散化处理
- U, V, W 共享权重
- 收集所有时刻的输出,计算的loss
- 梯度截取预防梯度爆炸

$$
\begin{aligned}
& L\left(\{\boldsymbol{x}^{(1)}, \ldots, \boldsymbol{x}^{(\tau)}\}, \{\boldsymbol{y}^{(1)}, \ldots, \boldsymbol{y}^{(\tau)}\}\right) \\
&= \sum_t L^{(t)} \\
&= -\sum_t \log p_{\text{model}}\left(y^{(t)} \mid \{\boldsymbol{x}^{(1)}, \ldots, \boldsymbol{x}^{(t)}\}\right)
\end{aligned}
$$

rnn-cell抽象

```
__init__(
    num_units,
    activation=None,
    reuse=None,
    name=None
)
```

Cell超参数：num_units

```
__call__(
    inputs,
    state,
    scope=None,
    *args,
    **kwargs
)
```

调用时刻要输入state

```
tf.nn.static_rnn(
    cell,
    inputs,
    initial_state=None,
    dtype=None,
    sequence_length=None,
    scope=None
)
```

static-rnn抽象

```
state = cell.zero_state(...)
outputs = []
for input_ in inputs:
  output, state = cell(input_, state)
  outputs.append(output)
return (outputs, state)
```

rnn-example

tf.keras.layers.SimpleRNNCell

https://tensorflow.google.cn/api_docs/python/tf/contrib/rnn/BasicRNNCell

rnn-cell抽象

- hidden-units : 模型的容量大小
- I(input) + S(state) -> O(output) + S(new_state)
- inputs: 输入
- state: 隐含了之前所有的输出信息
- 当前的输出完全取决于state和当前的输入

keras.layers.RNN(cell)

- Class SimpleRNN
- Fully-connected RNN where the output is to be fed back to input.

https://tensorflow.google.cn/api_docs/python/tf/keras/layers/SimpleRNN

https://tensorflow.google.cn/api_docs/python/tf/keras/layers/RNN?hl=en

```
__init__(
    units,
    activation='tanh',
    use_bias=True,
    kernel_initializer='glorot_uniform',
    recurrent_initializer='orthogonal',
    bias_initializer='zeros',
    kernel_regularizer=None,
    recurrent_regularizer=None,
    bias_regularizer=None,
    activity_regularizer=None,
    kernel_constraint=None,
    recurrent_constraint=None,
    bias_constraint=None,
    dropout=0.0,
    recurrent_dropout=0.0,
    return_sequences=False,
    return_state=False,
    go_backwards=False,
    stateful=False,
    unroll=False,
    **kwargs
)
```

课后作业

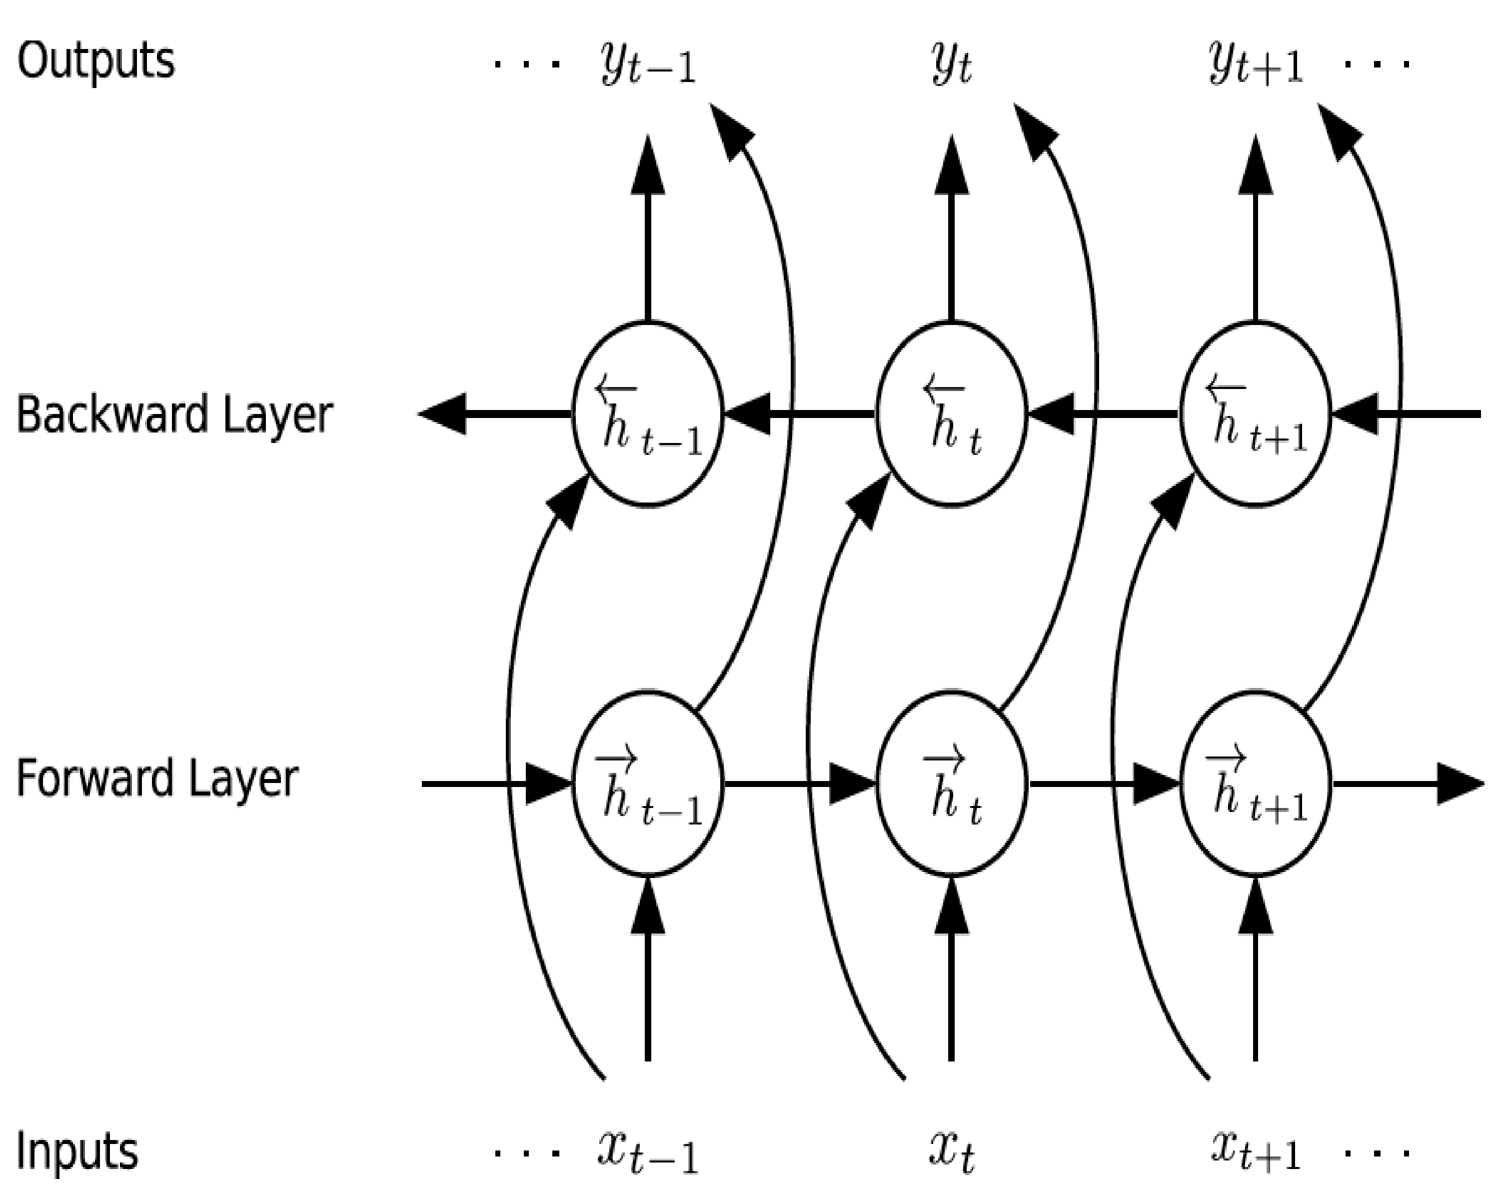

$$\overrightarrow{h}_t = \mathcal{H}\left(W_{x\overrightarrow{h}}x_t + W_{\overrightarrow{h}\overrightarrow{h}}\overrightarrow{h}_{t-1} + b_{\overrightarrow{h}}\right)$$

$$\overleftarrow{h}_t = \mathcal{H}\left(W_{x\overleftarrow{h}}x_t + W_{\overleftarrow{h}\overleftarrow{h}}\overleftarrow{h}_{t+1} + b_{\overleftarrow{h}}\right)$$

$$y_t = W_{\overrightarrow{h}y}\overrightarrow{h}_t + W_{\overleftarrow{h}y}\overleftarrow{h}_t + b_y$$

- [x] Alex Graves et al., Speech recognition with deep recurrent neural networks, ICASSP 2013.

RNN & LSTM

LSTM

- RNN训练有以下问题
  - RNN梯度爆炸
  - RNN梯度消失
- LSTM解决以上问题

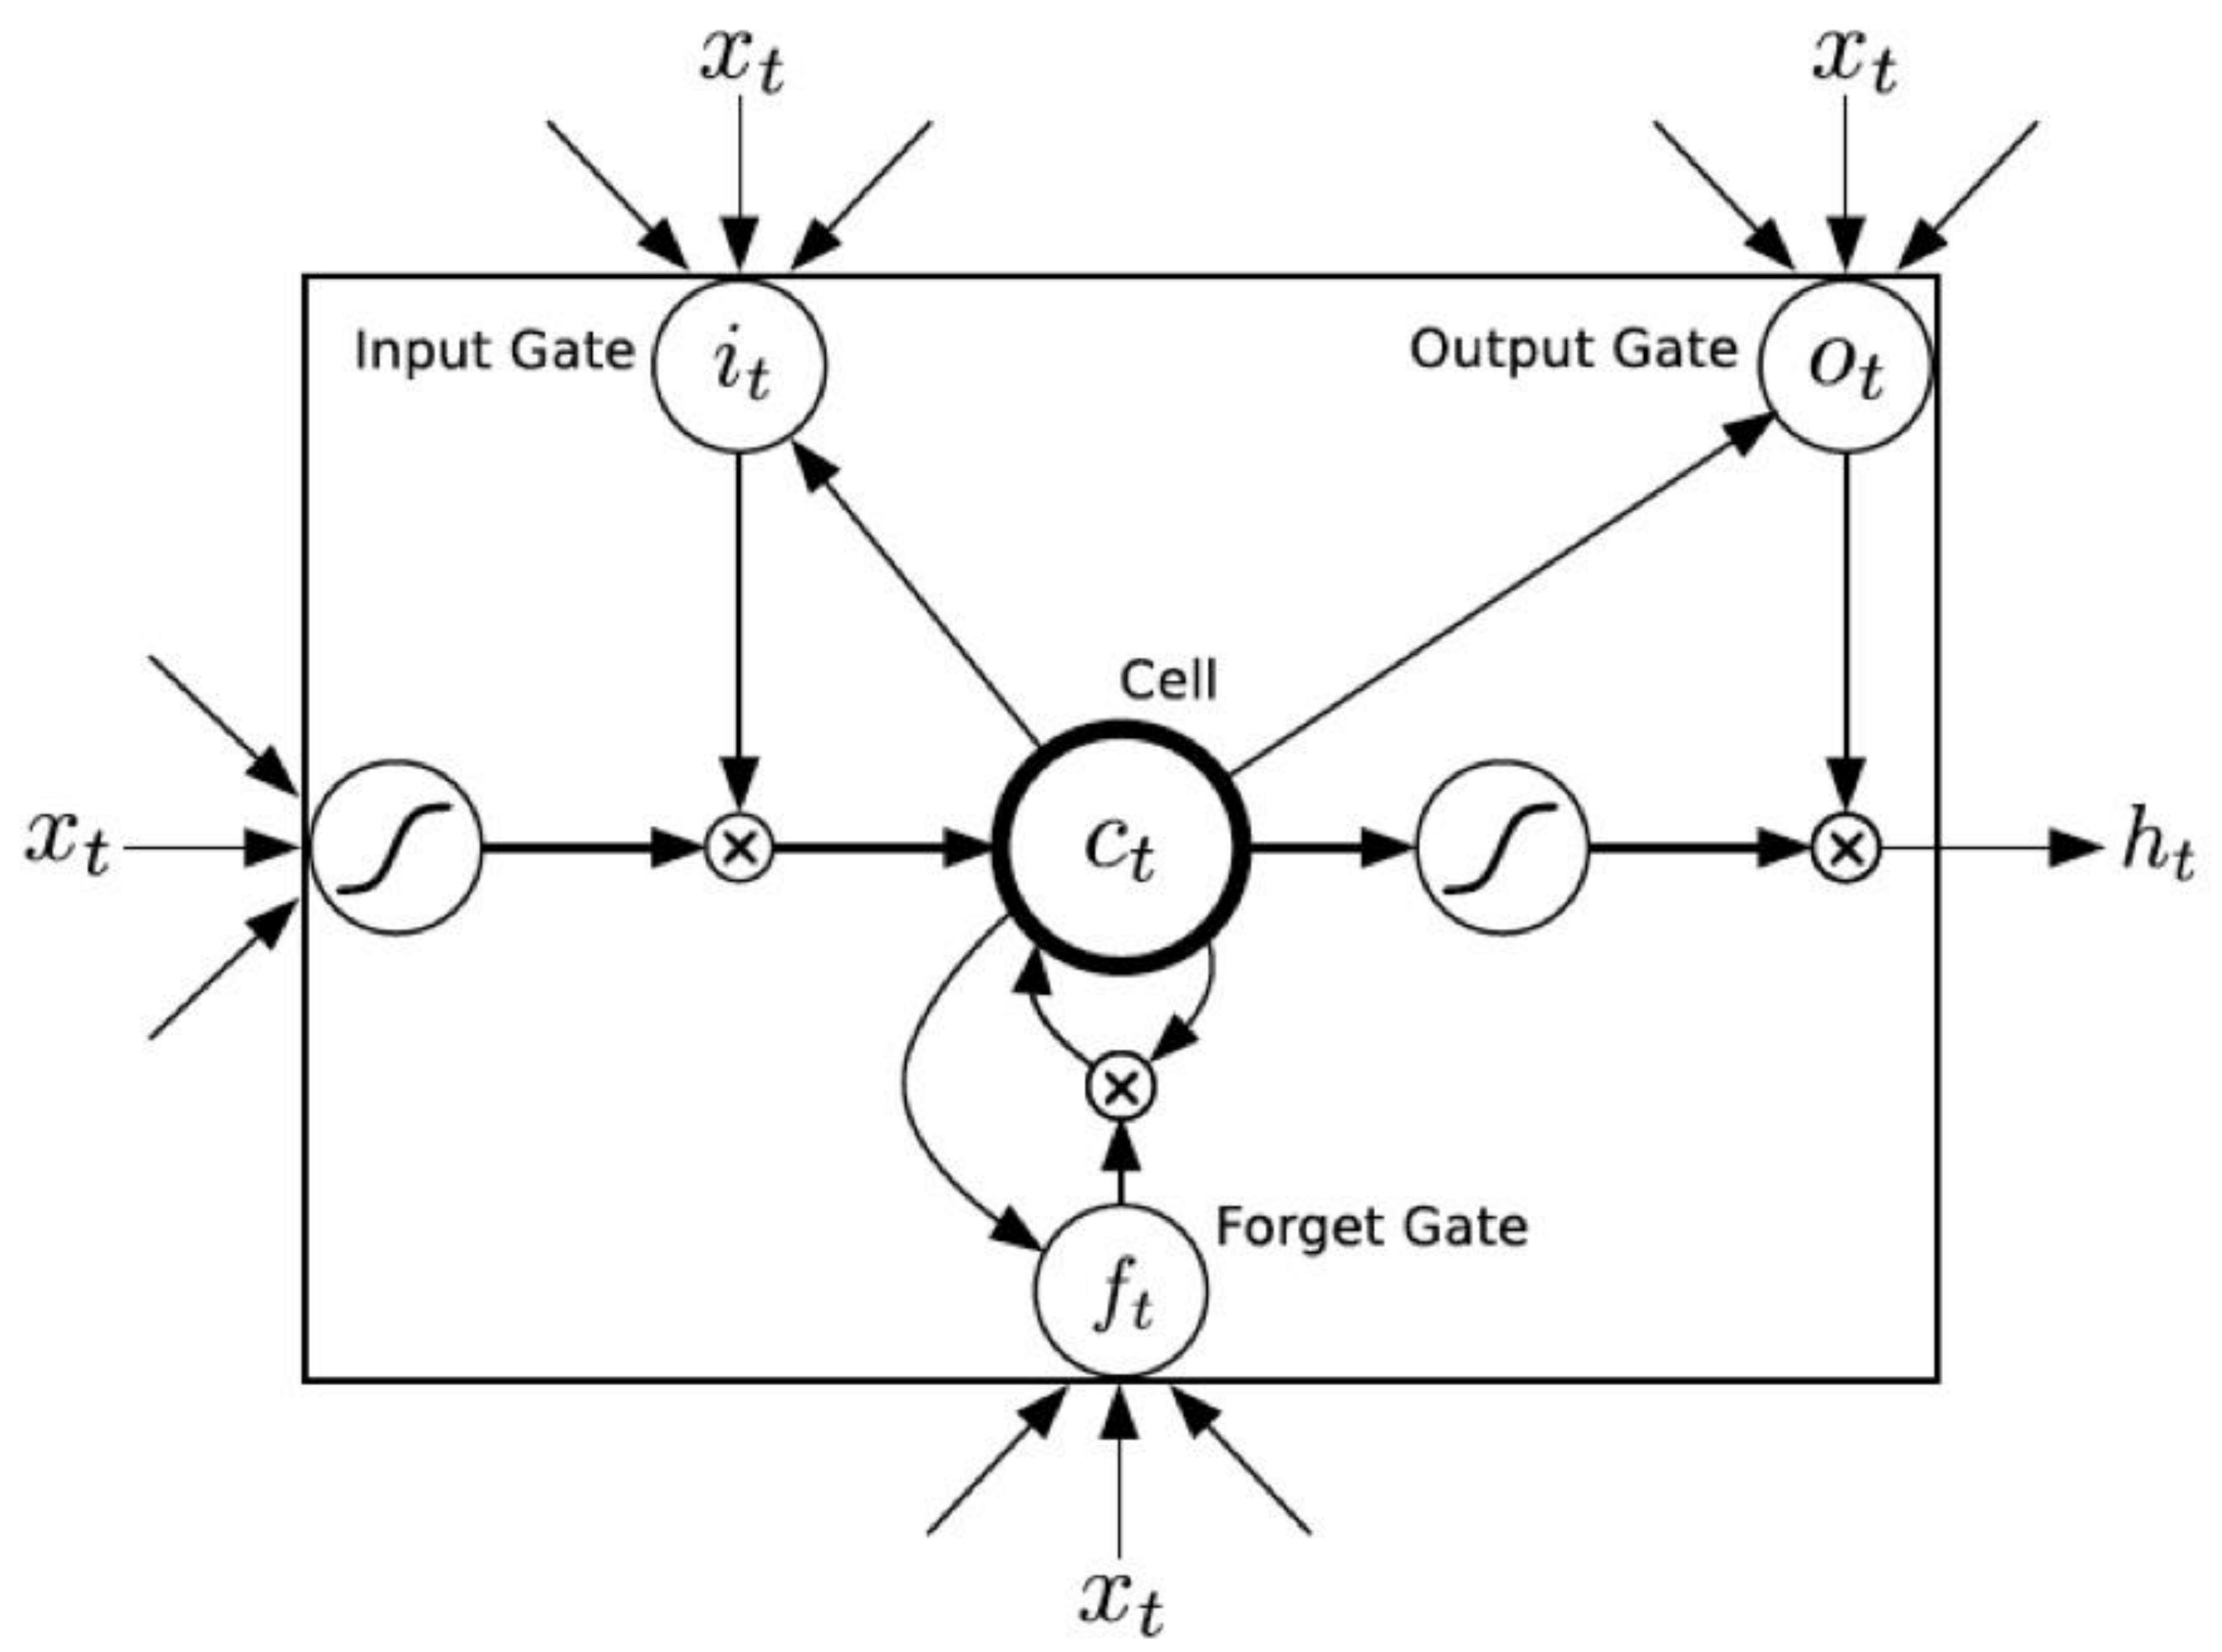

https://distill.pub/2019/memorization-in-rnns/

门电路

- Input和Control形状一致
- Control经过Sigmoid函数后，变成一个范围在0-1之间的一个同形状的Tensor
- Input和σ（Control）元素相乘等到一个同形的Output

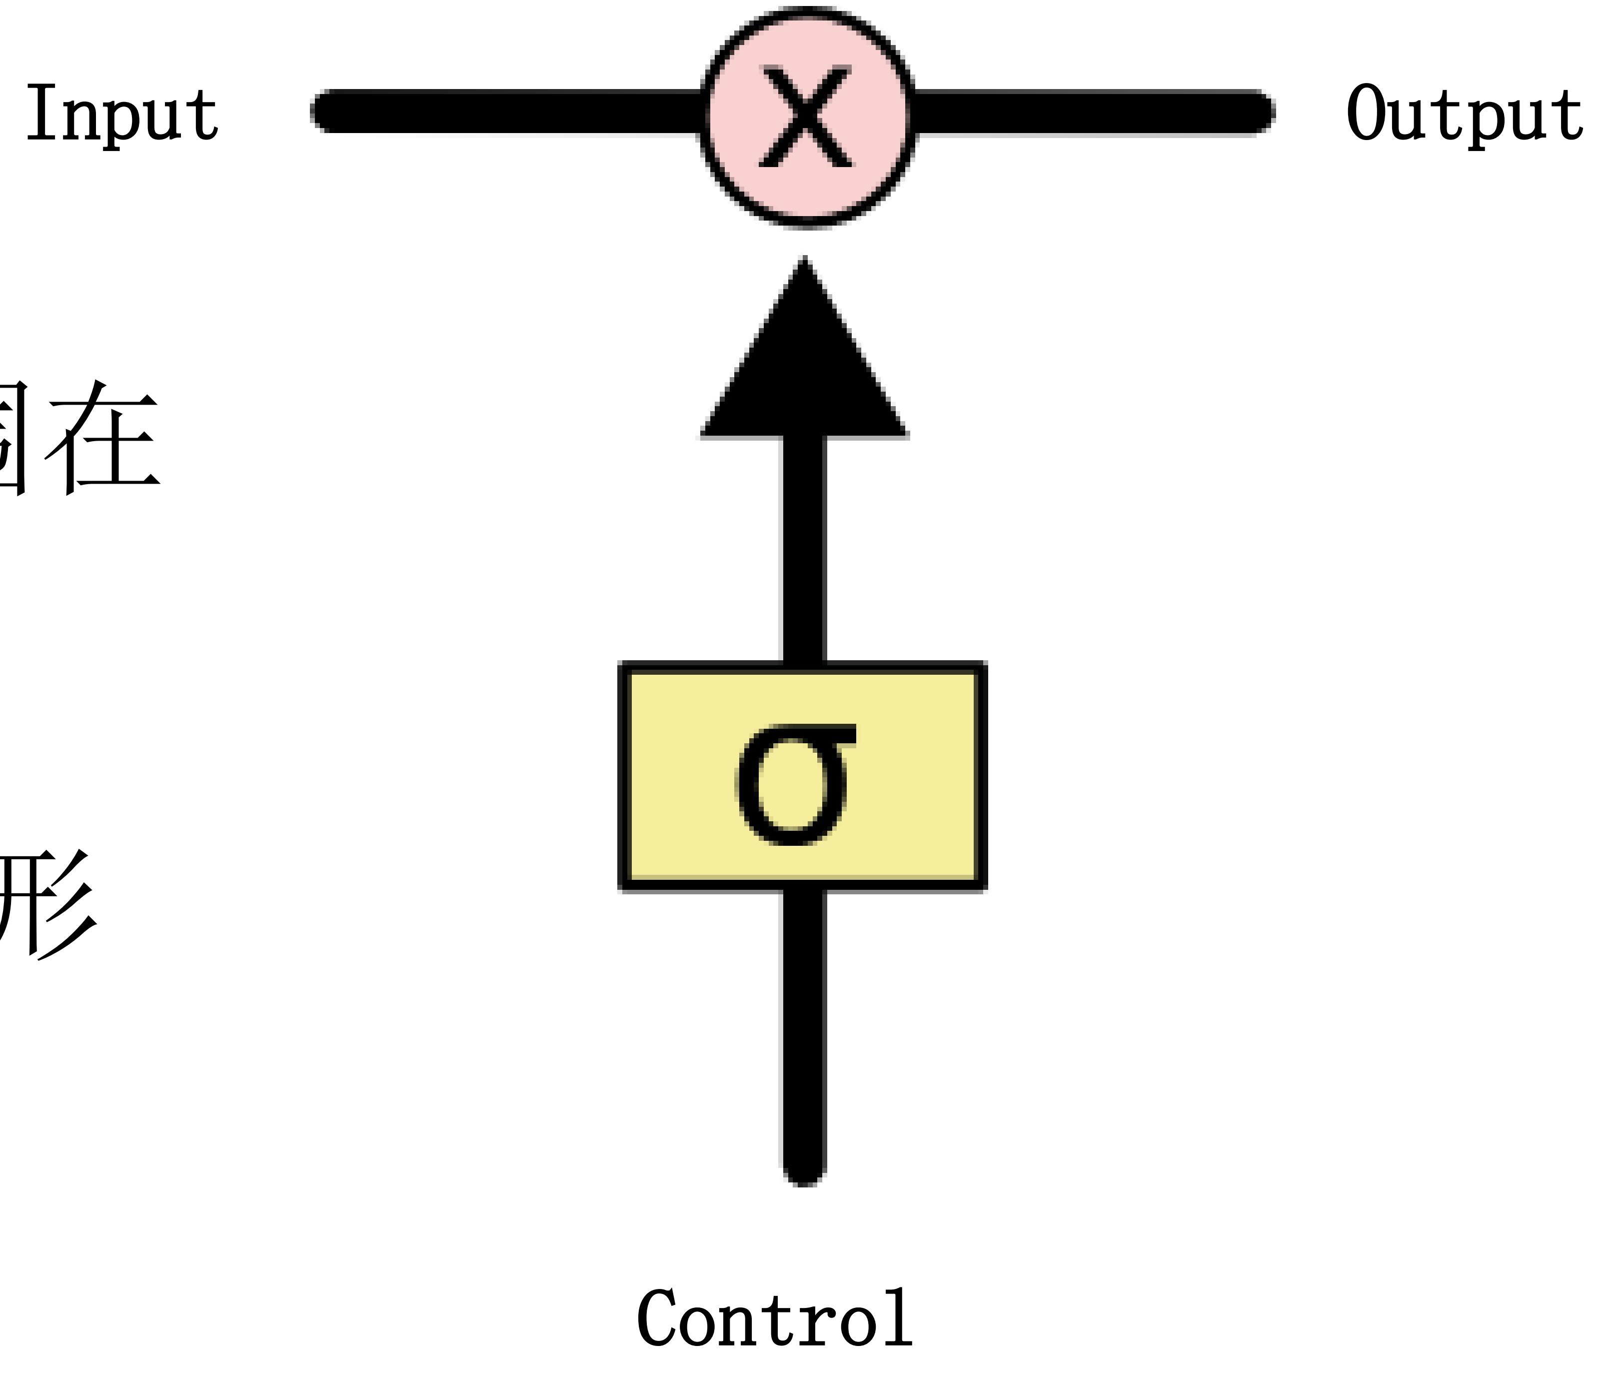

LSTM

- LSTM是RNN的一个改进，LSTM增加了一个辅助记忆单元和其他三个辅助的门限输入单元。
- 输入门（Input gate）控制是否输入，遗忘门（Forget gate）控制是否存储，输出门（Output gate）控制是否输出。
- 辅助记忆单元可以寄存时间序列的输入，在训练过程中会利用后向传播的方式进行。
- 记忆单元和门单元的组合，提升了RNN处理远距离依赖问题的能力 ，解决RNN网络收敛慢的问题。

RNN与LSTM

- RNN

$$h_t = \mathcal{H}\left(W_{xh}x_t + W_{hh}h_{t-1} + b_h\right) \quad (1)$$

$$y_t = W_{hy}h_t + b_y \quad (2)$$

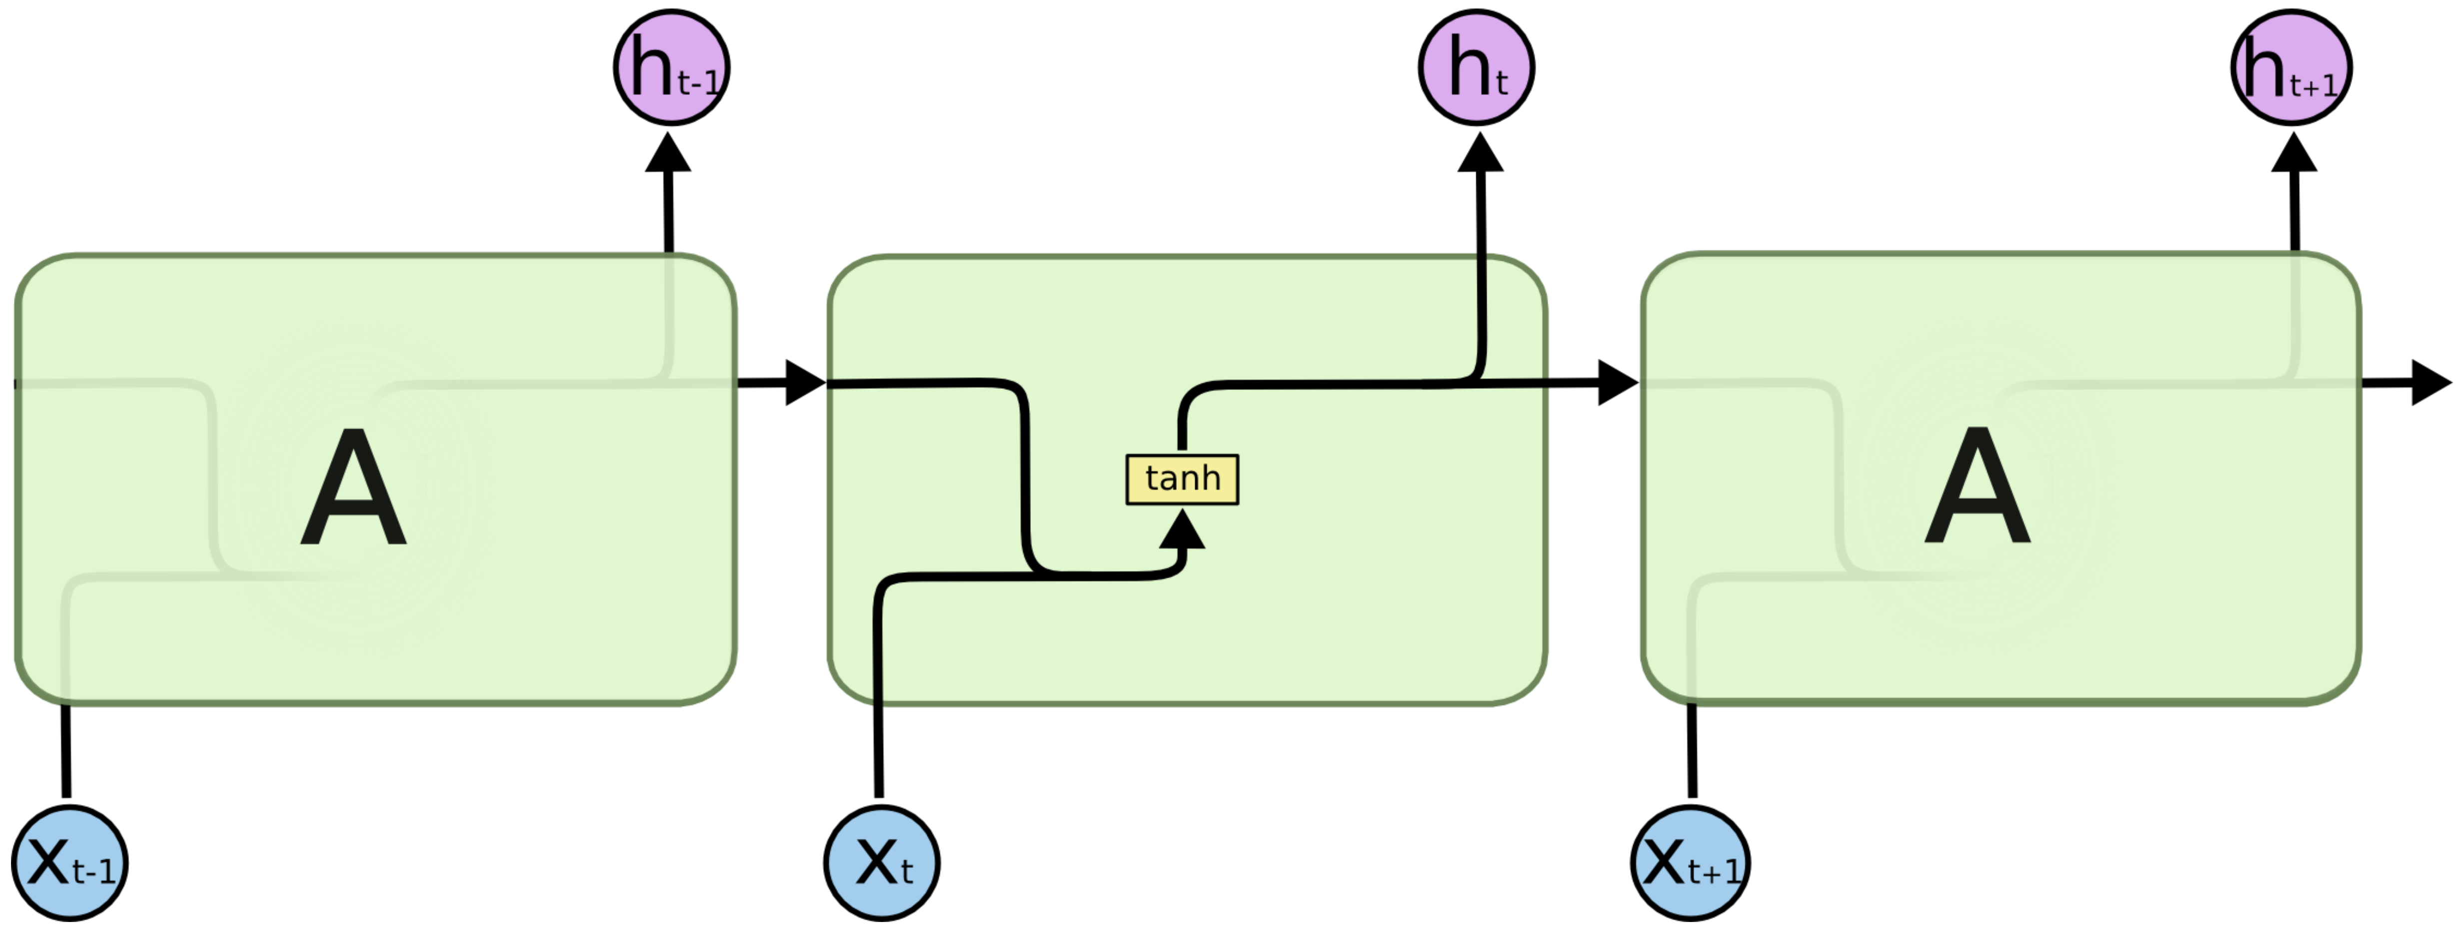

- LSTM

$$i_t = \sigma\left(W_{xi}x_t + W_{hi}h_{t-1} + W_{ci}c_{t-1} + b_i\right) \quad (3)$$

$$f_t = \sigma\left(W_{xf}x_t + W_{hf}h_{t-1} + W_{cf}c_{t-1} + b_f\right) \quad (4)$$

$$c_t = f_t c_{t-1} + i_t \tanh\left(W_{xc}x_t + W_{hc}h_{t-1} + b_c\right) \quad (5)$$

$$o_t = \sigma\left(W_{xo}x_t + W_{ho}h_{t-1} + W_{co}c_t + b_o\right) \quad (6)$$

$$h_t = o_t \tanh(c_t) \quad (7)$$

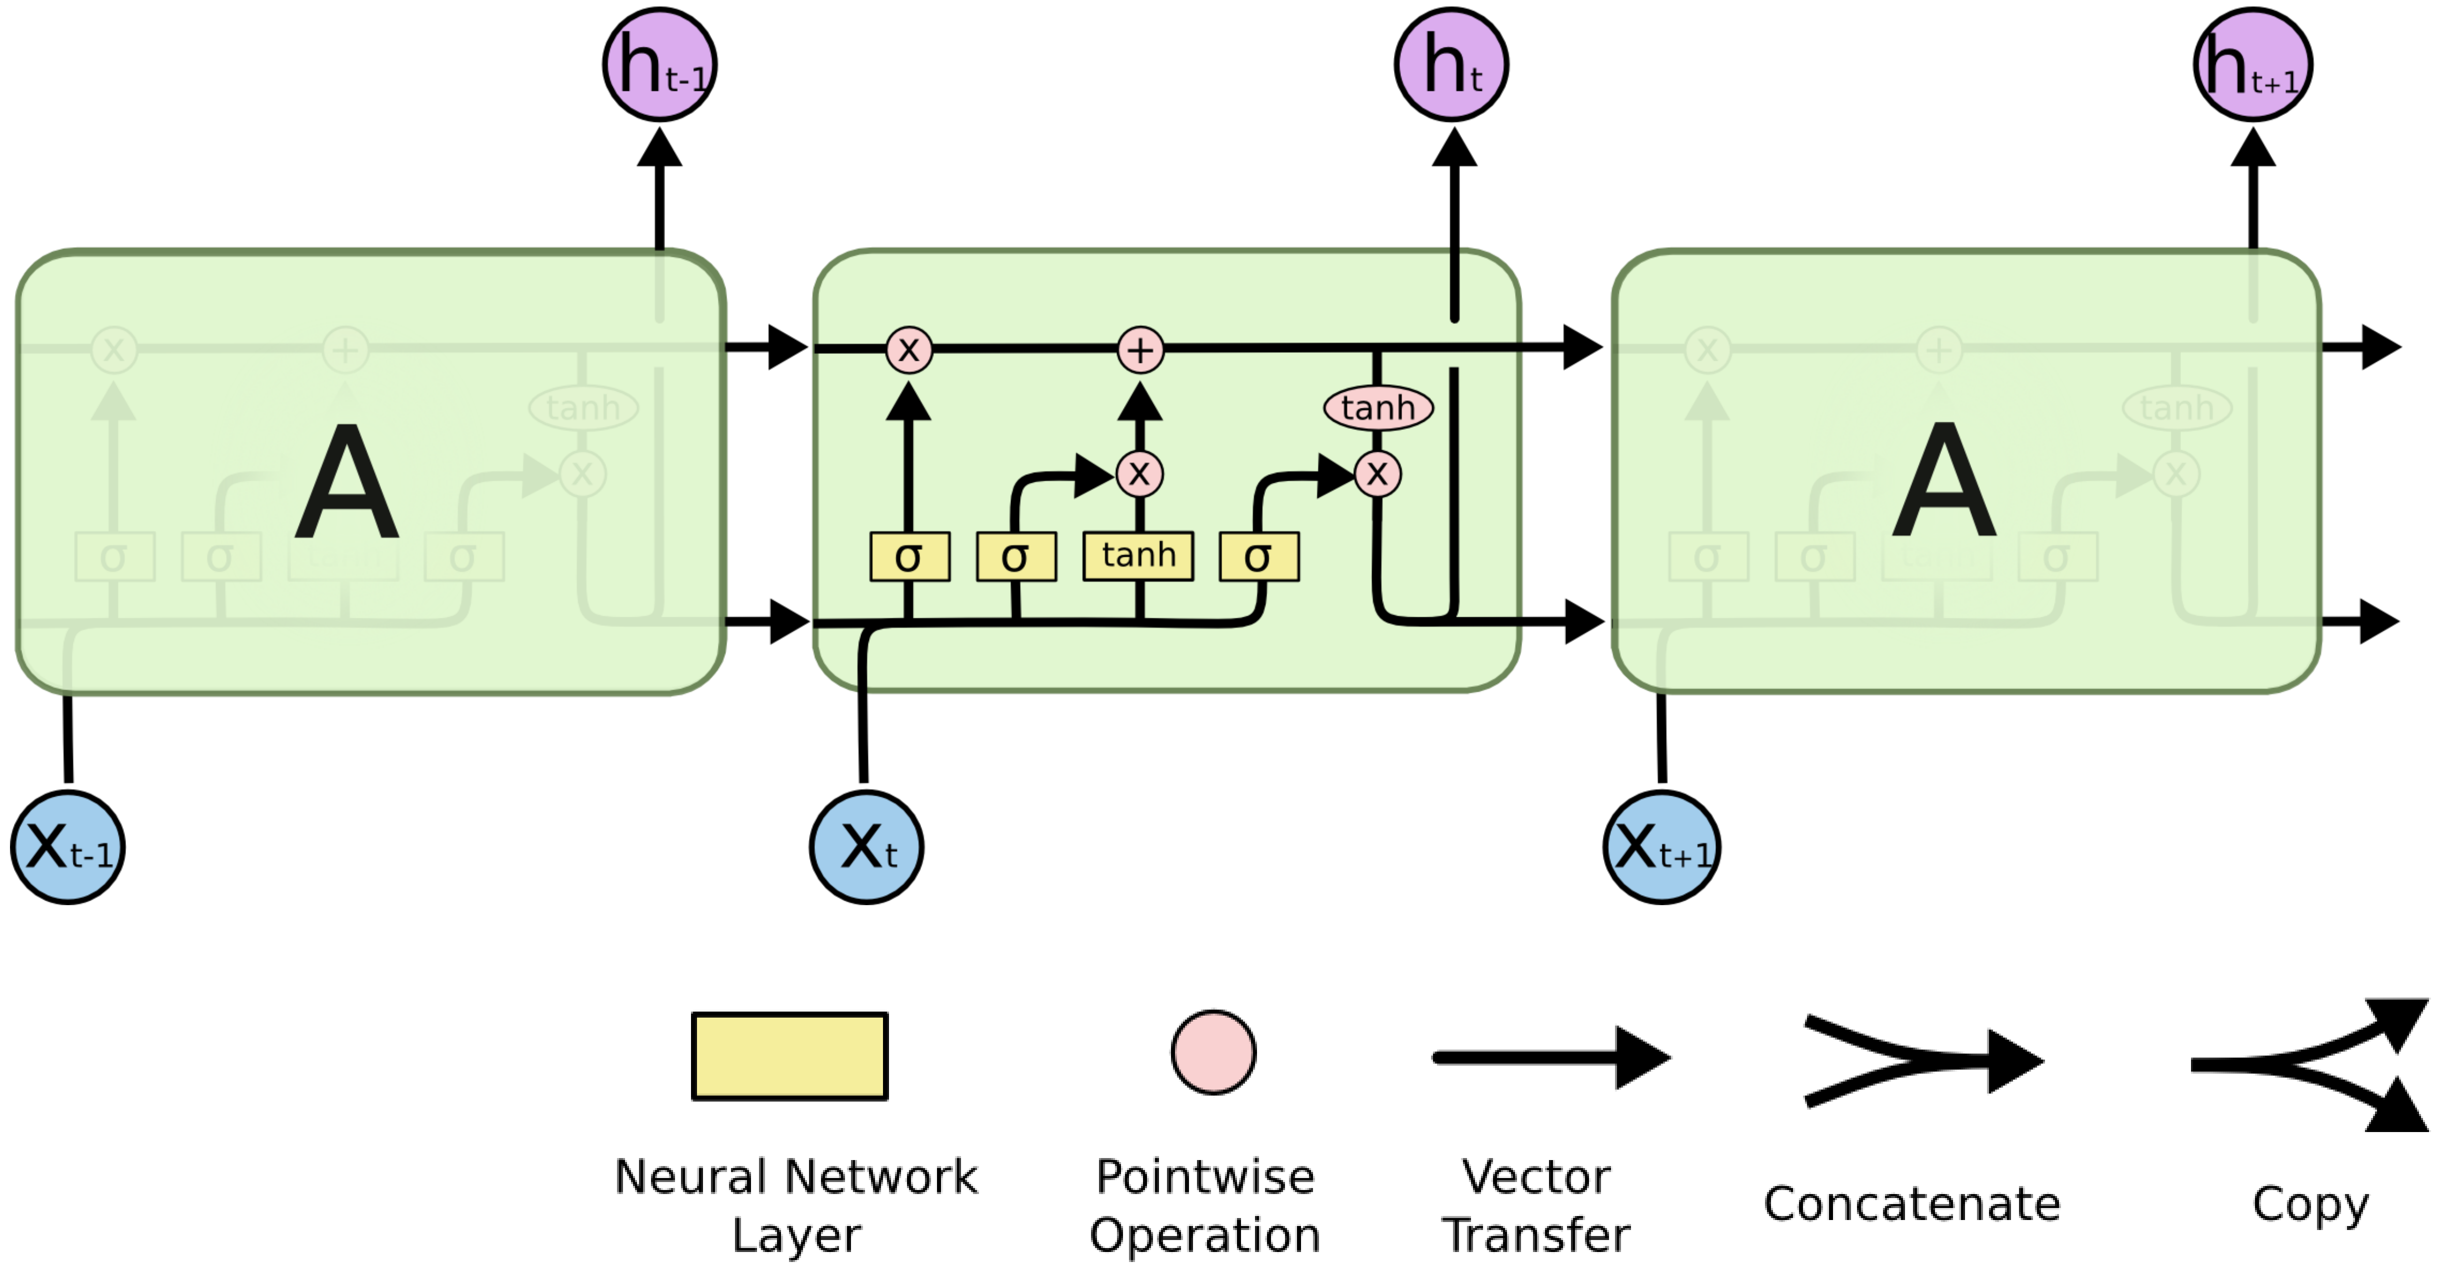

Understanding-LSTMs, http://colah.github.io/posts/2015-08-Understanding-LSTMs/

LSTMCell

- LSTM internal

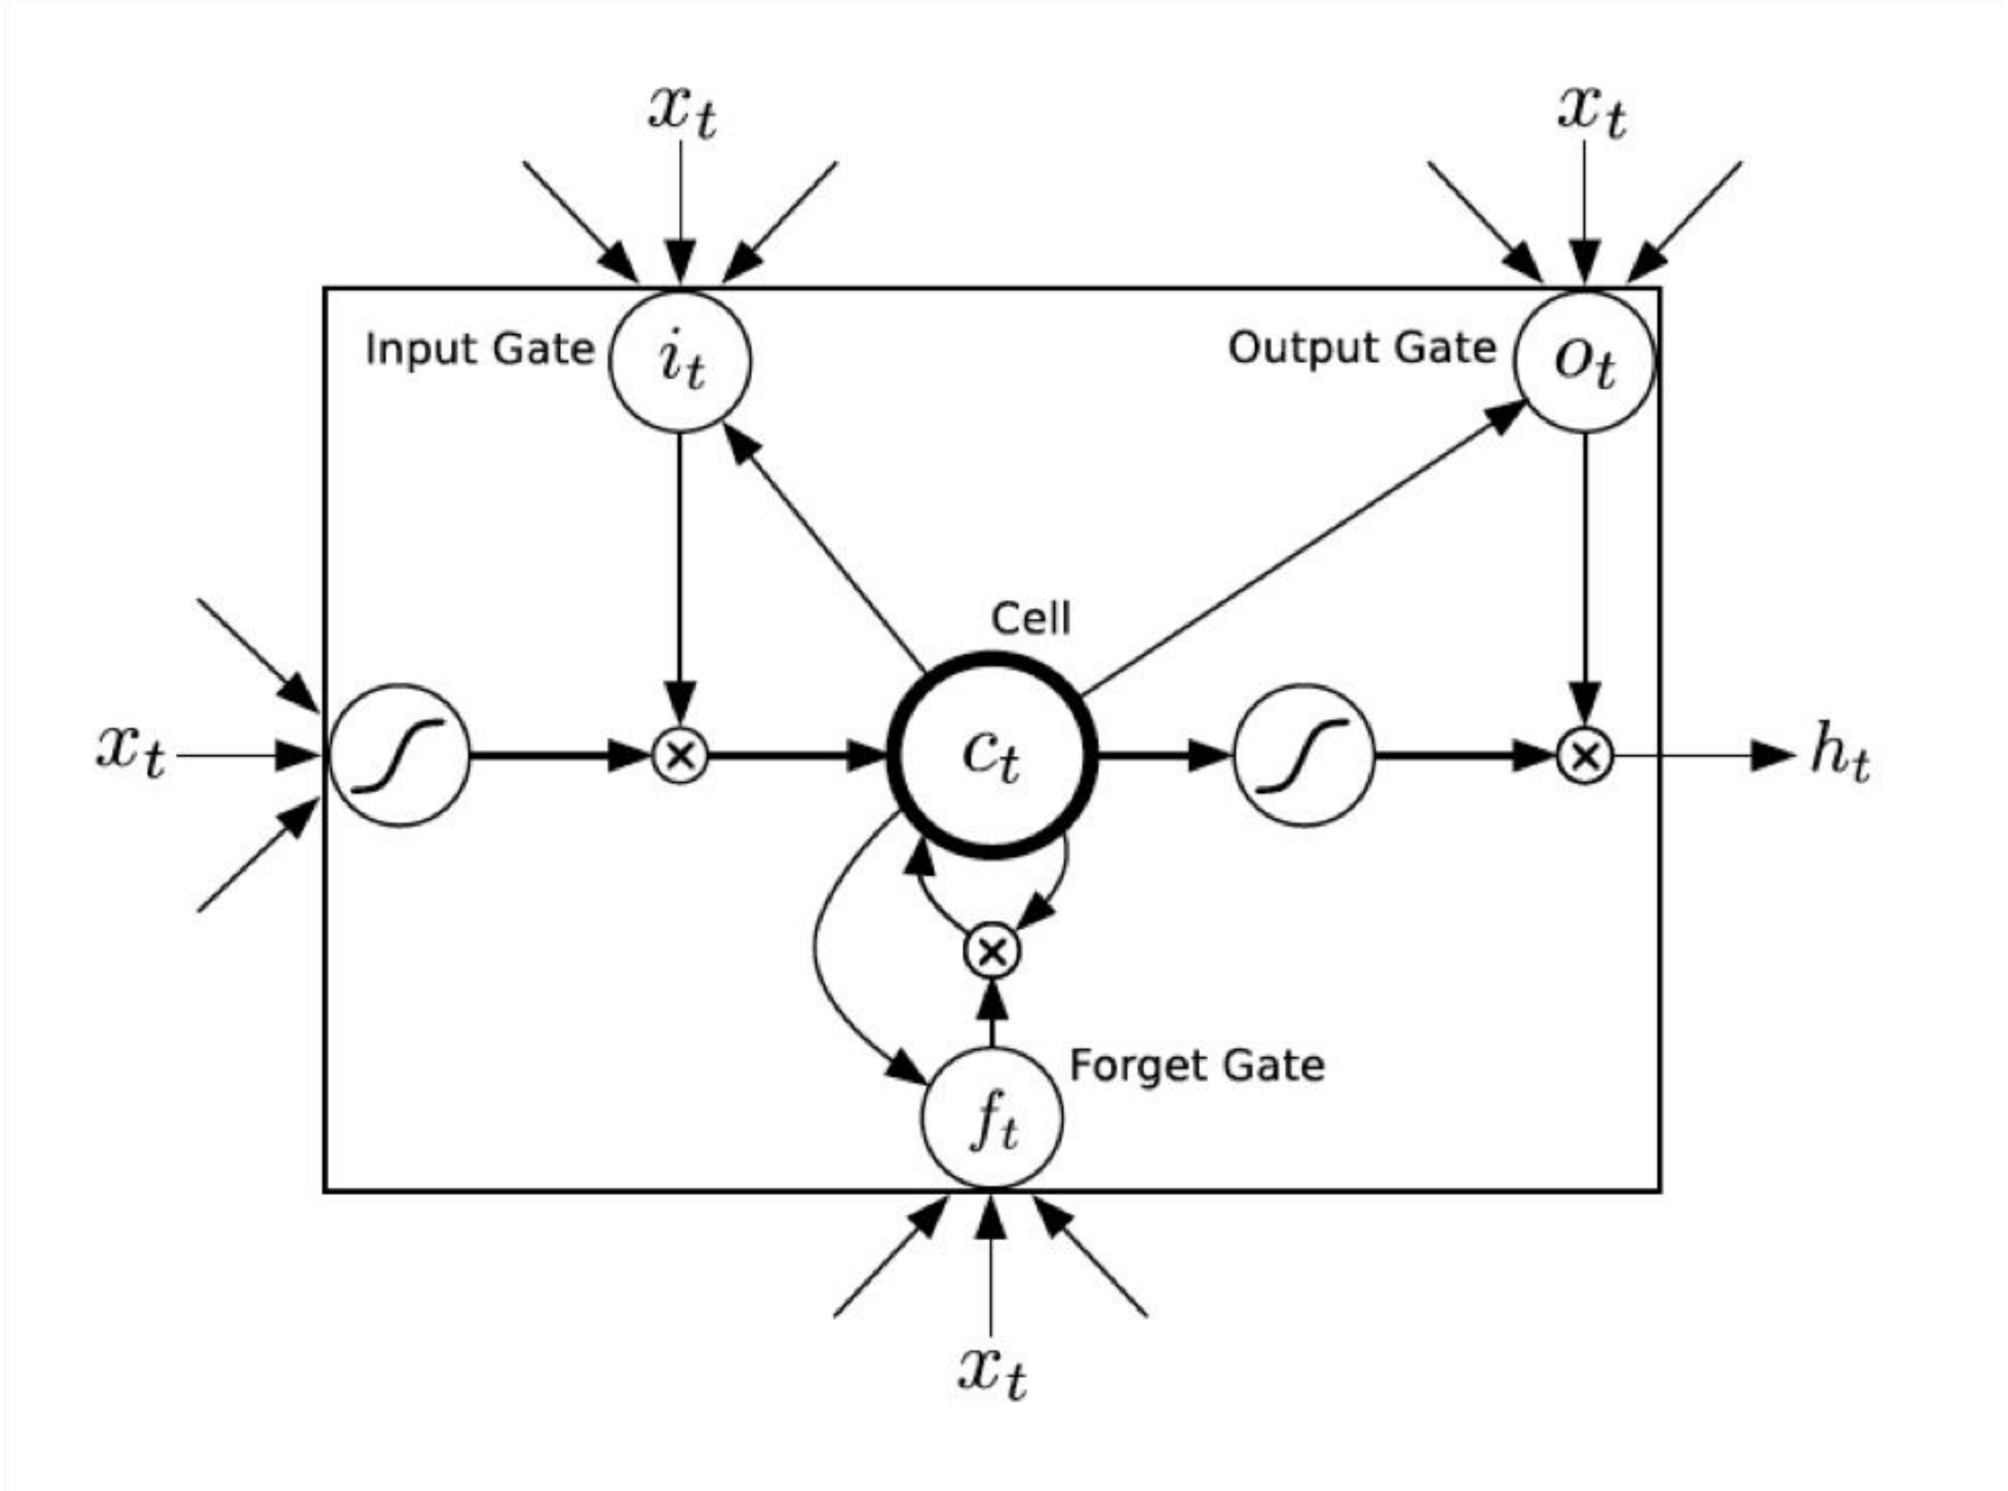


```
__init__(
    units,
    activation='tanh',
    recurrent_activation='sigmoid',
    use_bias=True,
    kernel_initializer='glorot_uniform',
    recurrent_initializer='orthogonal',
    bias_initializer='zeros',
    unit_forget_bias=True,
    kernel_regularizer=None,
    recurrent_regularizer=None,
    bias_regularizer=None,
    kernel_constraint=None,
    recurrent_constraint=None,
    bias_constraint=None,
    dropout=0.0,
    recurrent_dropout=0.0,
    implementation=2,
    **kwargs
)
```

https://tensorflow.google.cn/api_docs/python/tf/keras/layers/LSTM?hl=en

GRU

- Gated Recurrent Unit (GRU)
- 组合遗忘门（forget gates）和输入门（input gates）为单一的更新门（Update gates）
- 合并LSTM的cell状态（ cell state ）和隐藏态（hidden state）

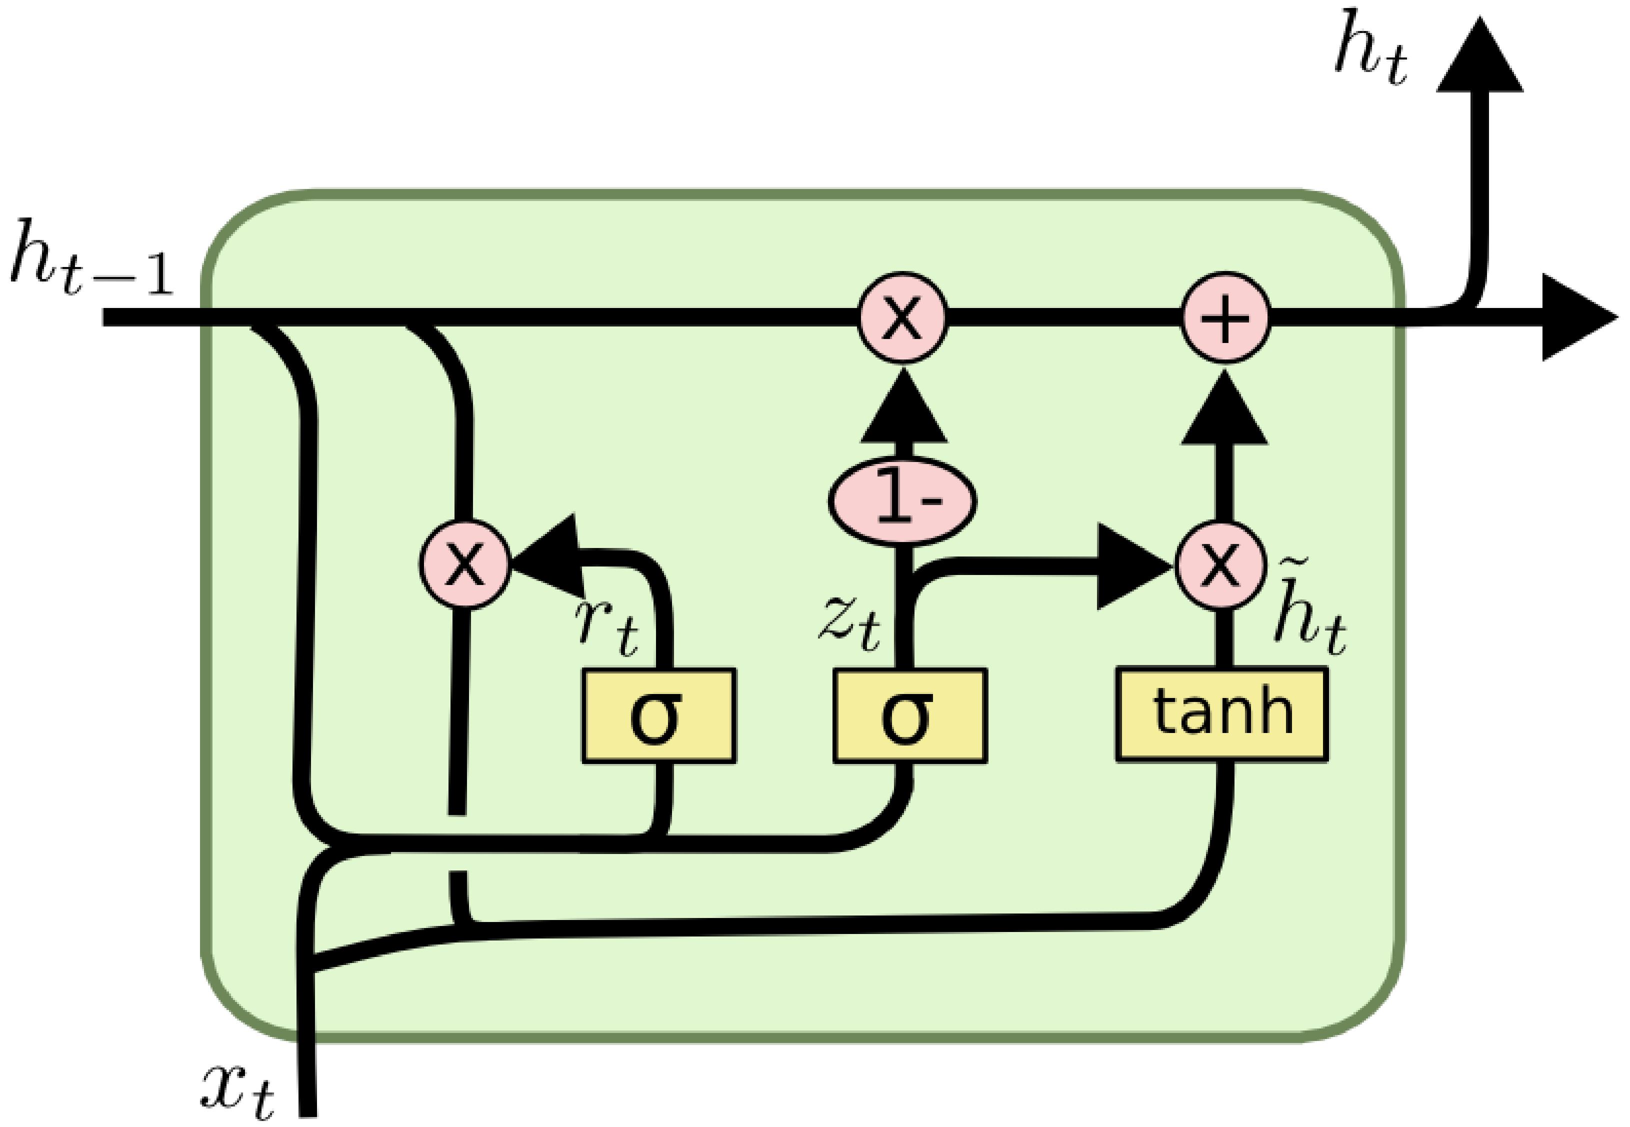

$$z_t = \sigma\left(W_z \cdot [h_{t-1}, x_t]\right)$$

$$r_t = \sigma\left(W_r \cdot [h_{t-1}, x_t]\right)$$

$$\tilde{h}_t = \tanh\left(W \cdot [r_t * h_{t-1}, x_t]\right)$$

$$h_t = (1 - z_t) * h_{t-1} + z_t * \tilde{h}_t$$

推荐阅读

- Understanding Convolutions
  - http://colah.github.io/posts/2014-07-Understanding-Convolutions/
- Conv Nets: A Modular Perspective
  - http://colah.github.io/posts/2014-07-Conv-Nets-Modular/
- The Unreasonable Effectiveness of Recurrent Neural Networks
  - http://karpathy.github.io/2015/05/21/rnn-effectiveness/
- Understanding-LSTMs
  - http://colah.github.io/posts/2015-08-Understanding-LSTMs/

谢谢！